

사회통계연습

변수의 조작과 자료 결합

김현우, PhD¹

¹충북대학교 사회학과 부교수



진행 순서

- 1 새 변수 만들기
- 2 결측치
- 3 자료의 결합

새 변수 만들기

새 변수 만들기

두 개 이상의 변수가 주어졌을 때 새로운 변수를 만들 수 있다.

- Jamovi에서는 [데이터]-[계산]을 통해 새로운 변수를 계산할 수 있다.
- SPSS에서는 [변환]-[변수 계산]을 통해 새로운 변수를 계산할 수 있다.
- 적절한 공식이 있으면 이것 활용할 수도 있다는 점에서, 예전에 배운 [변환]이나 [다른 변수로 코딩변경]과는 다르다!

새 변수 만들기

연습 1. COLLEGE.SAV 자료를 사용하여 전임교원 1인당 재학생수를 나타내는 변수를 만드시오. 이 비율이 지역에 따라 어떻게 다른지 확인해보시오.

새 변수 만들기

연습 2. COLLEGE.SAV 자료를 사용하여 전체교원 중 전임교원의 백분율(%)을 나타내는 변수를 계산하시오. 이 비율이 지역에 따라 어떻게 다른지 확인해보시오.

새 변수 만들기

변수와 관측치가 많은 자료를 분석하다보면 혼란스러울 수 있다.

- SPSS에서 변수의 순서를 바꾸거나 삭제하는 방법을 익히자. 변수의 이름을 바꾸는 법도 연습하자.
- 아쉽게도 Jamovi에선 이런 관리가 다소 불편하다.
- 새 변수를 만든 다음에는 즉각 레이블(label)을 달아두지 않으면 잊어버린다.
- 그러나 원본은 항상 건드리지 않고 놔둔다(적어도 백업을 마련해 둔다!).

결측치

자료를 처음 살펴볼 때 빠진 부분은 없나 주의해야 한다.

- 이 과정은 종종 **기술통계(descriptive statistics)**를 살펴보면서 함께 이루어진다.
- 변수별로 하나하나 기술통계를 살펴보면 이상한 숫자가 실수로 입력되어 있거나 한 경우를 쉽사리 발견할 수 있다.
- **1차 자료(primary data)**인 경우에는 필요에 따라 수집된 설문조사 종이 등을 재검토하고 재입력해야 할 수도 있다.
- 이 단계가 끝나기 전까지 종이 자료 등을 성급히 파쇄해서는 안된다(물론 요즘엔 종이 자료가 없는 경우가 더 많다).

- 2차 자료(secondary data)인 경우에도 이 과정을 생략해서는 안된다.
- (아무래도 입력상의 실수는 보통 없겠지만) 이 과정을 거쳐야만 자료와 친숙해질 수 있기 때문이다.
- 이 과정을 거친 뒤에 각 변수의 레이블과 자료유형(data type) 등을 정리해놓은 문서인 코드북(codebook)을 만들어 두기도 한다.

결측치

무엇보다 결측치 문제에 주목해야 한다.

- 결측치(missing values)는 아예 참여를 거부하지는 않았으나, 특정 문항에 대한 응답만큼은 거절한 경우이다.
- 결측치는 소득, 범죄경력 여부, 성관계 횟수 등 민감한 질문에 흔히 발생한다.
- 그러나 민감함 여부와는 상관없이, 질문이 잘못 설계되어 해당사항이 없는 경우에도 결측치가 발생할 수 있다(e.g., 모든 근로자에게 대학 전공-직업 일치도를 물어보는 경우).
- 빈칸으로 내버려두기도 하지만 -1, -999 같은 값으로 플래그(flag)를 세워두기도 한다(Why?).
- 이렇게 플래그 값을 준 경우 이것이 결측치를 뜻한다고 반드시 지정해야 한다.

결측치

- 만일 결측치 발생이 순수하게 임의(random)로 발생한다면 단지 추정치(estimates)의 표준오차(standard error)를 크게 할 뿐이다.
- 그러므로 이런 경우라면 결측치를 그냥 무시하고 평범하게 분석해도 사실 큰 문제가 되지 않는다(Why?).
- 그러나 응답자의 어떤 특성에 따라 결측치가 발생한다면(가령 범죄를 실제로 저질러 보았다면 범죄경력 여부에 무응답할 수도 있다), 결측치를 무시하는 것은 현명하지 못하다.
- 문제는 응답자의 어떤 특성에 따라 결측치가 발생할 가능성이 매우 높다는 점이다.

결측치

- 결측치를 무시하고 분석하면 결국 **행단위 삭제(listwise deletion)**를 수행하게 된다.
- 단 하나라도 사용하려는 변수에 결측치가 있다면 그 행(row)은 통째로 삭제하므로 상당히 극단적으로 표본 크기가 감소할 수 있다.
- 그러므로 분석 결과표에서 최종적으로 분석에 사용된 표본 크기를 세심하게 살펴보아야 한다.

id	age	politics	economy
1	20	1	3
2	21	1	.
3	.	4	2
4	23	2	.
5	23	.	3
6	.	2	4
7	22	3	1

결측치

- 단순히 말해, 결측치 문제가 너무 심각한 변수는 원칙적으로 사용하지 않는 편이 바람직하다.
- 그러나 꼭 사용해야 한다면 결측치는 기술적으로 메꿔볼 수 있다. 가장 단순한 방법은 **평균 대체(mean imputation)**와 **중앙값 대체(median imputation)** 등이다.
- 결측치를 내포하고 있는 변수를 먼저 기술통계로 살펴보아 (결측치를 제외하고) 평균이나 중앙값을 계산한 다음, 결측치는 평균 또는 중앙값으로 대체할 수 있다.

연습 3. NLSWORK_IND.SAV 자료에서 노조가입 여부(union)의 결측치 비중을 파악한 다음, 결측치를 적절히 대체하시오.

결측치

- 해당 변수의 기술통계를 살펴보고 평균이나 중앙값을 기억해 둔다.
- Jamovi라면 [데이터]-[변환]에서 새로운 변수를 만들고 평균으로 대체할 수 있다.



- SPSS에서 [분석]-[결측값 분석]을 수행하면 얼마나 결측값 비중이 높은지 파악할 수 있다.
- 아까 배웠던 [변환]-[변수 계산]에서 결측치가 담긴 변수를 하나 새로 복사한다.
- 다시 한 번 [변환]-[변수 계산]에서 평균값이나 중앙값으로 대체하되, “조건”에서 MISSING(.) 함수를 사용한다(Why?).

평균대체같은 간단한 방법들은 여러모로 결함을 가지고 있다.

- 결측치 대체 전후로 이 변수의 히스토그램을 그려보자.
- 무엇보다 결측치가 평균에 준할 것이라는 근거는 어디에도 없다(Why?).
- 성별 등 질적변수(qualitative variable)에서 결측치가 발생한 경우 그 평균이나 중앙값은 몹시 어울리지 않는다(최빈값은 그나마 좀 낫다).
- 그러나 일단은 가장 단순하기 때문에 의외로 그동안 널리 사용되어 왔다.

물론 기술적으로 훨씬 세련된 결측치 대체법도 있다.

- 전통적인 센서스(census)에서는 핫덱 대체(hot-deck imputation) 등을 사용했었다.
- 핫덱 대체는 비슷한 속성을 가진 다른 응답자의 값을 “기증받아” 무응답을 대체하는 기법이다.
- 일반적으로 무응답과 특성이 비슷한 개체를 찾기 위해서 여러 관련 변수들을 가지고 대체군을 형성한 다음에, 그 대체군 내에서 기증자를 무작위로 선택하여 기증자의 응답값으로 대체를 실시한다.
- (평균대체에 비한다면) 자료의 분포를 잘 유지해 주고 어떤 형태의 변수에도(e.g., 명목변수) 적용할 수 있다는 장점을 가지고 있다.
- 최근에는 훨씬 더 정교하고 세련된 결측치 대체법이 개발되어 사용되고 있다(학부 수준에서는 다루지 않는다).

자료의 결합

자료의 결합

때때로 두 개 이상의 자료를 결합하여 분석하기도 한다.

- 예를 들어 (한국은행에서 발표하는) 지역별 실업률이 (중앙선거관리위원회에서 발표하는) 지역별 지방선거 여당득표율에 부정적인 영향을 미친다는 연구가설을 살펴본다고 하자.
- 이 경우 (1) 살펴보려는 지방선거의 연도(가령 2022년)의 여당득표율을 구하고, (2) 그에 대응하거나 살짝 이른 시기의 지역별 실업률을 각각 따로 구해야 한다.
- 물론 두 데이터를 나중에 **결합(merging)**해야 하는 것은 물론이다!

자료의 결합

- 자료를 결합하려면 두 자료의 **공통 식별자(common identifiers)**를 기준으로 합쳐야 한다.

ID	var1	var2	var3
588	2	d	1
654	1	y	1
527	1	o	0
955	2	c	0
954	1	t	0

ID	var1	var2	var3
588	290	Apples	Breakfast
654	81	Bananas	Snack
527	63	Apples	Snack
955	6	Pears	Snack
954	146	Pears	Breakfast

ID	var1	var2	var3	var4	var5	var6
588	2	d	1	225	Apples	Breakfast
654	1	y	1	56	Bananas	Snack
527	1	o	0	245	Apples	Snack
955	2	c	0	46	Pears	Snack
954	1	t	0	121	Pears	Breakfast

자료의 결합

- 자료 결합에는 기본적으로 세 가지 방식이 있다: (1) 일대일(one-to-one), (2) 일대다(one-to-many), (3) 다대다(many-to-many).
- 다대다 결합은 좀처럼 사용되지 않으므로 우리 수업에서 다루지 않는다.
- 위의 예제(지역별 실업률 + 지역별 지방선거 여당득표율)는 오로지 1:1만 성립하는 상황이다(Why?).
- 주민등록대장 자료에 납세자명부 자료를 결합한다면 어떤 결합이 필요할까?
- 지난 5년간 응급환자명부의 자료에 주민등록대장 자료를 결합한다면 어떤 결합이 필요할까?
- 아파트 소유자 통계에 재산세 납입대장을 결합한다면 어떤 결합이 필요할까?

자료의 결합

- 추가(append)로 불러오는 다른 형태의 자료 결합도 있다.
- 물론 전혀 다른 설문조사 자료를 함부로 이렇게 합쳐선 안된다(Why?).

ID	var1	var2	var3
588	2	d	1
654	1	y	1
527	1	o	0
955	2	c	0
954	1	t	0



ID	var1	var2	var3
1280	1	p	1
1917	2	t	0
1854	2	x	1
1701	2	e	0
1928	1	q	1



ID	var1	var2	var3
588	2	d	1
654	1	y	1
527	1	o	0
955	2	c	0
954	1	t	0
1280	1	p	1
1917	2	t	0
1854	2	x	1
1701	2	e	0
1928	1	q	1

자료의 결합

- Jamovi에서는 jReshape 모듈을 미리 설치하고 [Data]-[Merge Columns]를 선택한다(기능에 다소 제약이 있다).
- SPSS에서는 [데이터]-[파일 합치기] 안에서 [변수 추가] 또는 [케이스 추가]를 선택하여 수행한다. 각각 결합(merging)과 추가(appending)가 된다.
- 결합을 수행할 때는 두번째 1:1과 세번째 1:m 사이에서 신중히 선택해야 한다.
- 첫번째 ‘파일 순서를 기반으로 하는 일대일 합치기’는 보통 사용하지 않으니 무시해도 좋다.
- 결합을 수행할 때, 공통 식별자의 이름을 꼭 통일시켜야 한다(Why?!)

자료의 결합

연습 4. DATA1.CSV 자료에 DATA2.CSV 자료를 결합하고자 한다. 어떤 공통 식별자를 사용하는 것이 적합한지 그리고 어떤 결합 유형이 적합한지 판단하고 이를 직접 수행하시오.

연습 5. INFO_MODELS.SAV 자료에 INFO_COMPANIES.SAV 자료를 결합하여 수입차 여부(foreign)와 차량무게(weight)의 연관성을 살펴보고자 한다. 어떤 공통 식별자를 사용하는 것이 적합한지, 그리고 어떤 결합 유형이 적합한지 판단하고 이를 직접 수행하시오.