사회통계연습
통계분석의 이해

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

September 2, 2022

진행 순서

1. 데이터에 기반한 사회학 연구
2. 자료분석의 첫 출발

데이터에 기반한 사회학 연구

데이터에 기반한 사회학 연구

경험과학이란 무엇인가? 과학철학자에 따르면...

- 경험주의(empiricism)에 기초하고 있는 과학이다.
- 경험주의는 경험을 지식의 유일한 원천으로 보는 이데올로기다.
- 경험적으로 검증가능한 명제(propositions) (e.g., "지구는 달보다 크다")를 생산하며 이것이 과학적 지식으로 축적된다.
- 이때, 경험에 의한 검증가능성(verifiability)이 생명이다(어원: Verus/참).

데이터에 기반한 사회학 연구

무엇이 경험과학적 지식이 아닌가?

- 논리적으로 검증가능한 명제(e.g., “오각형의 내각의 합은 삼각형 세 개의 내각의 합과 같다”)는 경험과학이 지향하는 지식과는 방향성이 약간 다르다.
- 초자연적이고 형이상학적 명제들, 특히 신학적 명제(e.g., “신은 존재한다”)와 배척된다.
- 윤리적 명제(e.g., “사람은 약속을 지켜야 한다”)나 미적 명제(e.g., “그의 외모는 아름답다”)와도 상관없다.
- 다만 위의 명제들을 경험적 명제로 뒤바꾸어 경험과학적 연구 주제로 삼을 수 있다!

데이터에 기반한 사회학 연구

경험과학에서는 귀납추론을 강조한다.

- 귀납추론(inductive reasoning)은 개별 사실에 대한 경험을 토대로 증거를 수집하여 이 자료(data)를 관통하는 (가능한 최대로 일반화된) 명제를 정립하는 방향으로(즉 구체에서 추상으로) 움직인다.
- 반면 연역추론(deductive reasoning)은 논리적으로 흠없는 명제를 세우고 이것을 통해 개별 사실을 설명하는 방향으로(즉 추상에서 구체로) 움직인다.

데이터에 기반한 사회학 연구

경험과학은 결국 자료와 측정을 토대로 한다.

- 주장에는 증거(evidence)가 필요하고, 증거는 자료(data)를 토대로 한다.
- 너무나도 당연한 말이지만, 자료가 축적되기 위해서는 관찰(observation)이 선행되어야 한다!
- 측정(measurement)이란 어떤 현상을 관찰한 후 일정한 규칙에 따라 수치를 부여하는 것이다.
- (사회학의 맥락에서 본다면) 이런 행위에는 사회 현상을 계량화(quantify)할 수 있다는 세계관을 내포하고 있다(어떤 사람은 이 관념을 극도로 배격한다).

데이터에 기반한 사회학 연구

현실 사회 곳곳에서 사회통계가 사용된다.

- 모두가 동의하는 주장에 대해서는 별로 논리나 증거가 필요하지 않다(Why?).
- 그러나 설득은 다원화된 현대사회에서 필수적인 커뮤니케이션이므로 논리와 증거를 간단히 넘길 수 없다.
- 사회통계학은 '증거'의 수집과 제시, 그리고 해석을 위한 한 방법이다(그러나 유일한 방법은 아니다).
- (당신이 좋든 싫든) 사회통계는 폭넓게 사용되어 왔고 앞으로도 더욱 확대될 것이다. 이것을 읽고 쓰는 힘을 익힐 필요는 여기에서 나온다.
- 사회통계의 힘은 연습에서 나온다.

자료분석의 첫 출발

자료분석의 첫 출발

자료와 관찰단위 그리고 분석단위의 개념을 되짚어보자.

- 자료(data): 분석 대상의 속성(attributes)을 기록한 수열(series).
- "자료의 관찰"은 사람을 단위로 이루어졌으나, 나중에 "자료의 분석"은 각 사람이 속한 지역 또는 국가 단위로 이루어질 수도 있다.
- 관찰단위(unit of observations): 자료의 관찰과 수집이 이루어지는 단위
- 분석단위(unit of analysis): 분석이 수행되고 발견이 일반화(generalization)될 수 있는 단위

자료분석의 첫 출발

열은 변수가 되고, 행은 관측치가 된다.

- 앞서 데이터는 수열이라고 말했지만, 사실 여러 변수(variables)를 갖기 때문에 각각의 변수가 하나씩 수열을 이루어서 결국 행렬(matrix)이 된다. 즉 데이터는 사각형이다.
- 행렬은 행과 열의 조합이다. 행은 가로고 관측치(observations)가 된다. 열은 세로고 변수(variables)가 된다.
- 변수는 변(vary)할 수 있는(able) 숫자이고, 관측치는 해당 변수에 실제 채워진 값들이다.
- 데이터를 남에게 설명할 때 "변수는 몇 개, 관측치는 몇 개"와 같은 식으로 표현할 수 있다.

자료분석의 첫 출발

SPSS를 켜고 hsb2.sav 파일을 불러오자.

- SPSS를 기동하기 위해서는 (1) 해당 아이콘을 더블클릭하거나 (2) SPSS 데이터파일을 더블클릭하거나 (3) Ctrl-Esc 다음 SPSS를 입력한다.
- 각 윈도우가 무엇을 의미하는지 살펴보자.
- 이 자료에서 데이터가 무엇이고 관찰단위가 무엇인지 파악해보자.
- 변수와 관측치는 각각 몇 개인가?
- 이 자료는 누구에게서 수집한건가? 왜 수집했나? 이것을 가지고 무엇을 할 수 있나?

자료분석의 첫 출발

각각의 변수마다 자료유형이 다를 수 있다.

- 자료유형(data type)이 다르다는 것은 보다 구체적으로 측정의 척도(scales of measurement)가 다르다는 것을 뜻한다.
- 측정의 척도란 변수가 정의(define)되고 유형화(categorize) 되는 방식을 뜻한다.
- 보통 네 종류의 척도를 거론할 수 있다: 명목(nominal), 서열(ordinal), 등간(interval), 비율(ratio).

자료분석의 첫 출발

네 종류의 척도에는 위계적인 관계가 있다.

- 명목척도(nominal scale): 범주(category)가 존재할 뿐, 그들 사이에 우열이나 대소가 없음.
- 서열척도(ordinal scale): 범주들 사이에 서열 혹은 순서(order)가 있음.
- 등간척도(interval scale): 범주들 사이에 우열이나 대소가 있고, 그 간격은 동등함(등간; equal interval).
- 비율척도(ratio scale): 범주들 사이에 우열이나 대소가 있고, 그 간격도 동일하며, 절대영(absolute zero) 또한 의미를 가짐.

자료분석의 첫 출발

hsb2.sav 파일에서 사용된 변수의 척도를 파악해보자.

변수	척도	변수	척도
id		read	
female		write	
race		math	
ses		science	
schtyp		socst	
prog			

자료분석의 첫 출발

SPSS에서 자료유형을 확인하고 변환해보자.

- SPSS의 한국어 번역은 통계용어규정을 제대로 반영하고 있지 않음에 주의하자.
- 측도는 measure의 번역어이고, nominal, ordinal, scale은 각각 명목형, 순서형, 척도로 번역되었다.
- 위의 척도(scale)는 결국 비율척도과 등간척도를 뭉뚱그린 것이다. 사실 이런 경우가 종종 있다(Why?).
- 자료를 보고 필요에 따라 측도를 바꾸어보자. 측도를 옳게 설정하는 것은 종종 건너뛰어도 된다(하지만 가끔씩 필수적이다).

자료분석의 첫 출발

이번엔 states.sav 파일을 열자.

- 이 자료는 어떻게 수집된 것인가? 왜 수집했나? 이것을 가지고 무엇을 할 수 있나?
- 관찰단위가 무엇인가? 변수는 몇 개인가? 관측치는 몇 개인가?
- 결측치(missing values)를 함부로 무시해서는 안된다(Why?).

자료분석의 첫 출발

states.sav 파일에서 사용된 개별 변수의 척도를 파악해보자.

- 특히 집계(aggregation) 이전의 자료유형은 어땠을지도 상상해보자.

변수	원래 척도	현재 척도	변수	원래 척도	현재 척도
state			house		
region			senate		
pop			csat		
area			vsat		
density			msat		
metro			percent		
waste			expense		
energy			income		
miles			high		
toxic			college		
green					

자료분석의 첫 출발

좀 더 단순하게 질적-양적 구분을 하기도 한다.

- 명목척도와 서열척도를 질적(qualitative) 척도로, 등간척도와 비율척도를 양적(quantitative) 척도로 묶을 수도 있다.
- 종종 리커트 척도(Likert scale)는 본래 성질상 서열척도이지만, 편의상 대체로 등간(approximately interval)이라고 부르며 양적척도처럼 분석하기도 한다.
- 혹은 같은 개념에 대해 여러 개의 리커트 척도를 활용하여 측정한 뒤, 이를 모두 더하거나 평균을 구한 점수를 대체로 등간척도로 보기도 한다.

자료분석의 첫 출발

poleff.sav를 불러와 정치적 효능감 지표를 확인해보자

- 정치적 효능감 정의
- 만일 하나의 문항만으로 정치적 효능감을 측정해야 한다면 그 문항은 어떤 것일까?
- 자료에서 주어진 각각의 문항은 어떤 척도로 볼 수 있을까?
- 모든 문항에 대해 전반적으로 긍정적으로 대답한다면 그 사람의 정치적 효능감을 어떻게 말할 수 있을까?
- 각 문항에 대한 응답 총점은 어떤 척도로 볼 수 있을까?

자료분석의 첫 출발

자료유형의 판별은 기초적이지만 매우 필수적이다.

- 거의 모든 통계학이나 데이터분석 수업이 자료유형 식별로부터 출발한다.
- 특히 숙제 등을 통해 자꾸 여러 자료유형을 제시하고 명목, 서열, 등간, 비율, 또는 대체로 등간(approximately interval)인지 여부를 자꾸 학습하도록 유도한다.
- 결측치(missing values)를 함부로 무시해서는 안된다(Why?).

끝!

와~ 숙제다~