사회통계연습
자료변환과 기술통계

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

September 16, 2022

진행 순서

1. 지난 주 리뷰
2. 자료변환과 응용
3. 기술통계

지난 주 리뷰

지난 주 리뷰

1. 미국 대학원에 진학하기 위한 시험 가운데 하나는 Graduate Record Examination (GRE)이다. 이것은 표준화된 시험으로 점수는 200점에서 800점 사이에 분포한다. 그 전체 평균은 500점이고 표준편차는 100점이다. [등간척도]

2. 초등학교 학생들은 교사에 의한 평가 결과에 따라 읽기 불가(0점), 초보수준 읽기 가능 (1점), 중급수준 읽기 가능 (2점), 상급수준 읽기 가능 (3점)으로 분류된다. 이 점수에 따라 학생들은 적절한 독서 그룹에 배정된다. [서열척도]

지난 주 리뷰

3. 임상면담 과정에서 재해 생존자들은 그들이 겪은 특정 유형의 PTSD (외상후 스트레스 장애 증후군)에 대해 "네" 또는 "아니오"라고 대답하도록 지시받았다. "네"에 대해서는 1점을, "아니오"에 대해서는 0점을 부여하였다. [명목척도]

4. C대학에서는 기숙사를 증설하면서 어떤 기숙사가 학생들에게 가장 인기있는지 조사하고자 한다. 이에 담당자는 각각의 기숙사에 대해 받은 입실신청서의 갯수를 세고 그 숫자에 따라 순위를 부여하였다. [서열척도]

지난 주 리뷰

5. 임상면담 과정에서 재해 생존자들은 그들이 겪은 서로 다른 유형의 PTSD (외상후 스트레스 장애 증후군)에 대해 각각 "네" 또는 "아니오"라고 대답하도록 지시받았다. 연구자는 "네"라는 응답 횟수의 총합을 계산하였다. [비율척도]

- 총합이라는 단어에 주의해야 한다. 문제를 끝까지 안 읽어 명목척도로 많이 답했다.

6. 한 연구자는 중년보다 노년에서 일일주기체온이 더 불안정하게 변화하는지 여부를 조사하고자 한다. 체온은 3일동안 약 15분 간격에 따라 화씨(F)로 측정되었다. [등간척도 또는 대체로 등간]

지난 주 리뷰

7. 시내 정신건강센터에 입소하는 모든 환자들은 증세 체크리스트를 작성하도록 요구받는다. 이 체크리스트는 지난 주 특정한 증세를 얼마나 자주 겪었던가를 조사하며, 입소자들은 "거의 겪지 않는다(0점)", "때때로 겪는다(1점)", "자주 겪는다(2점)", "거의 언제나 겪는다(3점)"으로 응답한다. [서열척도]

- 리커트 척도는 기본적으로 서열척도이다. 대체로 등간척도라고 답한 경우가 종종 있었다.

8. 실험 참가자들은 컴퓨터 앞에 앉도록 지시받았다. 이제 30초 간격으로 드라이버 그림이 화면 어딘가에 나타난다. 때때로 이 드라이버는 (+)자이거나 (-)자 꼴로 다르게 나타난다. 실험 참가자들은 (+)자인 경우 Y 키를 누르고, (-)자인 경우 N 키를 누르도록 지시받았다. 옳게 응답한 횟수의 총합이 각 참가자들의 점수로 배정되었다. [비율척도]

지난 주 리뷰

9. 시내 정신건강센터에 입소하는 모든 환자들은 여러 증세에 대한 체크리스트를 작성하도록 요구받는다. 이 체크리스트는 지난 주 여러 증세들을 얼마나 자주 겪었던가를 조사하며, 입소자들은 "거의 겪지 않는다(0점)", "때때로 겪는다(1점)", "자주 겪는다(2점)", "거의 언제나 겪는다(3점)"으로 응답한다. 응답한 점수의 총합이 해당 입소자의 증세 심각도로 평가된다. [대체로 등간척도]

- 서열 또는 비율척도로 답하는 경우가 많았으나 대체로 등간척도이다.

10. 한 연구자는 실험참가자들에게 자신의 삶에서 중요한 사람들과의 관계에 대해 떠올려보라고 요청하였다. 각각의 관계에 대해 "안정적임(1점)", "몰두함(2점)", "두려움(3점)", "거부함(4점)" 가운데 하나로 평가하도록 지시하였다. [명목척도]

- 가장 많이 틀린 문제로 항목에는 서열이 없다!

지난 주 리뷰

- 평균점수는 67.5점에 불과. 다수의 학생들이 절대영(absolute zero) 개념을 이해하지 못해 비율과 등간 사이에서 혼동하는 것 같다.
- 교재와 지난 학기 강의록으로 복습을 해야 한다. 척도 식별은 기초가 되므로 실패하면 시험에서 확실히 망한다.
- 이유를 적지 않으면 0점. 파일이름에 자기 이름쓰면 이제부터 감점함. PDF로 제출하지 말 것. 답을 하나만 적을 것("서열이거나 등간이다" 등은 0점).
- 늦게 제출시 무조건 0점.

자료변환과 응용

자료변환과 응용

척도 간에는 변환이 가능하지만 오로지 일방향으로만 가능하다!

- 자료변환(data transformation)을 특히 재부호화(recoding)라고 부른다(기억이 안나면 복습하자).
- 정보량에 차이가 있기 때문에 변환하는 순간 "사라진 정보"는 복원 불가능하게 된다.
- 즉 정보가 많은 쪽에서 정보가 적은 쪽으로만 변환 가능하다(Why?).
- 예를 들면 비율척도로 측정된 월평균 소득은 다음과 같이 서열척도로 변환할 수 있지만, 그 역은 성립하지 않는다.

비율척도	서열척도
100만원 미만	1
100만원 이상 ~ 300만원 미만	2
300만원 이상 ~ 500만원 미만	3
500만원 이상	4

자료변환과 응용

재부호화는 정보상실로 이어지지만 해석상의 편의를 위해 유용할 수 있다.

- 가령 우리는 "그 사람 월급은 481만원이야" 표현 대신 "그 사람 돈 다소 많이 벌어" 라는 표현을 사용한다(Why?).
- 언어적 표현(oral presentation)은 수학 특유의 엄밀성(rigorousness)을 상실하지만, 인간 사회에서의 의사소통에 유용하다.

비율척도	서열척도	언어적 표현
100만원 미만	1	"돈을 매우 못 벌어"
100만원 이상~300만원 미만	2	"돈을 다소 못 벌어"
300만원 이상~500만원 미만	3	"돈을 다소 많이 벌어"
500만원 이상	4	"돈을 매우 많이 벌어"

자료변환과 응용

연습 1. INCOM0.SAV 자료를 SPSS에서 불러들여 앞서 제시된 기준대로 (비율척도를 서열척도로) 재부호화하시오.

자료변환과 응용

재부호화의 기준은 잘 생각해야 한다.

- 언어적 표현은 그 자체로 상당한 설득력을 갖게 된다(Why?). 그러나 기준점(cutpoint 또는 threshold)에 따라 사실을 왜곡할 수 있다.
- 위의 재부호화 기준(recoding scheme)이 타당한지는 맥락에 달려있다.
- 사회통계를 연습한다는 것은 결국 통계적 결과물에 대한 언어적 표현을 연습하는 것이기도 하다(Why?).

자료변환과 응용

어떤 재부호화하는 조금 다른 상황에서 이루어진다.

- 많은 사회조사에서는 성별 변수를 {남성=1, 여성=2}으로 부호화(coding)한다.
- 이것은 분석에 그대로 사용될 경우 해석이 다소 불편하다(Why?).
- 그러므로 성별 변수는 주로 {남성=0, 여성=1} 또는 {여성=0, 남성=1}으로 재부호화된다.

자료변환과 응용

연습 2. INCOM0.SAV 자료를 SPSS에서 불러들여 앞서 제시된 기준 중 하나를 사용하여 성별을 재부호화하시오. 적절히 변수 및 입력값 레이블 (label) 또한 부여하시오.

자료변환과 응용

사회통계학에서는 설문조사로 수집된 자료를 분석하는 경우가 많다.

- 최근 동향을 보면 데이터 수집방식이 훨씬 더 다원화되었지만 여전히 설문조사는 중요한 자료의 원천이다.
- 사회현상에 관해 개인의 가치와 태도에 대해 설문할 때 리커트 척도(Likert scale)가 압도적으로 많이 사용된다.
- 한편 많은 사회조사에서는 리커트 척도의 초기 부호화 기준을 종종 거꾸로 되어있다. 다시 말해, 문항에 가장 적극적인 가치/태도를 보일 경우 가장 작은 값이 부여된다.
- 하지만 문항에 가장 적극적인 가치/태도를 보일 경우 가장 큰 값이 부여되는 편이 보다 직관적이므로(Why?), 역부호화(reverse-coding)가 필요하다.

자료변환과 응용

※ 이번에는 귀하의 전반적인 가치관에 대해서 여쭈어 보겠습니다.

HAPPY
66. 귀하의 요즘 생활을 고려할 때 전반적으로 얼마나 행복 또는 불행하다고 생각하십니까?

____ ① 매우 행복하다
____ ② 다소 행복하다
____ ③ 별로 행복하지 않다
____ ④ 전혀 행복하지 않다
____ (8) 선택할 수 없음

FAMSATIS
67. 모든 것을 고려해 봤을 때, 가족과의 관계에 얼마나 만족하십니까?

____ ① 전적으로 만족한다
____ ② 매우 만족한다
____ ③ 다소 만족한다
____ ④ 만족하지도 불만족하지도 않는다
____ ⑤ 다소 불만족한다
____ ⑥ 매우 불만족한다
____ ⑦ 전적으로 불만족한다
____ (8) 선택할 수 없음

68. 귀하는 다음의 각 상황에 대해서 옳다고 생각하십니까, 아니면 옳지 않다고 생각하십니까?

		전적으로 옳지 않다	대부분 옳지 않다	때에 따라 옳지 않다	전혀 잘못되지 않았다	선택할 수 없음
SEXATT1	1) 남녀가 결혼 전에 성관계를 갖는 것	①	②	③	④	(8)
SEXATT2	2) 결혼한 사람이 배우자가 아닌 사람과 성관계를 갖는 것	①	②	③	④	(8)
SEXATT3	3) 동성의 성인끼리 성관계를 갖는 것(동성애)	①	②	③	④	(8)

한국종합사회조사(KGSS)에서 사용된 리커트 척도의 예제

자료변환과 응용

연습 3. VALUE.SAV 자료를 SPSS에서 불러들여 HAPPY와 FAMSATIS 변수를 역부호화하시오. 또한 SEXATT1, SEXATT2, SEXATT3의 세 변수를 그대로 사용할 수 있는지 판단하고, 만약 필요하다면 적절히 재부호화하시오. 필요하지 않다면 그대로 놔두시오.

기술통계

기술통계

우리는 기술통계를 통해 자료를 요약한다.

- 기술통계(descriptive statistics)는 자료를 요약하는 목적을 가지고 있으므로 요약통계(summary statistics)라고도 부를 수 있다.
- "자료를 요약하라" 라는 말은 곧 기술통계를 제시하고 이를 언어적으로 표현하라는 말과도 같다.
- 자료를 요약하라고 했는데 자료를 그대로 복사해서 붙여넣으면 멍청한 짓이다(Why?).

기술통계

무엇보다, 가장 먼저, 자료의 척도를 옳게 식별해야 한다!

- 교재 23페이지에서도 설명하고 있듯 어떤 비율척도일수록 보다 다양한 기술통계를 활용할 수 있다.

변수유형	척도	추가되는 연산	요약 통계량
질적변수	명목척도	셈	빈도(frequency)와 구성비(percentage) 최빈값(mode)
	서열척도	순위 측정	중앙값(median) 범위(range)
양적변수	등간척도	덧셈/뺄셈	산술평균(arithmetic mean) 분산(variance)과 표준편차(standard deviation)
	비율척도	곱셈/나눗셈	기하평균(geometric mean) 조화평균(harmonic mean)

기술통계

기술통계는 주로 중심성향과 산포성향으로 나뉘어 보고된다.

- 중심성향(central tendency)는 자료를 대표하는(representative) 값이 자료의 가운데 어딘가에 위치해 있다라는 아이디어에 기반한다.
- 주로 세 가지 통계가 중심성향을 파악하기 위해 사용된다:

  (1) 평균(mean)
  (2) 중앙값(median)
  (3) 최빈값(mode)

- 셋 중 어느 것이 가장 좋은가? 평균, 중위값, 최빈값이 모두 같거나 비슷하면 뭘 써도 상관없다.
- 한편 평균은 극단값(outliers; extremes)에 민감하므로 극단값이 자료 속에 끼어있는 경우 평균이 커진다.

기술통계

중심성향으로만 충분히 자료를 잘 요약할 수 있을까? 사실은 그렇지 않다.

- 다음의 데이터가 주어졌다: [-10, 0, 0, 10]
- 평균, 중앙값, 최빈치는 각각 얼마인가?
- 다음의 데이터가 주어졌다: [-100, 0, 0, 100]
- 평균, 중앙값, 최빈치는 각각 얼마인가?
- 두 데이터는 정말로 같은가? 중심성향에 근거하여 두 데이터가 잘 요약되었나?

기술통계

그러므로 관찰값들이 얼마나 흩어져 있는가를 측정하는 통계가 필요하다.

- 산포성향(dispersion tendency)는 자료를 대표하는(representative) 값이 자료의 흩어진 정도에서 나타난다는 아이디어에 기반한다.
- 주로 세 가지 통계가 산포성향을 파악하기 위해 사용된다:

  (1) 범위(range)
  (2) 사분위수간 범위(interquartile range; IQR)
  (3) 분산(variance) 또는 표준편차(standard deviation)

기술통계

- 주로 세 가지 통계가 산포성향을 파악하기 위해 사용된다:

  (1) 범위(range)
  (2) 사분위수간 범위(interquartile range; IQR)
  (3) 분산(variance) 또는 표준편차(standard deviation)

기술통계

연습 4. INCOME.SAV 자료를 SPSS에서 불러들여 월평균 가구소득의 기술통계를 보고하시오. 학력별 월평균 가구소득의 기술통계를 각각 보고하시오.