사회통계연습
시각화(I)

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

September 23, 2022

진행 순서

1. 지난 주 리뷰
2. 도수분포표와 히스토그램
3. 트리맵과 오자이브

지난 주 리뷰

지난 주 리뷰

1. 1. 평균 수심이 10cm인 하천에서 장거한이 익사하고 말았다. 이 미스테리를 설명하시오. (10점)

- 평균만으로는 자료의 산포를 알 수 없다. 사람이 빠져죽을만큼 깊은 곳이 얼마든지 있을 수 있다.
- 평균은 중심성향을 파악하기 위한 통계로 활용되는데, 이 때 평균은 하천의 중심성향을 나타낸 것일 뿐 평균 만으로 전체 하천의 수심을 이해하기에 무리가 있다. 즉 장거한이 익사한 곳은 하천 중에서도 평균에 비해 깊은 극단값에 위치해 있을 가능성을 간과할 수 없다.
- "엎드렸다" 틀림.

지난 주 리뷰

2. 네오청주에 살고 있는 2인 이상 근로가구의 평균 저축액은 1800만 원이라고 하지만, 당신의 저축액은 50만 원이다. 왜 이런 경우가 있을 수 있는지 설명하시오. (10점)

- 평균만으로는 자료의 산포를 알 수 없다. 저축액이 50만 원 정도로 가난한 사람이 얼마든지 있을 수 있다(e.g., 당신).

지난 주 리뷰

3. 범위, 사분위수간 범위, 분산의 장단점을 통계학적으로 논하시오. (10점)

- 범위는 계산이 단순하나(장점) 극단치에 취약함(단점).
- 사분위수간 범위는 극단치에 강건하나(장점), 자료를 최대한 활용하지 않음(단점).
- 분산은 자료를 최대한 활용하나(장점) 단위에 민감(unit sensitive)함(단점).

지난 주 리뷰

4. SAMPLE.SAV를 활용하여 표본의 특성을 나타내는 표를 작성하시오. 이때 황정미(2010)의 기술통계표를 참고하여 이와 최대한 유사한 형태로 만드시오. 이때 SAMPLE.SAV와 황정미(2010)가 사용한 자료는 같은 것이 아니므로, 구성이 똑같지 않은 변수(e.g., 지역, 지역크기, 직업)에 대해서는 (SAMPLE.SAV에서) 주어진 변수를 그대로 활용하되, 연령 및 가구소득 수준만큼은 황정미(2010)의 재부호화 기준(recoding scheme)을 그대로 흉내내시오. (70점)

지난 주 리뷰

구분		사례수	%
전체		1,205	100
지역별	서울	234	19.4
	경기	355	29.5
	강원	38	3.2
	충청	132	11.0
	경상	314	26.1
	전라	120	10.0
	제주	12	1.0
지역크기별	큰 도시	484	40.3
	큰 도시 주변	315	26.2
	작은 도시	252	21.0
	시골마을	148	12.3
	외딴 곳	3	0.2
	모름/무응답	3	0.2

지난 주 리뷰

성별	남자	508	42.2
	여자	697	57.8
연령별	10대	11	0.9
	20대	124	10.3
	30대	158	13.1
	40대	187	15.5
	50대	296	24.6
	60세이상	429	35.6
학력별	무학	56	4.7
	초등(국민)학교	135	11.2
	중학교	118	9.8
	고등학교	411	34.2
	전문대학(2・3년제)	152	12.6
	대학교(4년제)	305	25.4
	대학원(석사과정)	23	1.9
	대학원(박사과정)	3	0.2
	모름/무응답	2	0.2

지난 주 리뷰

직업별	군인	1	0.1
	관리자	29	2.8
	전문가 및 관련 종사자	141	13.7
	사무 종사자	219	21.3
	서비스 종사자	143	13.9
	판매 종사자	153	14.9
	농림어업 숙련 종사자	95	9.2
	기능원 및 관련 기능 종사자	57	5.5
	장치,기계조작 및 조립종사자	66	6.4
	단순노무 종사자	124	12.1
	모름/무응답	177	14.7
월평균 가구소득 수준	100만원이하	131	10.9
	101-200만원	168	13.9
	201-300만원	181	15.0
	301-500만원	311	25.8
	501-1천만원	310	25.7
	1천만원초과	46	3.8
	모름/무응답	58	4.8

지난 주 리뷰

총평

- 평균점수는 약 83점.
- 표를 깔끔하게 만들어야 한다(소수점 반올림, 선 명확하게 긋기, 칸 크기 등). 문제가 있으면 감점하였다.
- 꼭 결측값(missing values)을 "모름/무응답"으로 정리하여야 한다.
- 모든 데이터를 사용해야 한다! 간혹 하나의 변수나 하나의 범주를 통째로 빼먹은 경우가 있었다.
- 표를 옮기는 과정에서 값을 잘못 입력하는 경우가 빈번하였다. 실수를 피하기 위해서는 되도록 표를 그대로 옮기고 정리만 해주어야 한다(새로 작성해서는 안된다).
- 4회 이상 숙제 미제출시 무조건 F가 된다. 직접 서류를 제출하지 않은 공결은 무효처리한다.

도수분포표와 히스토그램

도수분포표와 히스토그램

가장 중요한 단일변수 시각화 기법은 빈도분포표와 히스토그램이다.

- 범주형(categorical) 자료가 주어져 있으면 각 범주별로 하나하나 세서(tally) 즉각 빈도분포표 안에 요약하여 나타낼 수 있다.

ID	female	IQ	income	socialclass
1	1	135	250	1
2	0	110	310	2
3	1	128	1500	3
4	0	98	122	2
5	1	106	450	2
6	0	102	190	1

socialclass	Frequency	Perc.	Cum. Perc.
1	2	33.33%	33.33%
2	3	50.00%	83.33%
3	1	16.67%	100.00%

도수분포표와 히스토그램

- 이렇게 만들어진 빈도분포표를 그림으로 나타내면 곧 막대차트(bar chart) 또는 히스토그램(histogram)이 된다.
- 도수분포표와 히스토그램 그리고 막대차트는 본질적으로 같은 정보를 전달한다 (Why?).

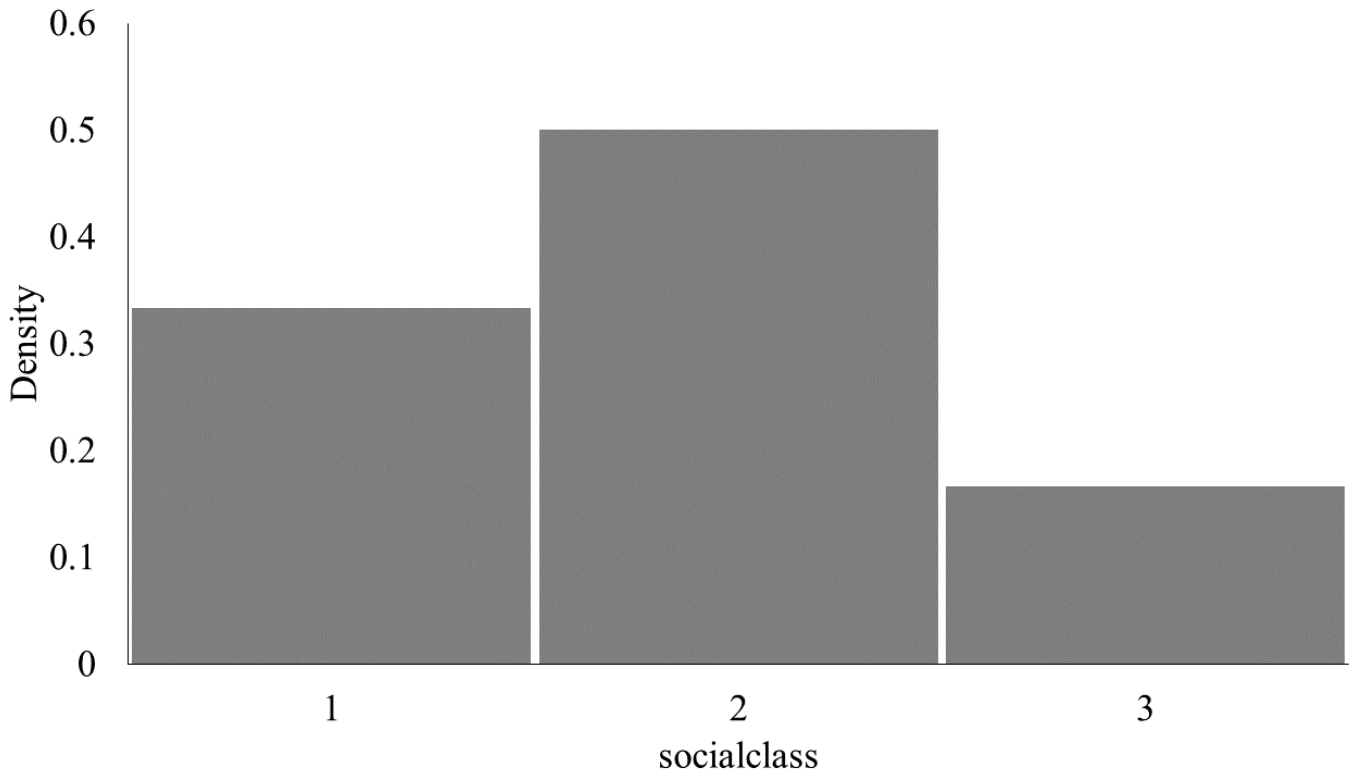

도수분포표와 히스토그램

연습 1. NHANES.SAV 자료를 SPSS에서 불러들여 주관적 건강(health)의 빈도분포표와 히스토그램(또는 막대차트)을 작성하고 그 의미를 해석하시오.

도수분포표와 히스토그램

- 빈도분포표와 막대차트는 결국 범주형 자료일 때 사용할 수 있다(Why?).
- 교과서에 따르면 히스토그램은 양적변수에 대응하고, 막대차트는 질적변수에 대응하지만 현실적으로는 거의 같다(Why?).
- 양적변수는 질적변수로 바꿀 수 있으므로 결국 범주형 자료로 재부호화하면 쉽게 시각화할 수 있다([변환]-[다른 변수로 코딩변경]).
- 만약 양적변수가 주어졌다면 (재부호화하기 앞서) 합리적인 기준점(cutpoint 또는 threshold)을 잡기 위해 기술통계표를 먼저 확인보아야 할 필요가 있다(Why?).

도수분포표와 히스토그램

연습 2. NHANES.SAV 자료를 SPSS에서 불러들여 이완기 혈압(bpdiast)의 빈도분포표와 히스토그램(또는 막대차트)을 작성하고 그 의미를 해석하시오. 자신이 선택한 구간설정의 근거에 대해서도 논의하시오.

도수분포표와 히스토그램

(서열척도가 같은) 여러 변수들을 하나의 도수분포표로 나타낼 수 있다.

- 기존의 도수분포표는 하나의 변수를 하나의 도수분포표로 나타내므로 부피가 상대적으로 크다.
- 만일 여러 변수들이 동일한 부호화 기준(coding scheme)을 사용하고 있다면(e.g., 리커트 척도), 변수를 행(rows)에 놓고 퍼센트를 열(columns)에 놓는 하나의 도수분포표로 요약할 수도 있다.
- SPSS에서는 [분석]-[표]-[사용자 정의 표]로 간다. 도수분포표로 요약할 변수를 "행"에 넣고 "요약통계량"에서 '빈도' 대신 '행 퍼센트' 안의 '행 N %'을 넣는다. "선택한 항목에 적용"하고 빠져나와 "범주 위치"는 '기본값' 대신 '행 레이블을 열로 표시'한다.
- SPSS에서는 [그래프]-[차트 작성기]를 사용하여 여러 그래프를 그릴 수 있다.
- 물론 (시간은 훨씬 더 걸리지만) 여러 개의 도수분포표를 만든 뒤 엑셀에서 편집할 수도 있다.

도수분포표와 히스토그램

연습 3. VALUE.SAV 자료를 SPSS에서 불러들여 성관계에 대한 태도 세 변수에 관한 통합형 빈도분포표와 막대차트를 작성하고 그 결과를 해석하시오.

도수분포표와 히스토그램

- 물론 (시간은 훨씬 더 걸리지만) 여러 개의 도수분포표를 만든 뒤 엑셀에서 편집할 수도 있다.

	A	B	C	D	E	F
1						
2	성관계에 대한 태도	전적으로 옳지 않다	대부분 옳지 않다	때에 따라 옳지 않다	전혀 잘못되지 않았다	
3	혼전성교	17.60%	13.40%	28.90%	40.10%	
4	혼외성교	70.70%	18.90%	7.40%	3.10%	
5	동성성교	51.60%	15.60%	13.80%	18.90%	
6	(참고: 반올림으로 인해 합이 100%와 다를 수 있음)					
7						
8						

- 한편 이런 나열을 통해 변수간 비교(comparison)를 해볼 수는 있지만, 연관성(association)을 본다고는 할 수 없다(Why?).

트리맵과 오자이브

트리맵과 오자이브

트리맵(treemap)은 위계적(hierarchical) 자료를 나타내기에 좋다.

- 자료에 위계성이 뚜렷하면 뚜렷할수록 트리맵은 독자에게 신선한 충격을 안겨준다 (e.g., "불균형 문제가 이렇게 심했어?")
- 최근 계산과학(computational science) 및 계산 알고리즘의 혁신 웨이브에 힘입어 인기몰이를 하고 있다.
- 각 사각형의 면적은 개별 항목별로 주어진 값에 비례한다(area-based visualization).
- 트리맵은 SPSS보다는 엑셀을 사용하자.

트리맵과 오자이브

연습 4. 온실가스 에너지 목표관리 명세서 주요정보.xslx를 엑셀에서 불러들여 온실가스 배출량 트리맵을 작성하시오.

트리맵과 오자이브

- 법인명과 온실가스 배출량만을 개별적으로 복사하여 새 탭에 붙여넣자. 자료를 이리저리 정렬(sort)하여 이상한 값을 제거해야 한다.
- 온실가스 배출량 변수를 하이라이트하여 [삽입]-[트리맵]을 선택한다. 약간의 꾸미기는 역시 필요하다.

트리맵과 오자이브

오자이브는 구간별 누적백분율을 시각화한다.

- 오자이브(ogive)의 x축은 (나타내고자 하는 변수의) 도수(frequency) 혹은 계급구간(class interval)을 나타내고, y축은 누적백분율(cumulative percentage)을 나타낸다.
- 오자이브와 로렌츠 곡선(Lorenz curve)은 (소득불평등을 나타내는) 이른바 지니계수(gini coefficient)와 직결된 시각화 기법이다.
- 두 시각화 기법의 공통점과 차이점을 생각해보자!

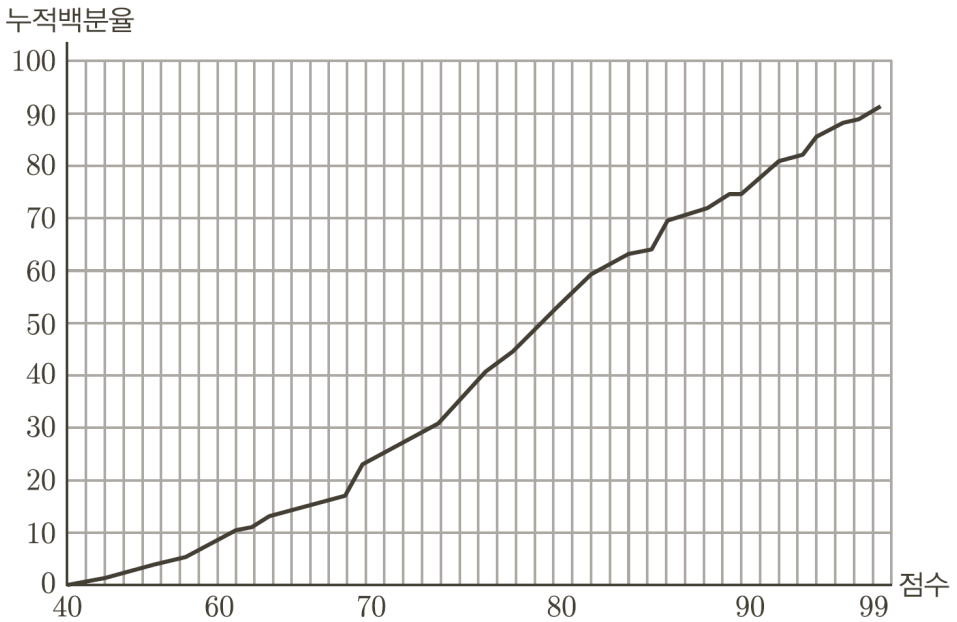

트리맵과 오자이브

연습 5. INCOME.SAV 자료를 SPSS에서 불러들여 월평균 가구소득을 오자이브로 시각화하고 그 함의를 해석하시오.

트리맵과 오자이브

- SPSS에서는 [그래프]-[차트 작성기]에서 '선형 차트'를 먼저 고르고 "통계량"을 '빈도'가 아닌 '누적 퍼센트'로 바꾸어 그릴 수 있다.
- 이 오자이브의 의미를 해석해보자.
- 양적변수가 주어졌을 때 오자이브를 그대로 그릴 수도 있다. 이렇게 하는 편이 좀 더 보기좋다.
- 하지만 경우에 따라서는 그 양적변수를 적절히 재부호화하여 범주로 만든 뒤, 오자이브를 그릴 수도 있다.