사회통계연습

χ^2 분포, F 분포 그리고 일원분산분석

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

October 14, 2022

진행 순서

1. 지난 주 리뷰
2. χ^2 분포와 F 분포
3. 일원분산분석의 논리

지난 주 리뷰

지난 주 리뷰

1. 정부의 최근 발표에 따르면 네오청주의 대학생은 평균적으로 28,650 천원의 학자금 대출 부채를 가지고 졸업한다. 그 표준편차는 7,000 천원인데, 최근 자산소득 양극화로 인해 정규분포하지 않는다. 세휘는 기말과제를 수행하기 위해 네오청주에서 임의의 대학생 30명에게 학자금 대출액을 조사하였다. 세휘의 표본에서 계산한 부채의 평균이 27,000 천원보다 클 확률은 얼마인가? (10점)

지난 주 리뷰

- 학자금 대출액의 모집단은 정규분포하지 않지만 세휘의 표집분포는 $n \geq 30$을 충족하므로 중심극한명제에 따라 정규분포인 Z 분포를 사용한다.
- 문제에서 주어진 정보를 그대로 이용하면 세휘의 표본에서 부채의 평균이 27,000 천원보다 클 확률은 다음과 같다.

$$
\begin{aligned}
P(\bar{X}) > 27000 &= P\left(Z > \frac{27000 - \mu_X}{\sigma_X}\right) \\
&= P\left(Z > \frac{27000 - 28650}{7000/\sqrt{30}}\right) \\
&= P\left(Z > -1.29\right) = 1 - P\left(Z < -1.29\right) = 0.90
\end{aligned}
$$

- 엑셀에서 1-NORM.DIST(-1.29, 0, 1, TRUE)를 사용하여 확률을 계산한다.
- 세휘의 표본평균이 27,000 천원보다 클 확률은 약 90%이다.

지난 주 리뷰

2. 전체 대학생 중 임의로 2500명을 추출하여 일주일 간 공부 시간을 조사했더니 평균은 3.2시간, 표준편차는 1.2시간이였다. 전체 대학생의 평균 복습시간을 95% 신뢰구간을 추정하시오. (10점)

지난 주 리뷰

- 문제는 $P(? \leq \mu \leq ?) = 0.95$를 묻고 있다(Why?).
- 문제에 주어진 정보에 따르면 $\mu = ?$, $\sigma = ?$, $\bar{x} = 3.2$, $s = 1.2$, $n = 2500$이다.
- $n \geq 30$이므로 중심극한명제에 따라 표집분포는 정규분포함을 알 수 있다.
- 이 표집분포에서 주어진 한 번의 표본평균 $\bar{x} = 3.2$가 현실적으로 모평균 μ에 대한 최선의 추정량이다. 그러므로 $\bar{x} = \mu = 3.2$로 놓는다.
- 주어진 일회성 표본의 표준편차 s가 1.2이고 표본크기는 $n = 2500$이므로 표준오차 $\sigma_{\bar{x}}$ 는 $1.2/\sqrt{2500}$이다.

지난 주 리뷰

- 정확한 95% 면적을 결정하는 Z 점수는 엑셀의 NORM.INV(0.025,0,1)=-1.96와 NORM.INV(0.975,0,1)=1.96로 알 수 있다.
- 그런데 구한 값은 Z 점수이기 때문에 원점수로 환원한다.

$$P(\bar{x} + Z_{0.025} \times \sigma_{\bar{x}} \leq \mu\bar{x} + \leq Z_{0.975} \times \sigma_{\bar{x}}) =$$
$$P(3.2 + -1.96 * \frac{1.2}{\sqrt{2500}} \leq \mu \leq 3.2 + 1.96 * \frac{1.2}{\sqrt{2500}}) =$$
$$P(3.15 \leq \mu \leq 3.25) = 0.95$$

- 결론적으로 $[3.15, 3.25]$ 구간이 모평균, 즉 전체 대학생의 평균 복습시간을 포함한다고 95% 확신할 수 있다.

지난 주 리뷰

3. 전체 회사원 중 임의로 600명을 추출하여 하루 수면 시간을 조사했더니 평균은 6.1시간, 표준편차는 0.8시간이였다. 전체 회사원의 평균 수면시간의 99% 신뢰구간을 추정하시오. (10점)

지난 주 리뷰

- 문제는 $P(? \leq \mu \leq ?) = 0.99$를 묻고 있다.
- 문제에 주어진 정보에 따르면 $\mu = ?$, $\sigma = ?$, $\bar{x} = 6.1$, $s = 0.8$, $n = 600$이다.
- $n \geq 30$이므로 중심극한명제에 따라 표집분포는 정규분포함을 알 수 있다.
- 이 표집분포에서 주어진 한 번의 표본평균 $\bar{x} = 6.1$가 현실적으로 모평균 μ에 대한 최선의 추정량이다. 그러므로 $\bar{x} = \mu = 6.1$로 놓는다.
- 주어진 일회성 표본의 표준편차 s가 0.8이고 표본크기는 $n = 2500$이므로 표준오차 $\sigma_{\bar{x}}$ 는 $0.8/\sqrt{600}$이다.

지난 주 리뷰

- 정확한 99% 면적을 결정하는 Z 점수는 엑셀의 NORM.INV(0.005,0,1)=-2.58와 NORM.INV(0.995,0,1)=2.58로 알 수 있다.
- 그런데 구한 값은 Z 점수이기 때문에 원점수로 환원한다.

$$P(\bar{x} + Z_{0.005} \times \sigma_{\bar{x}} \leq \mu\bar{x} + \leq Z_{0.995} \times \sigma_{\bar{x}}) =$$
$$P(6.1 - 2.58 \times \frac{0.8}{\sqrt{600}} \leq \mu \leq 6.1 + 2.58 \times \frac{0.8}{\sqrt{600}}) =$$
$$P(6.02 \leq \mu \leq 6.18) = 0.99$$

- 결론적으로 $[6.02, 6.18]$ 구간이 모평균, 즉 전체 직장인의 평균 수면시간을 포함한다고 99% 확신할 수 있다.

지난 주 리뷰

4. METHODS.SAV 자료를 사용하여 훈련방식(METHOD)에 따라 성과(PERFORMANCE)가 정말로 다르다고 할 수 있는지 가설을 세우고 95% 신뢰수준에서 통계적으로 검정하시오. (20점)

지난 주 리뷰

- 가설구조는 다음과 같다.

$$H_0 : \mu_1 - \mu_2 = 0$$
$$H_a : \mu_1 - \mu_2 \neq 0$$

- 자료를 잘 들여다보면 비열한 음모가 숨겨져 있다! PERFORMANCE 변수에 결측값이 99로 되어 있었기 때문에 이를 결측치로 제거해야 한다.
- 자료의 형태를 봤을 때 독립표본이므로 독립표본 t 검정을 95% 신뢰수준에서 시행한다.
- 자료를 재배열(reshape)하여 쌍체표본으로 바꿀수도 있지만 나라면 그렇게는 하지 않을 것 같다(Why?).

지난 주 리뷰

method	사례수	평균	표준편차	격차	t값
1번 프로그램	22	16.41	8.506	-12.82	-5.647*
2번 프로그램	35	29.23	8.243		

- 먼저 Levene의 등분산 검정 결과 유의확률(p-value)이 약 0.673로 0.05보다 크므로 "두 집단은 등분산이다"라는 귀무가설을 기각하지 못한다. 그러므로 등분산을 가정한 결과로 검정한다.
- 두 훈련방식의 평균 차이를 t-검정하면 t=-5.647이고 유의확률은 0.000으로 0.5 보다 작게 나타나므로 훈련방식에 따른 성과가 없다는 귀무가설을 95% 신뢰수준에서 통계적으로 유의하게 기각할 수 있다.
- 결론적으로 훈련방식에 따른 성과의 차이가 있다!

지난 주 리뷰

5. EFFECTS.SAV 자료를 사용하여 K-다이어트를 수행하였을 때 예전 몸무게(BEFORE)와 이후 몸무게(AFTER)에 차이가 나타났다고 할 수 있는지 가설을 세우고 95% 신뢰수준에서 통계적으로 검정하시오. (20점)

지난 주 리뷰

- 가설구조는 다음과 같다.

$$H_0 : \mu_{전} - \mu_{후} = 0$$
$$H_a : \mu_{전} - \mu_{후} \neq 0$$

- 자료를 잘 들여다보면 비열한 음모가 또 숨겨져 있다! AFTER 변수에 결측값이 999로 되어 있었기 때문에 이를 결측치로 제거해야 한다(안하면 감점).
- 자료의 형태를 봤을 때 쌍체표본이므로 쌍체표본 t 검정을 95% 신뢰수준에서 시행한다.

지난 주 리뷰

		평균	표본	표준편차	격차	t값
대응 1	before	65.620	249	8.7847	7.68	9.26***
	after	57.940	249	10.4574		
주: †p<.1, *p<.05, **p<.01, ***p<.001						

- 먼저 Levene의 등분산 검정 결과 F 값이 0.001, 유의확률(p-value)이 약 0.978로 0.05보다 크므로 "두 집단은 등분산이다"라는 귀무가설을 기각하지 못한다. 그러므로 등분산을 가정한 결과로 검정한다.
- 두 훈련방식의 평균 차이를 t-검정하면 유의확률은 0.036으로 0.5보다 작게 나타나므로 훈련방식에 따른 성과가 없다는 귀무가설을 95% 신뢰수준에서 통계적으로 유의하게 기각할 수 있다.
- 결론적으로 훈련방식에 따른 성과의 차이가 있다!

지난 주 리뷰

6. MEDCOND.SAV 자료를 SPSS에서 불러들여 각종 제한사항의 비율을 성별에 따라 비교하는 표를 작성하고 유의성 검정 결과를 보고하시오. 이때 표에는 (노령을 제외한) 모든 제한사항의 총합계 역시 성별로 비교하는 내용을 추가하시오. (30점)

지난 주 리뷰

- 가설구조는 다음과 같다(바뀌면 안된다).

$$H_0 : \mu_{여} - \mu_{남} = 0$$
$$H_a : \mu_{여} - \mu_{남} \neq 0$$

- 귀무가설은 "성별에 따른 각 제한사항의 비율이 차이가 없다"이고, 대립가설은 "성별에 따른 각 제한사항의 비율이 차이가 있다"가 된다.
- 너무 당연하게도 결측치는 숨겨져 있으므로 알아서 제거해야 한다.
- 자료의 형태를 봤을 때 독립표본이므로 각각의 변수에 대해 독립표본 t 검정을 수행한다.
- 총합계를 합성지수(composite index)로 사용하며 지시대로 노령은 제외한다.
- Levene의 등분산 검정 결과에 따라 유의확률이 0.05보다 크면 등분산을 가정한 결과를, 유의확률이 0.05보다 작으면 등분산을 가정하지 않은 결과를 사용한다!

지난 주 리뷰

변수	여성			남성			격차	t값
	표본	평균/비율	표준편차	표본	평균/비율	표준편차		
골절, 관절부상	829	0.08	0.27	769	0.08	0.27	0.00	0.01
관절염, 류머티즘	828	0.16	0.37	769	0.08	0.27	0.08	5.09***
심장질환	828	0.05	0.21	769	0.03	0.17	0.02	1.64
호흡문제, 폐질환, 천식	828	0.04	0.21	768	0.05	0.21	-0.00	-0.09
뇌졸중	828	0.01	0.11	768	0.01	0.11	-0.00	-0.17
당뇨병	828	0.05	0.22	769	0.04	0.20	0.01	1.00
고혈압	828	0.10	0.30	769	0.10	0.30	0.00	0.17
등, 목의 문제	827	0.17	0.38	769	0.11	0.31	0.06	3.74***
암	828	0.01	0.12	769	0.01	0.10	0.01	1.00
치아 및 구강질환	829	0.18	0.39	768	0.21	0.41	-0.02	-1.13
시력문제	828	0.22	0.42	768	0.22	0.42	0.00	0.09
청각문제	828	0.04	0.21	768	0.07	0.25	-0.02	-2.09*
치매	827	0.01	0.08	768	0.00	0.05	0.00	1.05
우울/불안/정서상 문제	829	0.09	0.29	768	0.04	0.18	0.06	4.78***
정신지체	828	0.00	0.05	768	0.01	0.07	-0.00	-0.91
비만	828	0.10	0.30	768	0.08	0.27	0.02	1.36
기타	827	0.05	0.22	768	0.03	0.17	0.02	1.98*
총합계	825	1.38	1.94	766	1.16	1.66	0.22	2.43*

주: †p<.1, *p<.05, **p<.01, ***p<.001

지난 주 리뷰

총평

- 공식만 달랑 써놓기 보다는 “신뢰구간은 ?와 ?사이이다”로 표현하면 좋다(감점 없음).
- 등분산 가정에 유의할 것. Levene의 등분산 검정 결과를 보고 귀무가설이 기각되면 아래를, 기각되지 않으면 위를 봐야 한다.
- 모든 문제에서 결측치 제거를 주의해야 한다(극소수만이 제외했다).
- 6번 문제에서는 여러 제한사항을 각각으로도 나타내야 한다. 종합 점수만 보고해선 안된다(점수 차감). 가설은 꼭 세워야하며 대체 어떤 귀무가설을 기각할 것인지 말 것인지를 분명히 해야 한다.

χ^2 분포와 F 분포

χ^2 분포와 F 분포

모집단의 분산에 관해서 두 가지로 가설검정을 할 수 있다.

- 만약 모집단이 "하나" 있다고 하자. 이것의 표본분산/모분산 비율의 표집분포가 χ^2 분포를 따른다고 할 때, (나의 표본에 따라) 귀무가설을 기각할 수 있는가 살펴볼 수 있다. 이것이 단일표본 χ^2 검정(one-sample chi-square test)이다.
- 만약 모집단이 "두 개" 주어졌다고 하자. 두 모집단 분산의 비율(ratio)의 (가상적인) 표집분포가 F 분포(F distribution)를 따른다고 할 때, (나의 표본에 따라) 귀무가설을 기각할 수 있는가 살펴볼 수 있다. 이것을 F 검정(F test)이라고 부른다.
- 말하자면 분산비교(variance comparison)도 평균비교(mean comparison)처럼 수행할 수 있는 셈이다.

χ^2 분포와 F 분포

하나의 모분산 σ^2에 관한 가설검정도 나름 쓸모있다.

1. 소득의 분산은 소득 불균등을 의미한다(사실 사회계층 및 불평등 연구에서는 좀 더 정교한 소득 불균등 지표가 사용되기는 한다).
2. 한 반에서 학생 성적의 분산은 교육 성과가 고르게 나타나지 않아 교육 양극화가 나타남을 시사한다.
3. 설문조사의 특정 문항에 대한 응답의 분산은 조사대상자 의견의 불일치 내지 다양성을 의미한다.
4. 금융상품의 수익률의 분산은 해당 상품의 스프레드(spread) 또는 리스크(risk)를 의미한다. 똑같은 논리가 도박에 대해서도 적용된다.
5. 제조된 공산품의 상태지표의 분산은 들쭉날쭉한 품질(quality) 상태를 의미한다.

χ^2 분포와 F 분포

일단 하나의 표본분산 s^2에 대한 표집분포를 상상해보자.

- 우리는 모집단에서 표본을 무한히 계속 뽑고 그것들의 분산 s^2를 구해 분산의 표집분포(sampling distribution of the variance)를 상상할 수 있다.
- 이때 표본 크기 n이 작다면 분산의 표집분포는 오른쪽 꼬리가 길어질 것이다(long tail).
- 그 이유는 생각보다 단순한데 분산의 계산 과정에서 제곱을 하다보면 큰 값이 우연히 많이 나오기 때문이다.

χ^2 분포와 F 분포

그러나 아쉽게도 표본분산 s^2에 관한 직접적인 이론 분포는 없다.

- 평균 $\bar{X}$의 경우 소표본일 때 t 분포, 대표본일 때 Z 분포라는 이론적 확률분포 (theoretical probability distribution)를 가졌다.
- 반면 분산 s^2의 경우 직접적인 이론적 확률분포가 없고, "표본분산 s^2와 모분산 σ^2 간의 비율"에 관한 이론적 확률분포인 χ^2 분포(chi-square distribution)를 대신 사용한다.

$$\chi^2_{n-1} = \frac{(n-1)s^2}{\sigma^2}$$

χ^2 분포와 F 분포

- χ^2 분포는 자유도 $n-1$에 의해 모양이 결정된다.
- χ^2 분포는 소표본일 때 비대칭적이고 오른쪽으로 꼬리가 길다(Why?). 여기서 증명하지는 않지만 사실 다음이 성립한다. 이렇게 제곱을 하다보면 우연히 큰 값이 나타나기 쉽고 표본이 작다보면 그 값이 튀어보인다.

$$\chi_k^2 = Z_1^2 + Z_2^2 + \ldots + Z_k^2 = \sum \left(\frac{x-\mu}{\sigma}\right)^2$$

- χ^2 값은 결국 분산들의 비율이므로 항상 양수값을 갖는다.

$$\frac{s^2}{\sigma^2} \geq 0$$

- 그러나 대표본이 될수록 정규분포의 모습에 점점 근사한다(Why?).

χ^2 분포와 F 분포

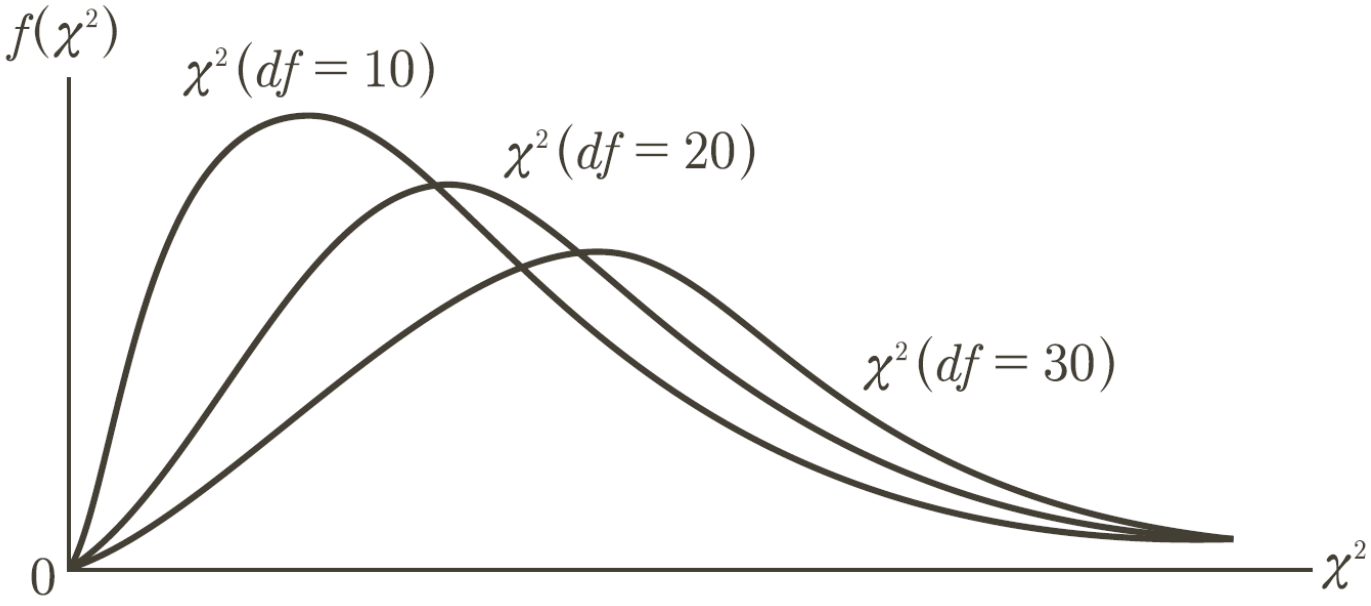

χ^2 분포와 F 분포

현실에서는 분산비교가 더 중요하고 이는 F 분포에 따라 수행된다.

- "단일모집단의 분산"에 관한 가설 검정이 χ^2 분포를 이용하는 반면, "두 모집단의 분산의 비율"에 관한 가설 검정은 F 분포를 이용한다(교과서 190).
- F 분포의 확률밀도함수(probability density function; PDF)는 다음과 같이 정의된다.

$$F_{(n_1-1,n_2-1)} = \frac{\chi_1^2/(n_1-1)}{\chi_2^2/(n_2-1)}$$

- 조금만 생각해보면 F 분포는 각각의 "단일모집단의 분산"을 설명하는 χ^2 의 비율임을 쉽게 파악할 수 있다(Why?).

χ^2 분포와 F 분포

- 우리는 두 표본의 분산의 차(difference)를 구하려는 것이 아니라 비(ratio)를 구하려는 것이므로 두 χ^2 값이 서로 비슷할수록 F 값은 (0이 아니라) 1에 접근하리라 예상할 수 있다.
- F 값은 두 개의 χ^2 분포의 비로 구성되므로 항상 양수(+)이다.
- F 분포는 두 개의 자유도 $n_1 - 1$와 $n_2 - 1$를 패러미터(parameter)로 받아 그 형태가 결정된다. 이것도 χ^2가 하나의 자유도 $n - 1$를 파라미터로 받아 그 형태가 결정되는 것과 유사하다.
- 두 개의 자유도가 작을 때는 우측 꼬리가 길다. 두 개의 자유도가 점점 커지면 정규분포에 점점 근사한다.
- χ^2 분포와 마찬가지로 대칭적인 형태가 아니다.
- 일단 χ^2 분포 자체에 익숙해져야 F 분포에 대해서도 쉽게 이해할 수 있다.

χ^2 분포와 F 분포

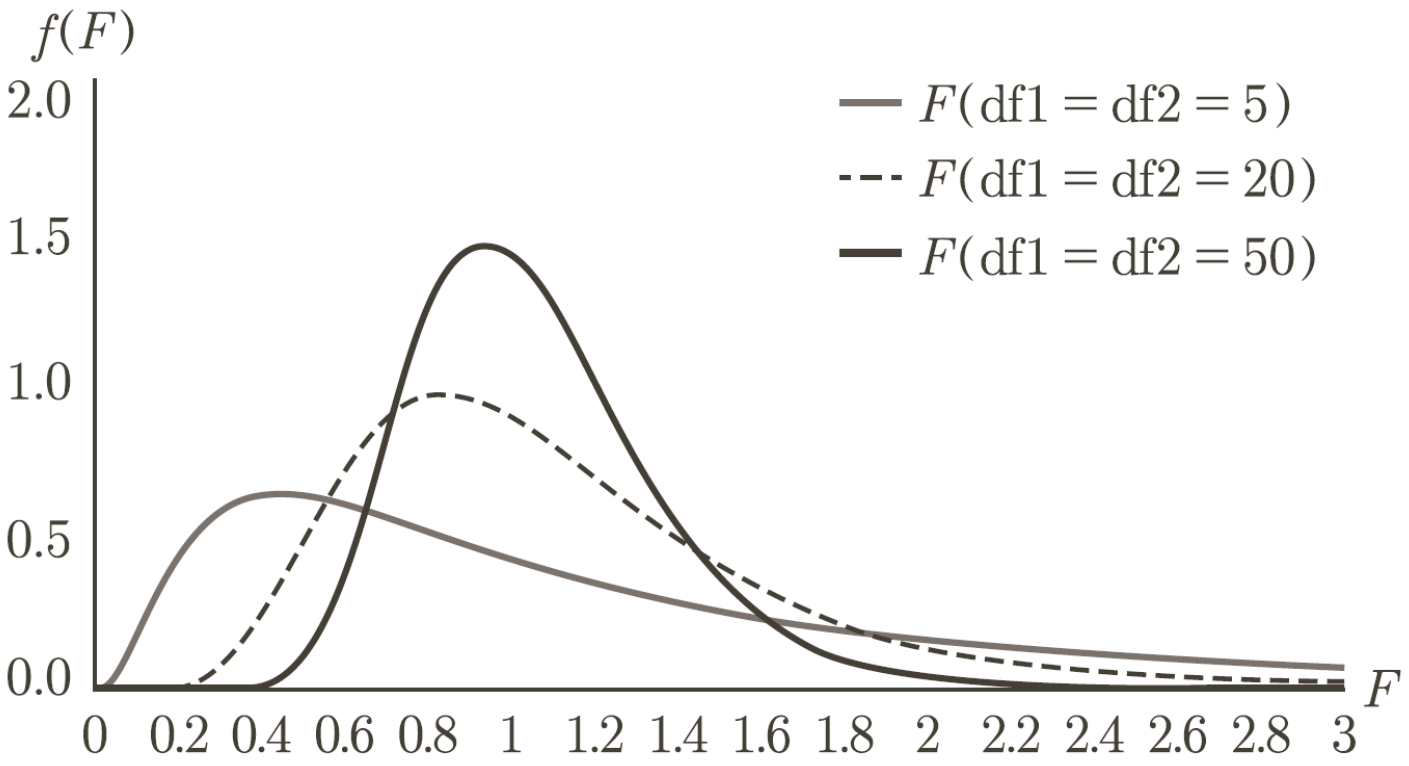
$f(F)$
2.0
1.5
1.0
0.5
0.0
0 0.2 0.4 0.6 0.8 1 1.2 1.4 1.6 1.8 2 2.2 2.4 2.6 2.8 3
F
$F(\mathrm{df1} = \mathrm{df2} = 5)$
$F(\mathrm{df1} = \mathrm{df2} = 20)$
$F(\mathrm{df1} = \mathrm{df2} = 50)$

χ^2 분포와 F 분포

검정통계량 F 값을 계산할 때 몇 가지 주의할 점이 있다.

- 검정통계량 F 값은 비율이기 때문에 어느 쪽이 분자가 되는지 주의해야 한다.
- 많은 교과서에서 분산이 큰 쪽을 반드시 분자로 놓도록 가르친다. 그러면 F 값은 반드시 1 또는 그보다 커지므로 양측검정은 사라지고 오로지 단측검정만 생각하면 된다(Why?).
- 우리도 이 설명 방식을 따른다.
- 분자분모 설정에 따라 분산비교를 위한 F 검정의 가설구조는 오로지 우측 단측검정만을 따르게 된다.

$$H_0 : \frac{\sigma_1^2}{\sigma_2^2} \leq 1$$

$$H_a : \frac{\sigma_1^2}{\sigma_2^2} > 1$$

일원분산분석의 논리

일원분산분석의 논리

분산분석으로 표본(=변수)의 분산에 관한 가설검정을 수행한다.

- Fisher는 F 분포를 만들고 그것을 절묘하게 활용하는 분산분석(Analysis of Variance; ANOVA)도 개발했다.
- Fisher는 젊은 시절에 대학 대신 농업연구소 Rothamsted에서 일하면서 체계적인 실험설계(experimental design)의 근본 원리로 이른바 피셔의 3원칙(Fisher's Three Principles)인 반복(replication), 무작위화(randomization), 국소화(blocking)를 제시한다.
- 이 원칙들이 오늘날에는 당연하게 여겨지지만 당시에는 상당한 반감을 샀다.

일원분산분석의 논리

- 일원분산분석(one-way ANOVA)은 분산분석에 속한 여러 기법들의 가장 기초가 된다.
- 분산분석의 기본적인 개념을 학습하는데 유용할 뿐 아니라, 실제로도 여러가지 맥락에서 자주 사용된다.
- 사실 심리학을 제외한 다른 사회과학 분야에서는 실험자료(experimental data) 대신 관찰자료(observational data)가 더 폭넓게 사용된다. 다시 말해, 분산분석이 폭넓게 사용되기 어렵다.
- 그러므로 우리는 오로지 (분산분석의 기초인) 일원분산분석만 배운다.

일원분산분석의 논리

일원분산분석의 데이터 구조가 어떻게 생겼는지 기억하자.

- 완전무작위설계(completely randomized design)에 따라 27개의 개체(subjects)에 대해 3가지의 서로 다른 실험처리(treatment)를 "같은 수 만큼 반복"한다고 하자.

Treatment 1	Treatment 2	Treatment 3	
y_{11}	y_{12}	y_{13}	
y_{21}	y_{22}	y_{23}	
$\vdots$	$\vdots$	$\vdots$	
y_{91}	y_{92}	y_{93}	
$\bar{y}_{\cdot 1}$	$\bar{y}_{\cdot 2}$	$\bar{y}_{\cdot 3}$	$\bar{y}_{\cdot\cdot}$

- 실험처리별 그룹이 3개라는 점, 각 그룹별로 9개(=27/3) 씩 표본이 들어있다는 점, 그리고 $\bar{y}_{\cdot j}$ 와 $\bar{y}_{\cdot\cdot}$ 같은 평균값에 주목하자.
- 이 표는 사실 표본의 자료구조를 나타낸 것이므로 표본의 $\bar{y}_{\cdot j}$는 모집단의 μ_j에 대응하고 표본의 $\bar{y}_{\cdot\cdot}$는 모집단의 μ에 대응한다.

일원분산분석의 논리

분산분석의 기초적인 용어에 먼저 친숙해질 필요가 있다.

- 분산분석의 맥락에서 독립변수는 요인(factor)이라고 불리운다. 이때, 요인은 실험처리 그룹의 식별자(identifiers)가 되므로 종종 그룹화 요인(grouping factor)이라고도 불리운다. 물론 반드시 범주형 변수(주로 명목척도)이다(Why?).
- 종속변수는 결과(outcome) 또는 반응 변수(response variable)이라고 불리운다. 이것은 반드시 양적변수가 된다.
- 일원분산분석의 경우 분석에 사용되는 요인과 반응변수는 각각 하나씩이다.

일원분산분석의 논리

분산분석은 2개 이상의 모평균에 관한 가설검정에 사용된다.

- t 검정을 통해 두 모평균의 차이 $\mu_1 - \mu_2$에 관한 가설검정을 수행할 수 있었다.
- 분산분석을 통해서는 둘 이상의 모평균이 같은가 $\mu_1 = \mu_2 = \ldots = \mu_j$에 관한 가설검정도 수행할 수 있다.
- 분산분석은 t 검정보다 훨씬 일반화된 분석기법인 셈이다.
- 그러나 연구나 실무에서는 범주형 독립변수에서 주어진 범주의 수가 2개 일 때 (예컨대 성별, 성인 여부, 대졸 여부 등)는 주로 t 검정을, 주어진 범주의 수가 3개 이상일 때(예컨대 최종학력별, 지역별, 고용조건별 등)는 주로 분산분석을 사용한다.

일원분산분석의 논리

일원분산분석은 매우 단순한 논리 구조를 가지고 있다.

- 일원분산분석의 모집단에 관한 수리모형은 다음과 같다.

$$Y_{ij} = \mu_j + e_{ij}$$

- 이때 e_{ij}는 오차항(error term)이다. 오차는 무작위적(random)이라고 가정된다.
- 처리효과(treatment effect)는 $\alpha_j = \mu_j - \mu$이므로(Why?),

$$Y_{ij} = \mu + \alpha_j + e_{ij}$$

- 다시 말해, (종속변수가 되는) 모집단 개체의 관찰값 Y_{ij}은 전체 평균 μ와 처리효과 α_j, 그리고 오차항 e_{ij}으로 분해된다.

일원분산분석의 논리

수학적으로 일반화되어 어려워 보이니 쉬운 예제를 통해 살펴보자.

- 다음과 같은 (극단적으로 단순한) 모집단이 있다고 상정하자.

처리집단1	처리집단2	처리집단3	
$Y_{11} = 2$	$Y_{12} = 3$	$Y_{13} = 3$	
$Y_{21} = 2$	$Y_{22} = 2$	$Y_{23} = 2$	
$Y_{31} = 5$	$Y_{32} = 1$	$Y_{33} = 7$	
$\mu_1 = 3$	$\mu_2 = 2$	$\mu_3 = 4$	$\mu = 3$

- 가령 첫번째 열(column) Y_{11}, Y_{21}, Y_{31}은 처리집단1의 평균 μ_1과 (약간의) 오차항 e_{i1}의 합으로 설명된다. 즉, $Y_{i1} = \mu_1 + e_{i1}$이다.
- 처리집단1의 평균 μ_1이 곧바로 처리효과가 되는 것은 아니다. 처리효과는 처리집단1의 평균 μ_1과 총평균 μ의 차이로 나타난다(Why?). 즉, $\alpha_1 = \mu_1 - \mu$이다.
- 그러므로 $Y_{i1} = \mu_1 + e_{i1} = \mu + \alpha_1 + e_{i1}$이다.

일원분산분석의 논리

- 우리가 보고 있는 결과인 Y_{ij}은 사실 그룹 간(between) 처리효과 α_j의 산물일 뿐만 아니라, (처리와는 별개로 우리 모두가 나름대로 가진) 일종의 출발선(baseline)이라고 할 수 있는 총평균 μ과 그룹 내(within) 개별적인 오차 e_{ij}로부터도 영향을 받아 나타난 것이다!

$$y_{ij} = \mu + \alpha_j + e_{ij}$$

- 이제 위 식을 살짝 변경하면 일원분산분석의 핵심을 모두 파악할 수 있다.

$$\begin{aligned} Y_{ij} - \mu &= \alpha_j + e_{ij} \\ &= (\mu_j - \mu) + (Y_{ij} - \mu_j) \end{aligned}$$

- 위 식에 제곱합(sum of squares; SS)을 해도 아래와 같이 성립한다는 것은 수학적으로 증명할 수 있다(우리는 하지 않지만!).

$$\begin{aligned} \sum (Y_{ij} - \mu)^2 &= \sum (\mu_j - \mu)^2 + \sum (Y_{ij} - \mu_j)^2 \\ SS_{total} &= SS_{between} \quad + SS_{within} \end{aligned}$$

일원분산분석의 논리

- 제곱합 SS는 적절한 자유도인 $n-1$와 $k-1$ 그리고 $n-k$로 나누어 평균제곱 (mean squares; MS)이라고 부른다.

$$\frac{\sum(Y_{ij}-\mu)^2}{(n-1)} = \frac{\sum(\mu_j-\mu)^2}{(k-1)} + \frac{\sum(Y_{ij}-\mu_j)^2}{(n-k)}$$

$$MS_{total} = MS_{between} \quad + MS_{within}$$

- 그런데 이것은 각각 "분산의 불편추정량"이 된다(Why?).

$$Variance_{total} = Variance_{between} + Variance_{within}$$

- 각각의 자유도 계산원리도 무척 단순하다(Why?). 여기서 k은 그룹의 숫자이다.

$$(n-1) = (k-1) + (n-k)$$

일원분산분석의 논리

일원분산분석의 검정통계량은 F 값이다.

- 일원분산분석은 F 분포를 사용하며, 그 근본 원리는 (앞서 설명한) 두 모집단 분산 비율에 대한 가설검정과 같다.

$$
\begin{aligned}
F_{(k-1,n-k)} &= \frac{Variance_{between}}{Variance_{within}} \\
&= \frac{SS_{between}/(k-1)}{SS_{within}/(n-k)} \\
&= \frac{MS_{between}}{MS_{within}}
\end{aligned}
$$

- 분자는 실험처리에 의한 효과(treatment effect)로 볼 수 있고, 분모는 무작위오차(random error)로 볼 수 있다(Why?).

일원분산분석의 논리

집단 간 분산이 클수록 그리고 집단 내 분산이 작을수록 F 값은 커진다.

- 수리적으로 따지고 들어갈 필요조차 없다. 사실 F 값이 갖는 의미는 상식적으로 너무나 명확하다!
- 두 표본이 주어졌을 때, 표본 간에는 차이가 크고 표본 내에는 차이가 작다면, 두 모집단은 서로 다른 것이다.
- 두 표본이 주어졌을 때, 표본 간에는 차이가 작고 표본 내에는 차이가 크다면, 두 모집단은 서로 다르다고 할 수 없다.
- 따라서 F 값이 크다는 것은 두 모집단은 서로 다름을 시사한다.

일원분산분석의 논리

- 집단 간(between) 차이가 크고 집단 내(within) 차이가 작은 경우

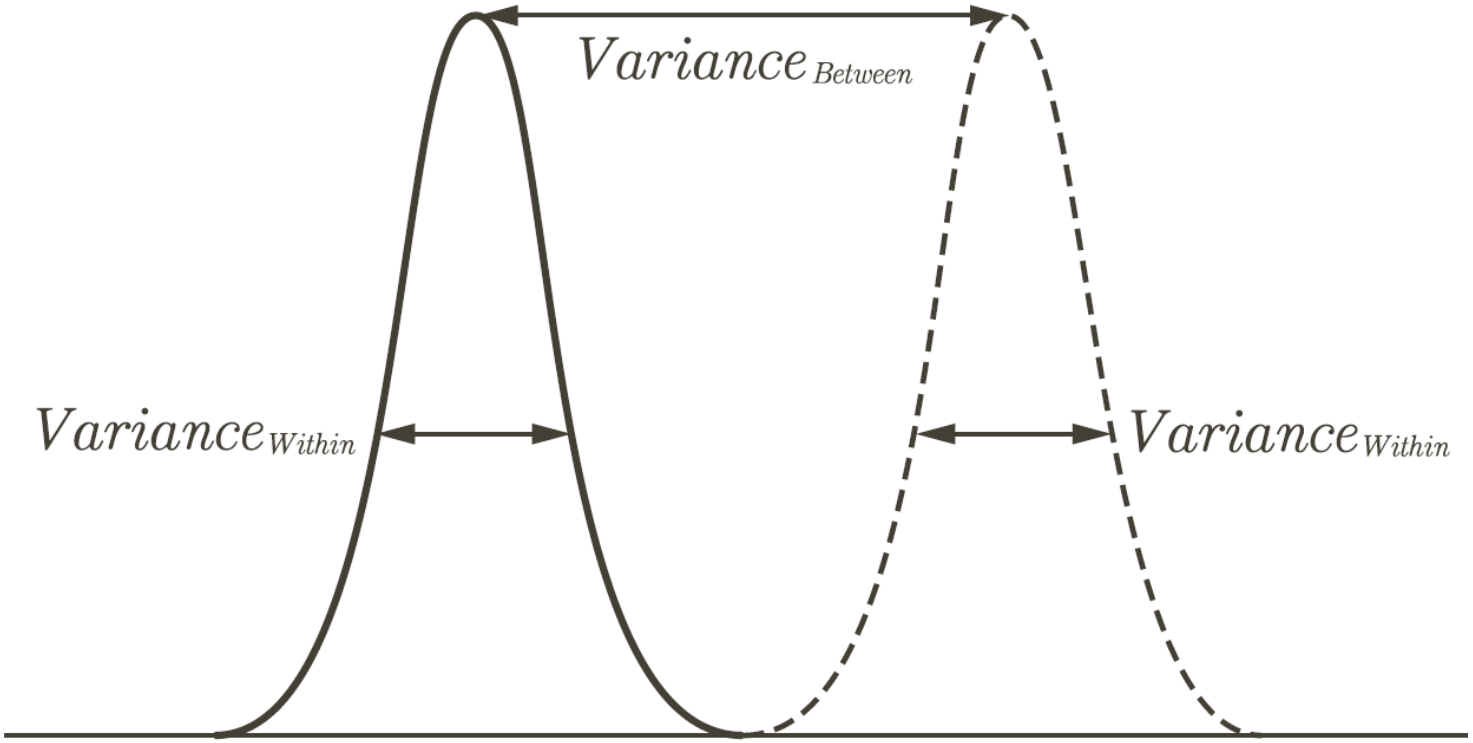

일원분산분석의 논리

- 집단 간(between) 차이가 작고 집단 내(within) 차이가 큰 경우

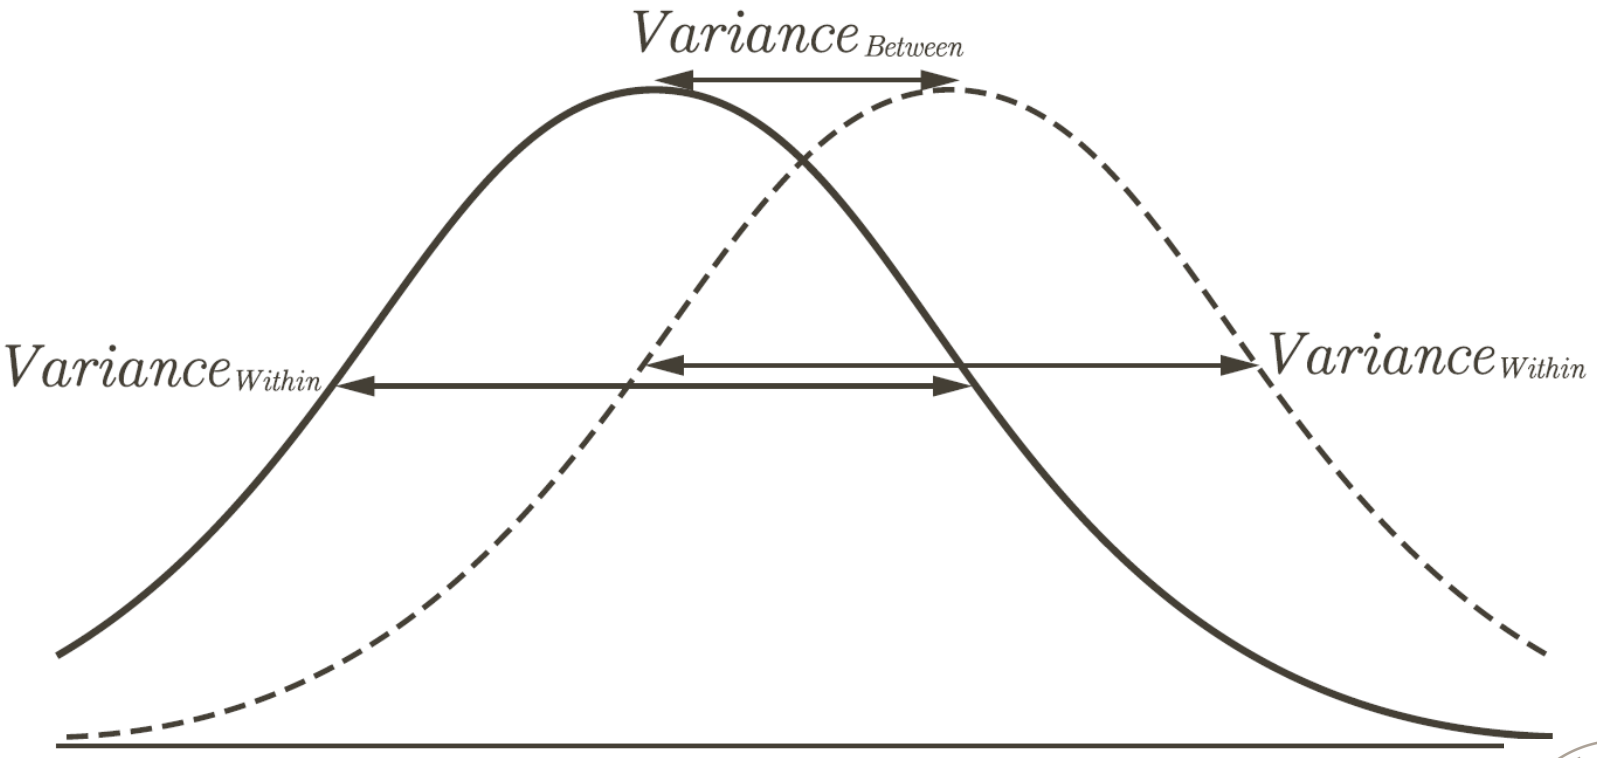

일원분산분석의 논리

- 계산을 진행하면서 분산분석표(ANOVA table) 안에 각각의 숫자를 채워넣으면 된다. 아! 물론 계산은 컴퓨터가 한다.

Variance	SS	df	MS	F
Between groups	$SS_{between}$	$(k-1)$	$MS_{between}$	F
Within groups	SS_{within}	$(n-k)$	MS_{within}	
Total	SS_{total}	$(n-1)$	MS_{total}	

- 실제 표에서는 F 옆에 유의확률(p-value)이나 임계값(critical value) 등도 추가해서 써넣는 경우도 있다.

일원분산분석의 논리

일원분산분석의 가설 설정은 다소 주의를 요한다.

- 귀무가설은 "모든 그룹에 걸쳐 평균이 같다"이다. 예를 들면 다음과 같다.

  (1) 인지된 기후변동의 심각성 점수의 평균에 최종학력별 차이는 없다.
  (2) 출신지역별로 정치적 보수주의 점수 차이가 없다.
  (2) 기업내 직급 수준에 따른 인적자원개발 프로그램 만족도 차이는 없다.

$$H_0 : \mu_1 = \mu_2 = \mu_3 = ... = \mu_k$$

- 그 대립가설은 "적어도 하나의 그룹에서 평균값이 다르다"이다.

$$H_a : (\mu_1 \neq \mu_2) \text{ or } (\mu_1 \neq \mu_3) \text{ or } ... \text{ or } (\mu_{j-1} \neq \mu_j)$$

- "모든 그룹에 있어 평균값이 다르다($H_a : \mu_1 \neq \mu_2 \neq \mu_3 = ... \neq \mu_j$)"가 아님에 주의할 것(Why?)!

일원분산분석의 논리

- 당연히 “최종학력이 높아질수록 인지된 기후변동의 심각성 점수도 함께 높아진다”와 같은 해석은 본래 일원분산분석으로 할 수 없는 과잉해석이 된다.
- 위와 같은 해석을 하기 위해서 (앞서 제시된 귀무가설을 넘어) 보다 구체적으로 두 그룹씩 짝지어 비교할 수 있다.
- 이른바 다중비교검정(multiple comparison test)은 임의로 선정된 두 그룹 중 어느 그룹에서 평균값이 더 높은가를 살펴보는 기법이다. 교과서에 따라서는 사후비교(post hoc comparison)라고 부르기도 한다. 우리는 다루지 않는다.
- 일원분산분석은 실제 분석상 분산의 비율을 비교하고 있음에도 불구하고, 가설 설정은 평균에 대해 이루어진다는 점도 주의해야 한다.

일원분산분석의 논리

- 앞서 분산분석의 논리를 설명하기 위해 동원했던 예제 자료는 사실 넓은 꼴(wide form)이다(Why?).
- 통계분석패키지를 사용하여 일원분산분석을 수행하려면 긴 꼴(long form)의 자료를 가지고 있어야 한다.
- 넓은 꼴과 긴 꼴의 자료 형태가 어떻게 다를지 상상해보아야 한다.

일원분산분석의 논리

분산분석 계열의 기법은 사실 굉장히 다양한 테크닉들을 광범위하게 포괄한다.

- 일원분산분석에서 일원(one-way)은 독립변수가 하나임을 뜻한다. 독립변수가 두 개인 경우 이원분산분석(two-way ANOVA)이 되고, 그보다 많은 경우 다원분산분석(multi-way ANOVA)이 된다.
- 그 밖에도 다변량분산분석(multivariate ANOVA 또는 MANOVA), 공분산분석(analysis of covariance 또는 ANCOVA)이나 다변량공분산분석(multivariate analysis of covariance 또는 MANCOVA) 등 다양하게 있으나 이것들은 이 수업의 수준을 한참 벗어난 것이므로 다루지 않는다.