사회통계연습
일원분산분석

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

October 14, 2022

진행 순서

1. 일원분산분석 연습

일원분산분석 연습

일원분산분석 연습

일원분산분석 절차는 굉장히 정형화되어 있다.

- 분석을 시작하기 전에 사용할 변수들이 무엇이고, 그들의 측도는 무엇인지 파악한다.
- 결측치와 극단치(outliers)의 존재를 파악하기 위해 먼저 기술통계 및 시각화를 수행하는 것이 좋다.
- SPSS에서 [분석]-[평균 비교]-[일원배치 분산분석]을 선택하여 일원분산분석을 수행한다. 이때 "기술통계"를 옵션에서 선택하는 쪽이 좋다.
- 분산분석표를 보고 해석할 수 있어야 한다. 제곱합, 자유도, 제곱 평균은 각각 어떻게 계산되었는지 이해한다.
- F 값과 유의 확률(p-value)은 어떻게 계산되었는지 이해한다.
- 분석의 결론은 무엇인지, 어떤 결론을 내려선 안되는지 판단한다.

일원분산분석 연습

연습 1. citytemp.sav 자료를 SPSS에서 불러들여 1월 평균기온(tempjan)이 센서스 지역구획(region)에 따라 다른지 여부를 검정하시오.

일원분산분석 연습

양적 연구에서 일원분산분석은 주로 두 가지 용도를 갖는다.

- 첫번째는 표본에 관한 기술통계(descriptive statistics)를 제시하는 부분이고, 두번째는 회귀분석(regression analysis)에서 모형 적합도(goodness-of-fit) 평가 부분이다(이것은 나중에 배운다).
- 기술통계 분석의 맥락에서 보면, 연구자는 자신의 표본 안의 핵심이 되는 "범주형" 변수를 요인(factor)으로 삼고 다른 여러 "연속형" 변수를 결과(outcome)로 삼아 일원분산분석을 수행할 수 있다.
- (앞서 설명하였듯) 범주형 변수는 명목 (내지 서열) 척도로 측정된 것이다. 가령 최종학력, 출신지역, 지지하는 정당, 고용상태 등을 생각해 볼 수 있다(이희정 2018).

일원분산분석 연습

연습 2. citytemp.sav 자료를 SPSS에서 불러들여 난방도일(heatdd), 냉방도일(cooldd), 1월 평균기온(tempjan), 7월 평균기온(tempjuly)이 센서스 지역구획(region)에 따라 다른지 여부를 검정하시오. 표와 시각화를 통해 그 결과를 요약하시오.

일원분산분석 연습

일원분산분석의 전형적인 표와 시각화 기법이 있다.

- 이미숙(2012)과 이희정(2018)의 논문에 실린 표를 살펴보면서 의미를 해석해보자.
- 이 표를 최대한 흉내내는 연습이 필요하다(당연히 숙제로 나간다)!
- 시각화 기법으로 무엇이 적절할까?

일원분산분석 연습

연습 3. FPOLICY.sav 자료를 SPSS에서 불러들여 정치적 이데올로기 성향에 따라 외국인 이주자 관련정책에 대한 종합적 의견에 차이가 나타나는지를 검정하시오. 그 발견을 전달하기 위해 표를 만들고 시각화를 함께 수행하시오. 그 결론을 간단히 정리하시오.

일원분산분석 연습

- 반드시 결측치 처리를 먼저 하고 방향성을 확실하게 따져가며 합성지수(composite index)를 만들어야 한다.
- 만들어진 합성지수가 어떠한지 먼저 기술통계 및 시각화를 수행하는 것이 좋다.
- 분석의 결론은 무엇인가? 어떤 결론을 내려선 안되는가?

일원분산분석 연습

연습 4. PROTEST.sav 자료를 SPSS에서 불러들여 정치적 참여의사 및 참여여부를 나타내는 합성지수를 구성하고 이것이 연도별로 어떻게 변화하였는지 살펴보고 통계적으로 이를 검정하시오. 그 발견을 전달하기 위해 표를 만들고 시각화를 함께 수행하시오.

일원분산분석의 논리

t 검정은 "두 개의 그룹"이 주어졌을 때 평균을 비교하고, 일원분산분석은 "두 개 이상의 그룹"이 주어졌을 때 분산의 비율을 비교한다.

- 그럼 만일 그룹이 두 개만 주어졌을 때 (t 검정 대신) 일원분산분석을 수행하면 어떤 결과를 가져올까?
- 본래 일원분산분석의 귀무가설은 "모든 집단에 걸쳐 평균값이 동일하다 ($H_0 : \mu_1 = \cdots = \mu_j$)"였다.
- 그룹이 두 개만 주어진 귀무가설의 경우 "두 집단에 걸쳐 평균값이 동일하다 ($H_0 : \mu_1 = \mu_2$)"로 축소된다.
- 이것은 t 검정의 귀무가설($H_0 : \mu_1 - \mu_2 = 0$)과 본질적으로 같다.
- 실제로 F 값과 t 값에는 밀접한 관계가 있다(증명 생략).

$$\sqrt{F} = |t| \quad (\text{또는 } F = t^2)$$

일원분산분석 연습

연습 5. MEMBERSHIP.sav 자료를 SPSS에서 불러들여 사회집단 소속 및 활동의 적극성이 대졸 여부에 따라 어떻게 다른지 살펴보고 통계적으로 이를 검정하시오. 어떤 분석기법이 적당한가? 다른 분석기법들이 적용가능하다면 결과는 어떻게 다른가 설명하시오.

일원분산분석의 논리

- 대졸 여부 더미변수를 만들 때 먼저 기준이 되는 변수들의 결측치 처리를 마치도록 하자.
- SPSS에서 [다른 변수로 코딩변경]을 사용하여 응답자 학력(EDUC)의 4 (전문대학)에서 7 (대학원; 박사과정)까지 1로, 나머지를 0으로, 결측치는 결측치로 처리한다.
- 이때 "조건" 기능을 사용하여 졸업 여부(GRADUATE)가 1인 경우에만 위의 코딩변경을 수행하도록 하자.
- 여전히 대학원 중퇴 등의 예외적인 경우가 있다! 이것들은 각각 응답자 학력(EDUC)이 6과 7인 경우이므로 [같은 변수로 코딩변경]에서 이를 새로운 조건으로 삼으면 된다.

일원분산분석의 논리

정반대로 2개 이상의 그룹에 대해 일원분산분석 대신 t 검정을 여러번 하면 안될까?

- 결론만 말하자면 (1) 굉장히 불편하고 혼란스러울 뿐 아니라, (2) 추정상의 오류를 저지르게 될 위험이 극단적으로 커지므로 안된다.
- 첫째, t 검정을 아주 여러 번 수행하고 비교해야 하는 부담이 있다. 예컨대 겨우 5개의 모집단을 비교하기 위해서 t 검정을 10번이나 수행해야 한다(Why?). 게다가 이 횟수는 기하급수적으로 증가한다.
- 둘째, 이 10번의 t 검정을 수행하는 과정에서 최소 1번 이상 오류가 나타날 가능성은 급격히 증가한다. (이항분포로 계산하면 알 수 있듯) 예컨대 5% 유의확률이라면 1회 이상의 오류 확률은 40%나 된다(Why?).

일원분산분석 연습

연습 6. VULNERAB.sav 자료를 SPSS에서 불러들여 한국사회가 일곱 종류의 각종 위험에 대해 얼마나 취약한지 사람들의 주관적 인식을 드러내는 합성지수를 구축하시오. 그리고 이 (인지된) 일곱 종류의 개별적인 위험 취약도와 종합적인 위험 취약도가 정치적 진보·보수 성향에 따라 다른지 여부를 적절한 표를 만들어 설명하고 통계적으로 검정하시오. 발견한 사실을 간략히 설명하시오.