사회통계연습

교차표와 χ^2 독립성 검정

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

October 21, 2022

진행 순서

1. 지난 주 리뷰
2. 교차표의 기초
3. 교차표 표준화
4. χ^2 독립성 검정

지난 주 리뷰

지난 주 리뷰

1. 수연이 운영하는 산부인과에서 2020년 측정한 신생아의 출생시 평균 체중은 2,980g이였다. 그리고 10년이 지난 2030년 수연이 다시 한 번 신생아 100명을 무작위로 추출하여 평균 체중을 조사하였다. 그 결과 몸무게는 3,040g 이었고 표준편차는 316였다. 유의수준 5%에서 지난 10년 사이 신생아의 체중이 증가했다고 할 수 있는지 검정하시오. (10점)

지난 주 리뷰

- 귀무가설은 $H_0 : \mu \leq 2980$이고 대립가설은 $H_a : \mu > 2980$이다. 이것은 단측가설이다.
- 신생아의 표본수는 100명이므로 중심극한정리에 따라 Z 검정을 수행할 수 있다.
- 주어진 조건들을 조합하면 검정통계량은 다음과 같다.

$$Z = \frac{3040 - 2980}{316/\sqrt{100}} = 1.9$$

- 이 표집분포에서 표본평균이 1.9보다 큰 값이 나올 확률은 1-NORM.DIST(1.9, 0, 1, TRUE)로 구할 수 있다.
- 답은 0.029로 유의확률 5%보다 작으므로 95% 신뢰수준에서 통계적으로 유의하게 귀무가설을 기각할 수 있다.
- 결론적으로 10년 사이에 신생아의 체중은 증가했다고 할 수 있다.

지난 주 리뷰

2. 인터넷 이용시간이 정규분포한다고 알려진 가운데, 지난해 초등학생의 인터넷 이용시간은 하루 평균 88분이였다. 올해 초등학생의 인터넷 이용시간을 조사하기 위해 10명의 임의표본을 추출하여 살펴보니 평균은 97분이고 분산은 151.29였다. 초등학생의 인터넷 이용 시간이 늘었다고 할 수 있는지 유의수준 5%로 검정하시오. (10점)

지난 주 리뷰

- 귀무가설은 $H_0 : \mu \leq 88$이고 대립가설은 $H_a : \mu > 88$이다. 이것은 단측가설이다.
- 표본 크기는 10명으로 매우 작으므로 t 분포를 사용한다.
- 주어진 조건들을 조합하면 검정통계량은 다음과 같다.

$$t = \frac{97 - 88}{12.3/\sqrt{10}} = 2.31$$

- 자유도(df)는 9이므로 이 표집분포에서 표본평균이 1.9보다 큰 값이 나올 확률은 1-T.DIST(2.31, 9, TRUE)로 구할 수 있다.
- 답은 0.023으로 유의확률 5%보다 작으므로 95% 신뢰수준에서 통계적으로 유의하게 귀무가설을 기각할 수 있다.
- 결론적으로 지난해보다 초등학생의 인터넷 이용시간은 증가했다고 할 수 있다.

지난 주 리뷰

3. 연령대(20대, 30대, 40대, 50대, 60대, 70대 이상)에 따라 NHANES.SAV 안의 자료로 주어진 모든 생물지표(biomarkers)의 차이를 비교하고 통계적으로 검정한 뒤, 이를 시각화하시오. (40점)

지난 주 리뷰

		표본수	평균	표준편차	F
성별	남자	368	350.25	218.55	75.064***
	여자	362	227.84	157.83	
연령	20대 이하	61	255.25	106.71	8.061***
	30대	123	327.87	185.28	
	40대	141	320.93	177.37	
	50대	208	318.39	193.23	
	60대	148	248.36	258.44	
	70대	36	163.31	120.31	
	80대 이상	13	104.46	87.82	
혼인상태	기혼	519	305.31	215.48	3.296**
	사별	42	193.36	184.98	
	이혼	39	246.92	105.76	
	별거	6	298.33	115.83	
	미혼	121	270.62	148.52	
	동거	3	210.00	79.37	
최종학력	무학	21	145.29	115.42	11.787***
	초등(국민)학교	61	159.74	116.56	
	중학교	69	249.90	325.94	
	고등학교	248	272.46	178.51	
	전문대학(2・3년제)	104	300.41	167.67	
	대학교(4년제)	204	361.61	177.81	
	대학원(석사과정)	19	371.05	202.29	
	대학원(박사과정)	2	575.00	106.07	
직업	관리자	24	850.42	327.54	51.863***
	전문가 및 관련 종사자	112	348.08	160.05	
	사무 종사자	145	331.86	122.52	
	서비스 종사자	90	209.90	117.24	
	판매 종사자	114	267.48	134.47	
	농림어업 숙련 종사자	66	189.24	305.99	
	기능원 및 관련 기능 종사자	43	314.88	99.70	
	장치,기계조작 및 조립종사자	43	276.16	112.97	
	단순노무 종사자	72	157.78	73.97	
지역	서울	150	351.67	222.59	4.615***
	경기	228	291.32	182.10	
	강원	22	178.36	152.14	
	충청	81	272.70	163.07	
	경상	167	274.98	161.27	
	전라	73	241.42	289.25	
	제주	9	293.33	197.80	
도시/농촌	농촌	143	227.17	249.73	17.633***
	도시	587	304.74	183.39	

주: †p<0.1, *p<0.05, **p<0.01, ***p<0.001

지난 주 리뷰

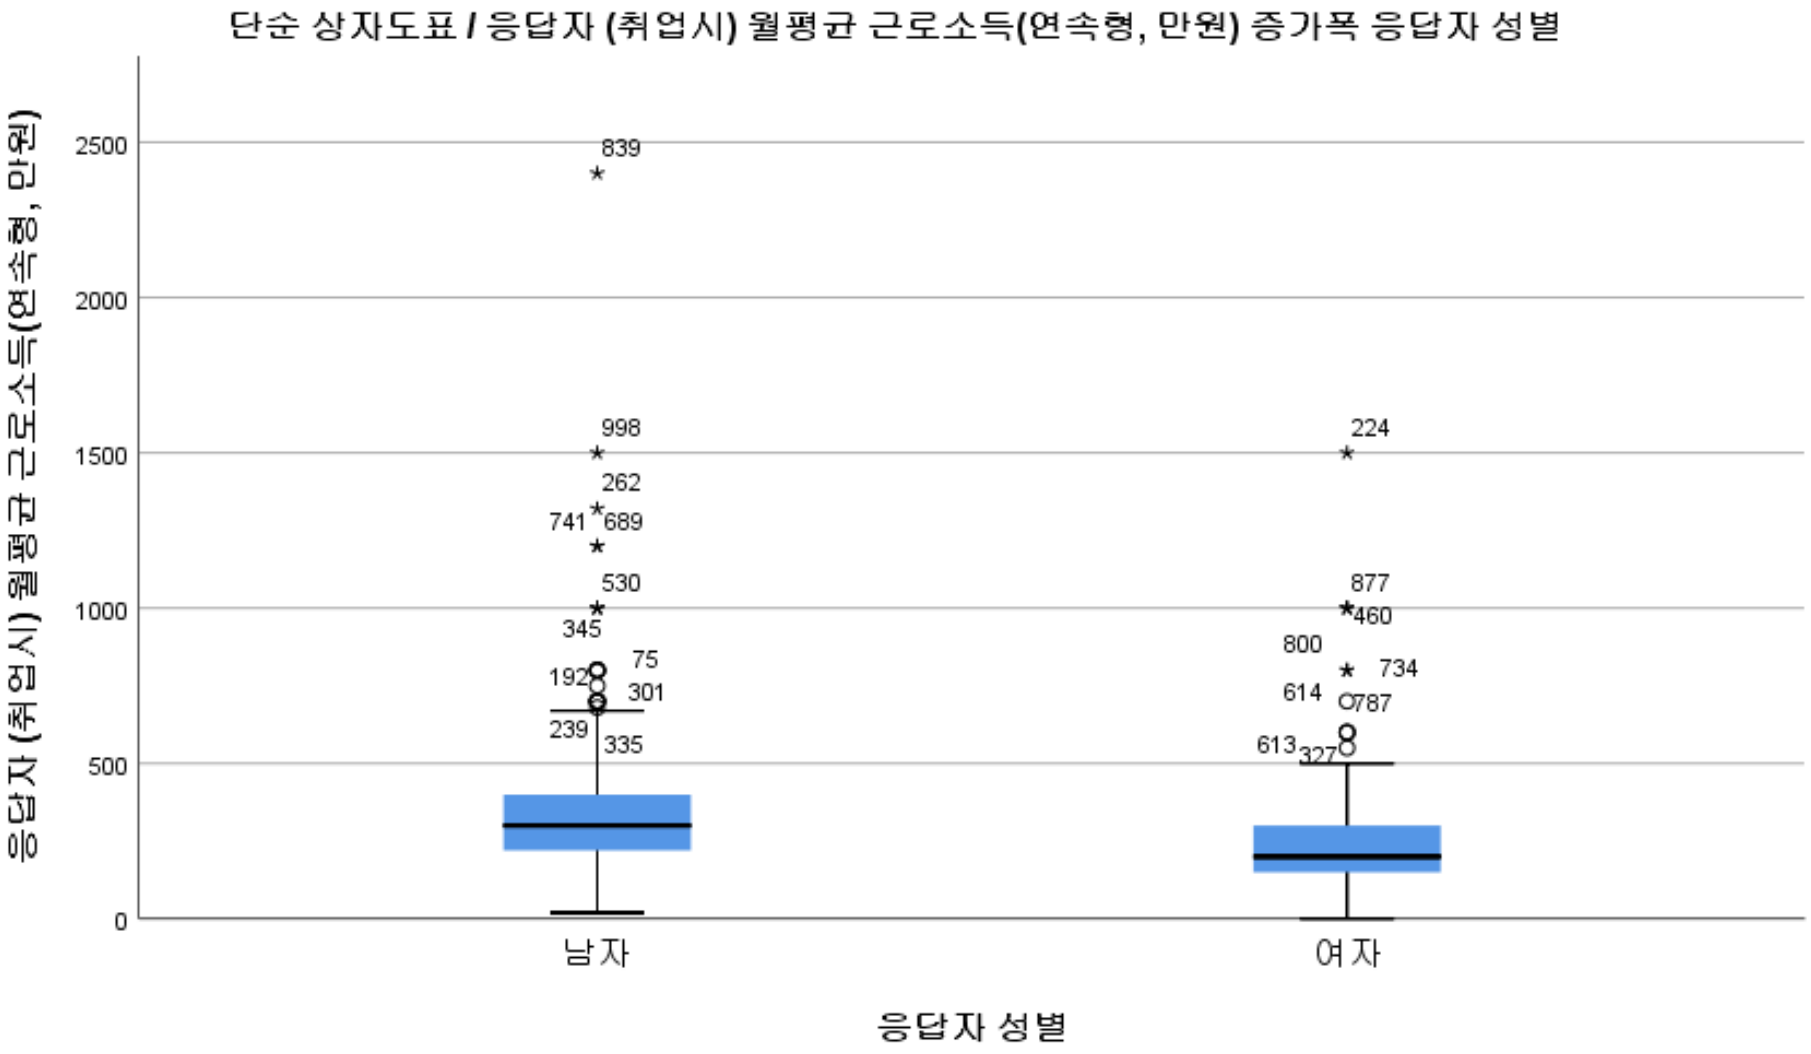
단순 상자도표 / 응답자 (취업시) 월평균 근로소득(연속형, 만원) 증가폭 응답자 성별
응답자 (취업시) 월평균 근로소득(연속형, 만원)
2500
2000
1500
1000
500
0
839
998
262
741
689
530
345
75
192
301
239
335
224
877
460
800
734
614
787
613
327
남자
여자
응답자 성별

지난 주 리뷰

4. 연령대(20대, 30대, 40대, 50대, 60대, 70대 이상)에 따라 NHANES.SAV 안의 자료로 주어진 모든 생물지표(biomarkers)의 차이를 비교하고 통계적으로 검정한 뒤, 이를 시각화하시오. (40점)

지난 주 리뷰

	연령대	표본수	평균	표준편차	F
systolic blood pressure	20대	2320	117.350	15.641	605.943***
	30대	1621	120.240	16.501	
	40대	1270	126.970	18.981	
	50대	1289	135.690	21.793	
	60대	2852	141.540	23.727	
	70대	985	148.200	26.134	
diastolic blood pressure	20대	2320	75.530	11.314	195.387***
	30대	1621	79.640	11.891	
	40대	1270	83.580	12.824	
	50대	1289	85.790	13.169	
	60대	2852	84.670	12.608	
	70대	985	83.430	13.064	
(중간 생략)					
erythrocyte porphyrin (mcg/dl)	20대	2302	51.290	15.408	8.818***
	30대	1608	52.050	19.040	
	40대	1258	54.090	32.875	
	50대	1280	54.700	28.583	
	60대	2832	55.280	32.333	
	70대	977	55.400	16.557	
lead (mcg/dL)	20대	1131	13.530	5.881	8.540***
	30대	750	14.180	6.217	
	40대	649	14.950	6.795	
	50대	635	15.140	6.749	
	60대	1321	14.560	6.011	
	70대	456	13.800	5.096	

주: †p<0.1, *p<0.05, **p<0.01, ***p<0.001

지난 주 리뷰

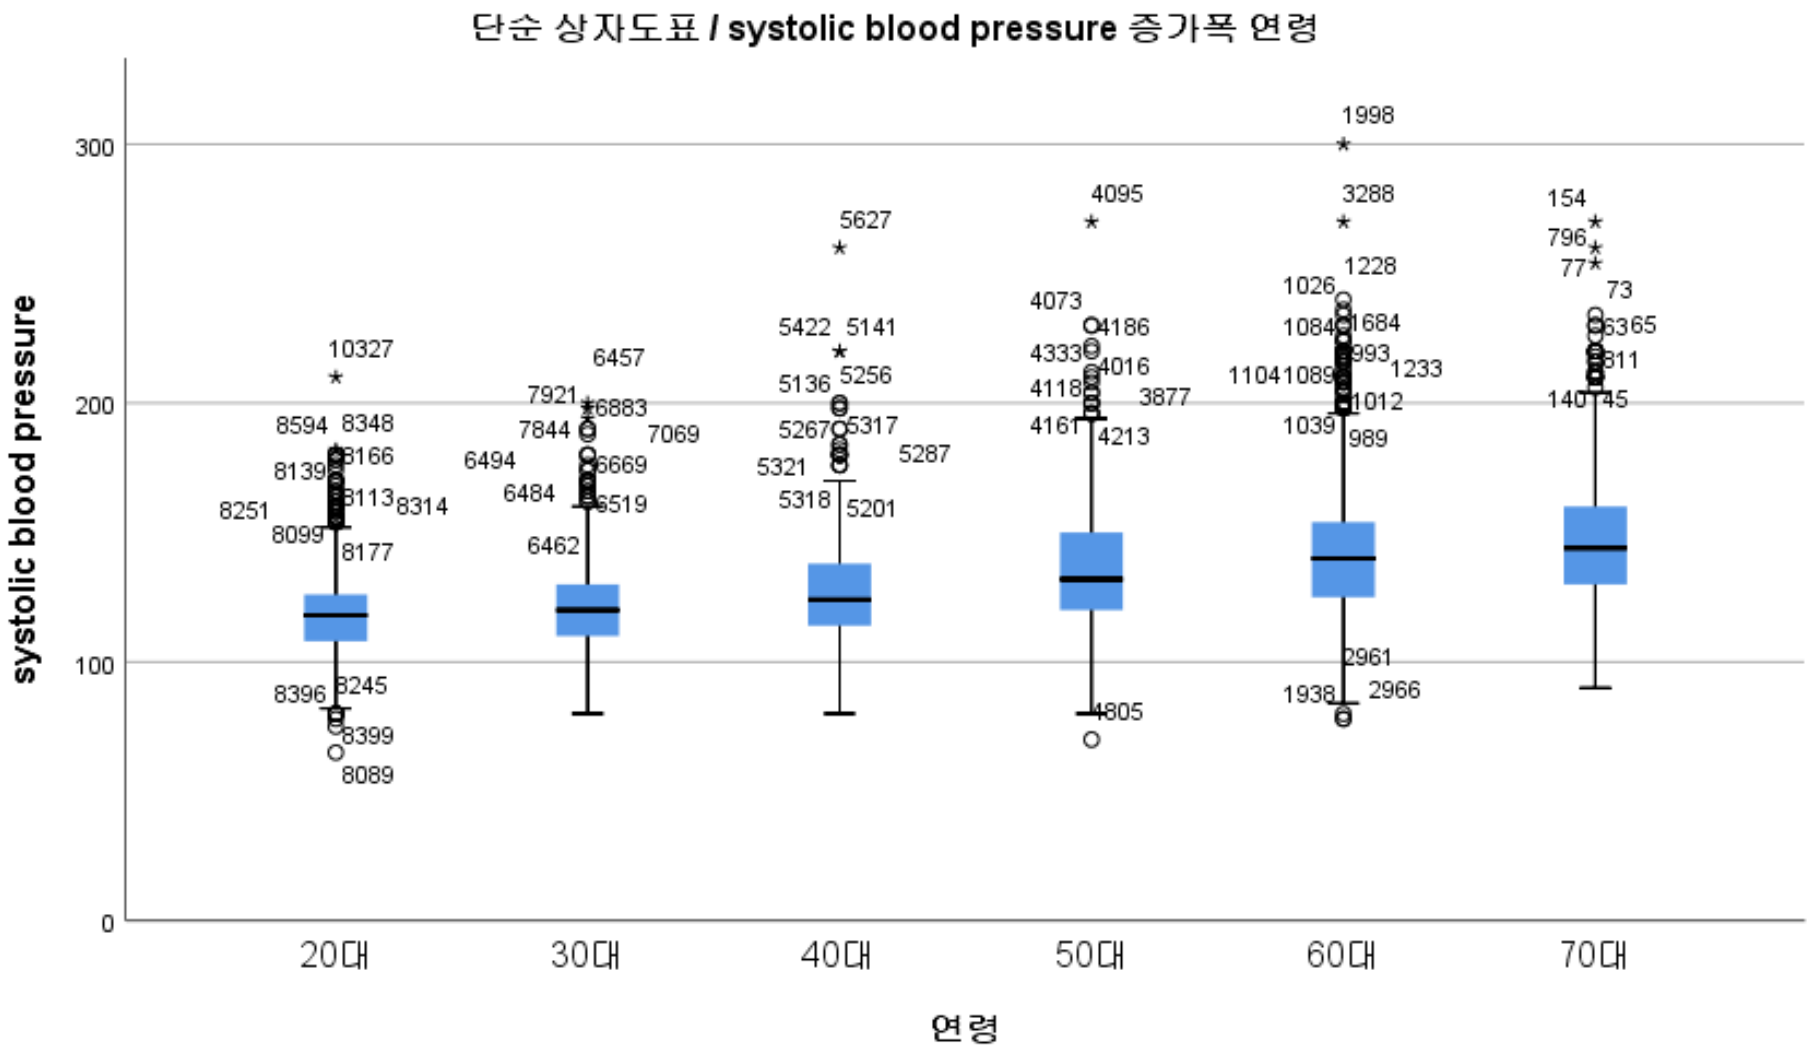
단순 상자도표 / systolic blood pressure 증가폭 연령
systolic blood pressure
300
200
100
0
20대
30대
40대
50대
60대
70대
연령

지난 주 리뷰

총평

- 1번과 2번 문제에서 단측검정을 제대로 수행한 학생은 극소수. 양측검정도 관행상 틀리지 않지만 복습문제인 만큼 단측검정을 수행하는 편이 바람직하다.
- 엑셀에서 계산 문제를 풀 때는 꼭 셀 참조(cell reference)를 해야 계산을 반복하는 동안 소숫점 차이가 크게 벌어지지 않는다!
- 3번 및 4번의 경우 대립가설에 주의해야 한다.
- 가령 4번 문제의 경우 귀무가설은 "모든 연령대에 걸쳐 해당 생물지표의 평균이 같다" 이고, 대립가설은 "해당 생물지표의 평균이 하나의 연령대에서라도 다르다" 이다.
- 말할 필요도 없이 모든 문제에서 결측치를 제거해야 한다.

교차표의 기초

교차표의 기초

교차표는 어쩌면 가장 중요한 사회조사기법이다.

- 원칙적으로 교차표는 두 개의 질적변수 사이의 관계를 분석하는데 사용한다.
- 하지만 일정한 정보의 손실을 감수한다면 숫자형 변수를 범주형 변수로 얼마든지 변환할 수 있다(e.g., 숫자형 연령에서 범주형 연령으로).
- 그러므로 교차표는 (1) 두 개의 질적변수, (2) 하나의 질적변수와 하나의 양적변수, (3) 두 개의 양적변수 등 자료유형과 무관하게 다 사용할 수 있다.
- 즉 교차표는 둘 이상의 변수 간 관계를 분석하는데 있어 매우 탄력적이고 강력한 도구이다.
- 수많은 보고서, 연구논문 뿐 아니라, 사회학의 고전(예를 들면 뒤르켐의 〈자살론〉)에서조차 교차표는 폭넓게 사용되어 왔고 앞으로도 그럴 것이다.

교차표의 기초

- 교차표로 유형론(typology)을 제시하기에 편리하다.
- 신문의 정치적 이데올로기에 따라 다음의 2×2 교차표를 만들었다고 하자.

표 6-4 신문의 정치적 유형

		대외정책	
		보수주의적	진보주의적
국내정책	보수주의적	A	B
	진보주의적	C	D

- 각각의 셀(cell) A, B, C, D는 각각 Max Weber가 말한 이념형(ideal type)에 나타낸다고도 할 수 있다.
- 현실은 아주 구체적이다(e.g., "모든 나무는 다르게 생겼다"). 하지만 우리는 현실을 반영한 추상적 이론을 만들 수 있다(e.g., "나무는 활엽수 또는 침엽수로 나뉜다").
- 앞으로 낯선 현실에 부딪칠 때 과거의 유형론을 꺼내쓸 수 있다!

교차표 표준화

교차표 표준화

- 교차표는 각 셀에는 빈도(frequency)를 보고하는 것에서 종종 출발한다. 하지만 사실 비율(percentage)을 보고하는 쪽이 해석에 훨씬 편리하다.
- 그런데 상대비율을 구할 때는 세 가지 방법을 상상해 볼 수 있다!

  (1) 행 합계(row total)로 표준화하는 방법
  (2) 열 합계(column total)로 표준화하는 방법
  (3) 총 합계(grand total)로 표준화하는 방법
- 물론 셋 다 연습해야 한다. 분석 목적에 따라 다른 표준화 방식이 적용되어야 하기 때문이다.
- 그런데 우리는 관습에 따라 종종 독립변수 X에 해당하는 부분을 행(row)에 놓고, 종속변수 Y에 해당하는 부분을 열(column)에 놓는 경향이 있다.
- 이 경우 행 합계로 표준화하는 편이 해석에 편리하다(Why?).

교차표 표준화

종교성의 성차를 살펴본다고 하자.

- 좌측은 빈도를, 우측은 행 합계 비율을 나타내고 있다.

	비종교인	종교인	합계
남자	232	68	300
여자	124	97	221
합계	356	165	521

	비종교인	종교인	합계
남자	0.77	0.23	1
여자	0.56	0.44	1
합계	0.68	0.32	1

- 이 해석은 물론 조건부확률(conditional probability) 개념을 사용하고 있다.

$$P(\text{비종교인}|\text{남자}) = 0.77 \qquad P(\text{종교인}|\text{남자}) = 0.23$$
$$P(\text{비종교인}|\text{여자}) = 0.56 \qquad P(\text{종교인}|\text{여자}) = 0.44$$

교차표 표준화

- 좌측은 빈도를, 우측은 열 합계 비율을 나타내고 있다.

	비종교인	종교인	합계
남자	232	68	300
여자	124	97	221
합계	356	165	521

	비종교인	종교인	합계
남자	0.65	0.41	0.58
여자	0.35	0.59	0.42
합계	1	1	1

- 만약 열 합계로 표준화할 경우, P(여자|종교인), P(남자|종교인), P(여자|비종교인), P(남자|비종교인)을 계산할 수 있다. 이 해석들도 조건부확률 개념을 사용하고 있다.

교차표 표준화

- 좌측은 빈도를, 우측은 총 합계 비율을 나타내고 있다.

	비종교인	종교인	합계
남자	232	68	300
여자	124	97	221
합계	356	165	521

	비종교인	종교인	합계
남자	0.45	0.13	0.58
여자	0.24	0.19	0.42
합계	0.68	0.32	1

- 이 해석은 결합확률(joint probability)을 사용하고 있다.

$$P(\text{비종교인} \cap \text{남자}) = 0.45 \qquad P(\text{종교인} \cap \text{남자}) = 0.13$$
$$P(\text{비종교인} \cap \text{여자}) = 0.24 \qquad P(\text{종교인} \cap \text{여자}) = 0.19$$

교차표 표준화

(제3주차 시각화 수업에서 배웠듯) 막대 차트를 이용해 시각화할 수 있다.

- SPSS에서는 [분석]-[기술통계량]-[교차분석]에서 “수평배열 막대형 차트 표시”를 클릭할 수 있다.
- 그러나 [그래프]-[차트 작성기]에서 “수평누적 막대도표”를 선택한 뒤, x축과 군집을 잘 선택하는 편이 낫다(Why?).

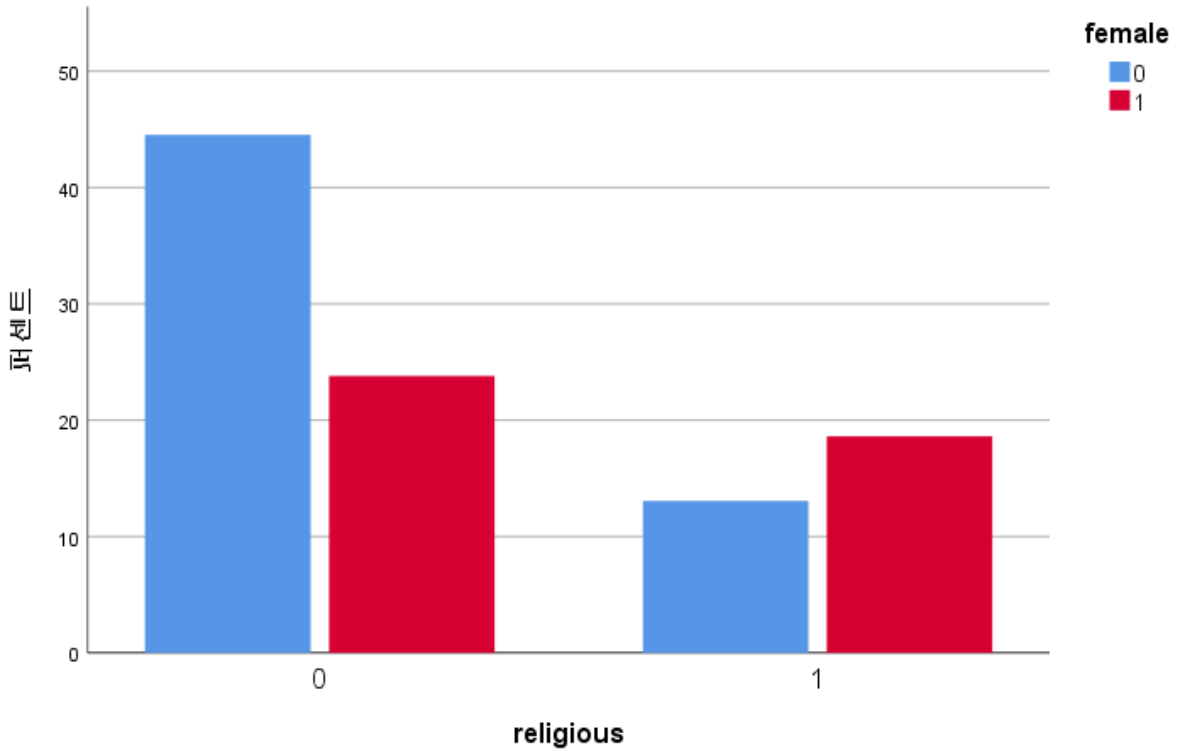

교차표 표준화

연습 1. HATE.SAV 자료를 SPSS에서 불러들여 오프라인 혐오표현 노출과 온라인 혐오표현 노출 간 연관성을 드러내는 표를 작성한 뒤, 이를 적절히 해석하시오.

χ^2 독립성 검정

χ^2 독립성 검정

χ^2 분석으로 교차표의 유의성 검정을 수행할 수 있다.

- 우리는 이미 χ^2 분포에 관해 모분산에 대한 추정과 가설검정 파트에서 배웠다.
- 이제 Karl Pearson이 개발한 χ^2 독립성 검정(chi-square test of independence) 또는 χ^2 분석(chi-square analysis)이라고 불리우는 기법을 하나 더 배운다.
- χ^2 분포를 따르는 확률밀도함수를 정의하기 위해서는 독립성 가정(independence assumption)이 필요했음을 떠올리자. Karl Pearson의 χ^2 분석은 이 가정을 절묘하게 이용했다.
- 즉, 독립성을 가정하고 이론적으로 계산한 기대빈도(expected frequency) E와 실제 교차표의 관찰빈도(observed frequency) O를 비교하여 너무 큰 차이가 나는지 살펴보는 것이다!

χ^2 독립성 검정

기대빈도 E는 χ^2 분포의 독립성 가정에 따라 계산된다.

- 표준화된 비율 자료가 아니라 빈도 자료로 χ^2 독립성 검정을 시작한다.

	비종교인	종교인	합계
남자	232	68	300
여자	124	97	221
합계	356	165	521

- 성별과 종교 두 변수가 독립적이라면(=다른 모집단에서 나온 표본이라면) 곱셈법칙이 성립한다.

$$P(A \cap B) = P(A|B) \cdot P(B) = P(A) \cdot P(B)$$

- e.g., $P(\text{여자} \cap \text{종교인}) = P(\text{여자}) \cdot P(\text{종교인}) = (221/521) \cdot (165/521) \approx 0.13434$
- $n = 521$ 이므로 "여자 $\cap$ 종교인" 사건의 기대빈도 E는 $521 \cdot 0.13434 = 69.99$이다.

χ^2 독립성 검정

- 이제 채워진 관찰빈도 O와 기대빈도 E를 곰곰히 비교해보자!

	비종교인	종교인	합계
남자	232	68	300
여자	124	97	221
합계	165	356	521

	비종교인	종교인
남자	204.99	95.01
여자	151.01	69.99

- 기대빈도 E는 두 변수가 독립적이라는 가정에 입각했을 때 이론적으로 기대된 빈도였다.
- 다시 말해, 기대빈도 E가 관찰빈도 O와 크게 다르지 않다면 독립성 가정(=두 변수는 서로 독립적이다)는 결론에 도달한다.
- 반면, 기대빈도 E와 관찰빈도 O가 크게 다르다면 독립성 가정이 틀리다는 결론에 도달한다. 즉 두 변수는 연관되어 있는 것이다.

χ^2 독립성 검정

지금까지 논의를 통해 χ^2 분석의 가설구조를 유추할 수 있다.

- χ^2 독립성 검정의 가설은 다음과 같다.

$$H_0 : \text{성별과 종교인 여부는 서로 독립적이다.}$$
$$H_a : \text{성별과 종교인 여부는 서로 독립적이지 않다.}$$

- 만일 귀무가설을 기각할 수 있었다고 할지라도 여성이 더 종교적인지 여부 등은 독립성 검정을 통해서는 알 수 없다.
- 단지 "성별과 종교성이 서로 독립적"이라는 귀무가설을 통계적으로 유의하게 기각할 수 있을 뿐이다.
- 대립가설 이상의 해석을 χ^2 독립성 검정에 멋대로 덧붙이지 않도록 꼭 주의해야 한다!

χ^2 독립성 검정

관찰빈도 O와 기대빈도 E가 다름을 확인하는 유의성 검정을 수행한다.

- (유의성 검정에서 사용하는) 이론적 확률분포는 확률변수 χ^2의 분포이다.

$$\sum_{j=1}^{J}\sum_{k=1}^{K}\frac{(O_{jk}-E_{jk})^2}{E_{jk}} \sim \chi^2_{(j-1)(k-1)}$$

- 만일 귀무가설대로 $O = E$라면 χ^2는 0이다. 그러나 표본에서 계산된 χ^2 값이 크다면 (그려진) χ^2 분포 위의 아주 구석진 곳에 놓일 것이다.
- 유의수준에 따른 판정은 엑셀 함수 1-CHISQ.DIST(·)를 활용할 수 있지만 SPSS가 바로 답을 준다.

교차표 표준화

연습 2. religious.csv 자료를 SPSS에서 불러들여 종교성과 성차의 연관성을 살펴보고 이에 대한 유의성 검정을 수행한 뒤, 결과를 해석하시오.

교차표 표준화

연습 3. FINEDUST.SAV 자료를 SPSS에서 불러들여 “귀하는 미세먼지로 인해 어느 정도 영향을 받고 계십니까”라는 문항이 응답자가 거주하고 있는 광역지역에 따라 연관성이 있는지 여부를 나타내고 해석하시오.

χ^2 독립성 검정

교차표와 유의성 검정 결과를 기술통계표로 제시할 수도 있다.

- 김봉정 외 (2009) 논문 ⟨표2⟩, ⟨표3⟩, ⟨표4⟩를 통해 교차표를 어떻게 만들 수 있는지 잘 살펴보자.
- (만일 가능하다면) 다른 어떤 방식으로 유의성 검정을 수행할 수 있을까?

교차표 표준화

연습 4. ASAN.SAV 자료를 SPSS에서 불러들여 응답자의 성별, 연령대, 거주지역, 학력, 직업, 가구소득 별로 기술통계표를 만들고자 한다. 이때 각 인구학적 속성이 주한미군 신뢰도 및 주한미군의 한국주둔 필요성과 어떠한 연관성을 가지고 있는지 나타내는 표를 작성하고 적절한 유의성 검정을 수행하시오.

χ^2 독립성 검정

본래 χ^2 분석에는 독립성 검정 이외에 다른 유형도 있다.

- 기본적으로 독립성 검정(independence test)이 압도적으로 많이 쓰인다.
- 그러나 동질성 검정(homogeneity test)과 적합성 검정(goodness-of-fit test)도 분석 목적에 따라 나름 유용하다(교재 11장 참고).
- 독립성 검정과 동질성 검정은 두 변수 사이의 독립성에 주목하는 반면, 적합성 검정에서는 단일한 변수에 대한 이론적 분포와 (실제로) 관찰된 분포 사이의 일치성 여부를 살펴본다.
- 적합성 검정은 고급통계학이나 수리사회학(mathematical sociology) 분야에서는 매우 중요한 분석도구가 되지만, 기초사회통계에서는 다루지 않는다.