사회통계연습
상관분석과 산점도

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

October 21, 2022

진행 순서

1. 상관분석 톺아보기
2. 유의성 검정 및 해석상 주의사항

상관분석 톺아보기

상관분석 톺아보기

"둘 이상의 양적변수" 사이의 관계를 볼 때는 일차적으로 상관분석 (correlation analysis)을 수행한다.

- 상관분석은 상관계수(correlation coefficient)를 구하는 기법이고, 상관계수를 이해하려면 먼저 분산(variance)과 공분산(covariance)을 돌이켜 볼 필요가 있다.
- 먼저 다시 분산의 식을 돌이켜보자.

$$
\begin{aligned}
Var(X) &= \frac{1}{n}\sum_{i=1}^{n}(X_i - \mu)^2 \\
&= \frac{1}{n}\sum_{i=1}^{n}(X_i - \mu)(X_i - \mu)
\end{aligned}
$$

- 변수가 하나만 주어져 있을 때 편차(deviation)를 구해 제곱하여 분산을 구했는데, 아래처럼 살짝 바꾸면 곧바로 공분산이 된다.

$$
Cov(X, y) = \frac{1}{n}\sum_{i=1}^{n}(X_i - \mu_X)(Y_i - \mu_Y)
$$

상관분석 톺아보기

- 공분산과 분산의 아이디어는 거의 똑같다!
- 두 변수의 편차끼리 곱할 때, 모두 양수(+)이거나 음수(-)이면 공분산은 양수(+)가 되고, 어느 한쪽이 양수(+)이고 다른 쪽이 음수(-)이면 공분산은 음수(-)가 된다.
- 공분산은 흥미로운 아이디어를 제시하고 있지만 명확한 단점이 있었다. $\mathrm{Cov}(X, Y)$는 X 내부(within X)의 분산과 Y 내부(within Y)의 분산이 다를 수 있다는 점을 고려하지 않는다. 제대로 표준화가 안되었다는 의미다.
- 그 결과 그 자체로는 해석이 어려웠기 때문에 새로운 대안이 필요했다.

상관분석 톺아보기

Karl Pearson은 공분산의 단점을 보완하는 천재적인 접근을 제시했다.

- 그는 두 변수 X와 Y의 각각의 표준편차(분산이 아니고!)를 분모로 각각 나누어줌으로서 X 내부의 분산과 Y 내부의 분산이 다를 수 있는 가능성을 제거하고 표준화를 이루었다.
- 뿐만 아니라, 일부러 분산이 아닌 표준편차로 나누어주었기 때문에 표준화된 값은 절묘하게 -1과 1사이로 두 변수가 얼마나 강한 상관관계를 가지고 있는지 보여준다.
- 이것이 이른바 피어슨의 적률상관계수(Pearson's product-moment correlation coefficient)이다. 줄여서 상관계수 ρ다. ρ는 rho라고 읽는다(신뢰도 계수와는 다르다!).

$$\rho = \frac{\mathrm{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

상관분석 톺아보기

상관계수의 해석은 매우 간단하지만 혼동하지 않도록 주의해야 한다.

- 상관계수는 반드시 -1과 1사이에 놓인다.
- 상관계수가 0보다 크면 두 변수는 서로 같은 방향(정방향)으로 움직인다. 즉 "X가 증가하면 Y도 증가한다."
- 상관계수가 0보다 작으면 두 변수는 서로 다른 방향(역방향)으로 움직인다. 즉 "X가 증가하면 Y는 감소한다."
- 왜 이렇게 해석되는지 공분산의 분자 부분인 $\sum(X-\bar{X})(Y-\bar{Y})$ 를 들여다보자.
- 상관계수가 1에 가까울수록 (그리고 -1에 가까울수록) 두 변수는 더욱 밀접한 관계를 갖게 된다.

상관분석 톺아보기

- 해석은 이런 식이 편리하다: 0과 1 사이를 사분위수로 나누고 각각 리커트 4점 척도로 의미를 부여한다. 물론 0과 -1 사이에서도 마찬가지이다.

상관계수	상관관계의 해석
[-1, -0.75]	매우 강한 역방향
[-0.75, -0.5]	다소 강한 역방향
[-0.5, -0.25]	다소 약한 역방향
[-0.25, 0]	매우 약한 역방향
[0, 0.25]	매우 약한 정방향
[0.25, 0.5]	다소 약한 정방향
[0.5, 0.75]	다소 강한 정방향
[0.75, 1]	매우 강한 정방향

유의성 검정 및 해석상 주의사항

유의성 검정 및 해석상 주의사항

상관계수에 대해서도 다음과 같이 유의성 검정을 할 수 있다.

- 상관계수에 대해서는 무조건 양측검정을 수행하며, 주어진 가설 구조는 다음과 같다:

$$H_0 : \rho = 0$$
$$H_a : \rho \neq 0$$

- t 검정을 통해 유의확률(p-value)을 구한다. 단, t 분포의 꼴은 $(n-2)$의 자유도로 결정된다.
- 검정통계량 t 값은 다음과 같다:

$$t = \frac{\hat{\rho} - \rho}{SE_\rho} = \frac{\hat{\rho}}{\sqrt{\frac{1-\hat{\rho}^2}{n-2}}} = \hat{\rho}\sqrt{\frac{n-2}{1-\hat{\rho}^2}}$$

- 즉 (1) 추정된 상관계수 $\hat{\rho}$가 커지고 (2) 사례수 n가 많아질수록 t 값이 커져 영가설을 기각하기 쉬워진다.

유의성 검정 및 해석상 주의사항

소표본만 벗어나도 상관계수의 유의성 검정에 사실 큰 의미가 없다.

- 위 식을 곰곰히 들여다보면 눈치챌 수 있는 부분인데, 예컨대 $n = 50$ 정도로 작은 샘플에서 $\hat{\rho} = 0.3$ 정도의 값만 나와주어도 이미 95% 신뢰수준에서 통계적으로 유의하다(Why?).
- 오늘날 경험적 사회과학 연구에서 $n = 50$ 짜리 연구는 없다. 게다가 $\hat{\rho} = 0.3$는 거의 없는 수준의 상관관계에 불과하다.
- 많은 보고서와 논문에서는 기술통계(descriptive statistics)의 일환으로 상관계수행렬을 제시하는 편인데, 상관계수행렬은 보고서 또는 논문의 한 페이지를 통째로 잡아먹기 때문에 근래에는 보고하지 않는 경우도 많아졌다. 여기에 더해 상관계수 옆에 별을 잔뜩 붙이다보면 페이지 공간을 쓸떼없이 차지하고 별 의미도 없다.

유의성 검정 및 해석상 주의사항

연습 2. airdust.csv 파일을 SPSS로 불러들이고, 코드북을 참조해 "제1차 국민정책제안 각 과제"의 의견 총합과 "중장기 정책과제"의 의견 총합 사이의 관계를 살펴보시오. 두 합성지수의 의미를 고민하고 이를 각각 구성하시오. 그 기술통계를 살펴보고 시각화한 뒤, 합성지수의 신뢰도를 판정하시오. 모든 측정항목들이 합성지수를 구성하는데 의미있었는지도 확인하시오. 두 변수 간의 연관성을 나타내는 통계적 검정을 수행하고 그 결과를 시각화하시오.

유의성 검정 및 해석상 주의사항

산점도를 꾸밀 때 주의해야 할 점이 있다.

- 많은 사회조사에서는 양적척도가 좀처럼 사용되지 않고 대체로 질적척도인 경우가 많다(Why?).
- 반면 통계학의 분석기법(상관분석이나 회귀분석 등)은 대체로 양적변수일 때 편리하다.
- 그러므로 사회조사에서는 질적변수로 물어보고 이를 합성지수로 (재)구축하여 대체로 등간(approximately interval)인 양적변수로 바꾸는 전략이 종종 사용된다!

유의성 검정 및 해석상 주의사항

- 종종 대체로 등간 변수간 관계를 산점도로 시각화하면 점이 나란히 줄지어서 나타난다(Why?).
- 이를 개선하기 위해 덜덜떨기(jittering) 또는 투명화(transparency)를 주로 사용한다.
- 투명화는 SPSS에서 일단 그림을 만든 뒤, 더블클릭하고서 [옵션]-[구간 요소]에서 색상 농도를 조정하여 구현할 수 있다.
- 두 변수 중 하나라도 측도가 질적변수로 설정되어 있는 경우 적합선이 그려지지 않는다. 이런 경우 수동으로 재설정해야 한다!

유의성 검정 및 해석상 주의사항

상관계수를 보고할 때는 반드시 함께 산점도를 그려준다.

- 상관계수는 기본적으로 두 변수간 선형적 관계의 강도(strength of the linear relationship)를 나타내 보인다. 다시 말해, 두 변수 사이에 선형적이지 않은 관계, 즉 비선형적 관계(nonlinear relationship)가 있는 경우에는 상관계수가 오해를 불러온다. 애시당초 두 변수 사이가 U자형, 역U자형, W자형 등등이 아니라는 보장이 어디에 있는가?
- 게다가 상관계수는 극단치(outliers)를 가진 경우 여기에 민감하게 영향받을 수 있다.
- 이런 문제를 방지하기 위해 반드시 산점도(scatterplot)를 그려보아야 한다. 이를 통해 대략 상관계수가 어떻게 나올지 짐작할 수도 있다.
- 기울기(degree of steepness)는 상관계수의 본질이 아니다! 오히려 관찰값 사이의 흩어짐(degree of scatter), 다시 말해 "산포 경향"이 상관계수의 본질이다(Why?).

유의성 검정 및 해석상 주의사항

필요하다면 분석 전에 변수를 변환해야 한다.

- 대수변환(logarithmic transformation)이 가장 대표적이다.
- 작은 값에 대수(log)를 취하면 작은 값이 나온다. 큰 값에 대수(log)를 취하면 작은 값보다 살짝 크게 나온다(엑셀로 연습해보자!).
- 변수를 멋대로 변환해도 괜찮은 것일까? 대수변환의 경우 그 답은 "그렇다"이다 (Why?).
- SPSS에서는 [변환]-[변수 계산]에서 수행한다. 자연대수(natural log)를 가장 흔히 사용하는데 LN(·)으로 만들수 있다.
- 종종 변수의 분포가 치우쳐 있을 때(e.g., 소득분포) 정규분포에 가깝게 바꾸어 줄 수 있다.
- 산점도를 그릴 때 필요하다면 어느 한 변수(혹은 둘 다) 대수변환을 하는 것이 바람직하다!

유의성 검정 및 해석상 주의사항

연습 3. TENURE.SAV 파일을 SPSS로 불러들여 월 평균소득액과 근속기간 사이의 연관성에 관한 통계적 검정을 실시하고 이를 적절하게 시각화하시오.

유의성 검정 및 해석상 주의사항

- 무턱대고 상관계수를 계산하고 산점도를 그리기에 앞서 결측치 등을 확인하고 히스토그램 역시 그려보아야 한다!
- 소득액은 확실히 오른쪽으로 긴 꼬리를 갖고 있으므로 자연대수로 변환하면 정규분포에 근접하게 된다.
- 이제 산점도를 그려보면 비로소 극단치(outliers)가 발견된다. 이들을 제거하고 다시 상관계수를 계산하고 산점도를 그려보면 적지 않은 변화가 나타난다.

유의성 검정 및 해석상 주의사항

연습 4. DEPR.SAV 파일을 SPSS로 불러들여 응답자들이 인지한 거주 동네의 성격과 우울감 사이의 연관성에 관한 통계적 검정을 실시하고 이를 적절하게 시각화하시오.

유의성 검정 및 해석상 주의사항

- 신뢰도 계수를 계산해보고 만일 특정 문항을 제외했을 때 신뢰도 계수가 크게 상승한다면 이를 제외해야 한다.
- 색깔 바꾸기와 적합선 그리기를 확실히 해야 한다.
- 집단적 효능감(collective efficacy)와 우울감 사이에는 어떠한 연관성이 있는지 결론을 내려보자.