사회통계연습

회귀계수의 해석과 유의성 검정

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

November 11, 2022

진행 순서

1. 지난 주 리뷰
2. 단순선형회귀모형
3. 회귀계수와 상수의 유의성 검정
4. 다중회귀모형

지난 주 리뷰

지난 주 리뷰

1. 주어진 데이터에서 Q로 시작하는 변수들은 주요 정부기관에 대한 신뢰도를 묻고 있다. 이 변수들을 단순 합산하여 합성지수를 구성하시오. 그 합성지수의 내적 일관성을 판단하시오. [30점]

지난 주 리뷰

- 먼저 결측치를 제거하고, (신뢰지수이므로) 개별 변수를 역코딩해야 한다.
- 단순합을 하고 그 합성지수의 내적 일관성을 확인하기 위해 크론바흐 알파를 계산한다. 신뢰도 계수가 .895이므로 충분히 높다고 할 수 있다.

지난 주 리뷰

2. 새롭게 만든 합성지수와 Welzel의 세속가치점수(sacsecval) 사이의 관계를 살펴보기 위해 적절한 분석 기법을 검토한 뒤, 이를 수행하시오. 단 반드시 두 변수 사이의 관계를 드러내 보이기 위한 시각화를 적절하게 수행하고 설명하시오. [35점]

지난 주 리뷰

- 두 변수 모두 대체로 등간척도이며 양적변수이므로, 상관계수와 산점도를 사용할 수 있다.
- 변수의 변환은 고려할 필요가 없다(Why?).
- 상관계수는 -.4 정도 나오며 99.9% 신뢰수준에서 통계적으로 유의하다(살짝 다를 수도 있다).

지난 주 리뷰

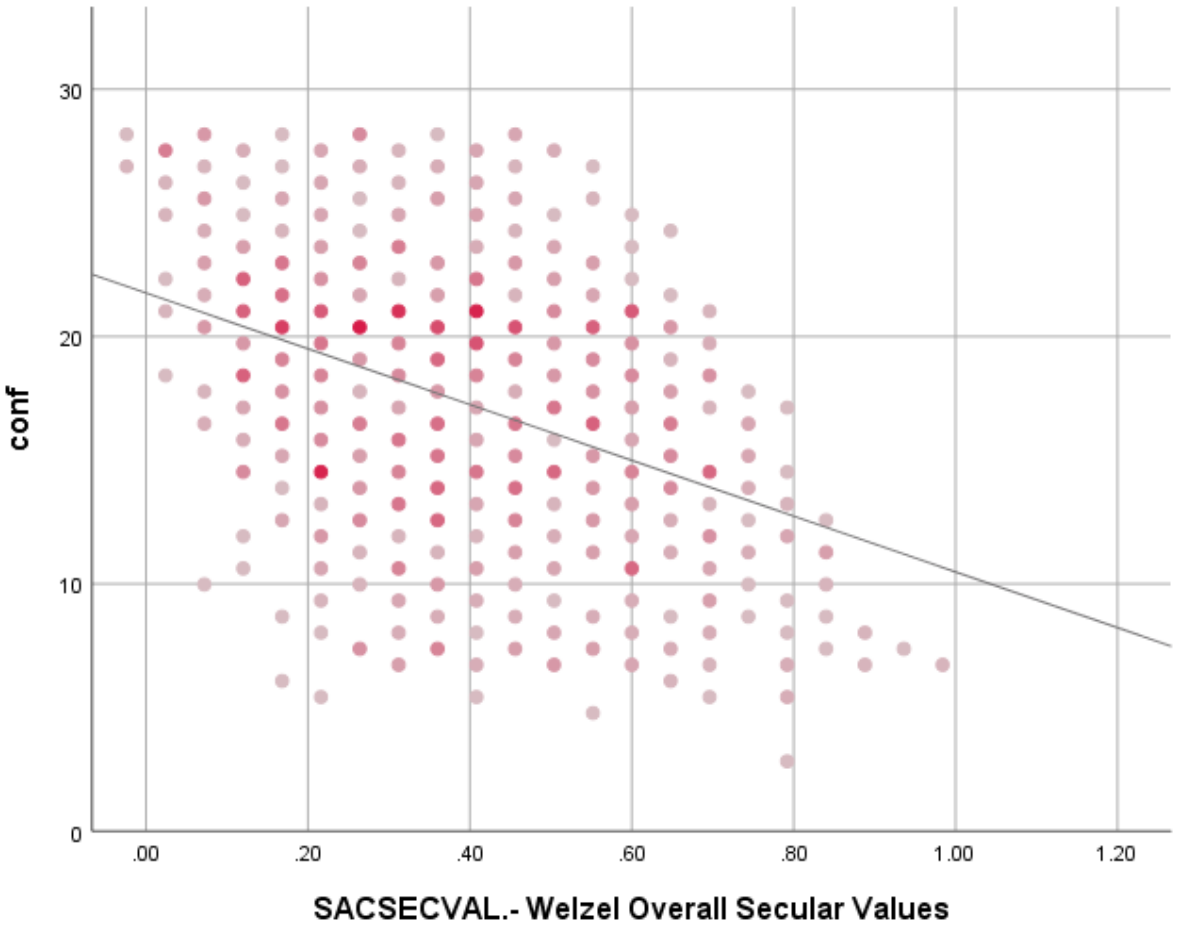
30
20
10
0
conf
.00
.20
.40
.60
.80
1.00
1.20
SACSECVAL.- Welzel Overall Secular Values

지난 주 리뷰

3. 주요 정부기관에 대한 신뢰도와 세속가치점수 간의 연관성이 국제지역별(regionWB)로 어떤 공통점 혹은 차이점이 있는지 통계적으로 분석하고 시각화하시오. 도출한 결론에 대해서도 설명하시오. [35점]

지난 주 리뷰

- SPSS에서 케이스 선택을 통해 지역을 고른다.
- 그림을 여러 개 그릴 때는 나란히 보여 읽는 사람이 쉽게 비교할 수 있도록 배려해야 한다.
- 결국 세속가치점수와 신뢰점수는 역관계에 있음이 문명권을 넘어 공통적으로 관찰된다.
- "신뢰도는 ~이다" 라고 이야기하기 보다는 "신뢰도는 ~이므로 통상적 기준 0.7을 넘어 내적 일관성이 있다고 판단할 수 있다"하는 식으로 설명해야 한다.

지난 주 리뷰

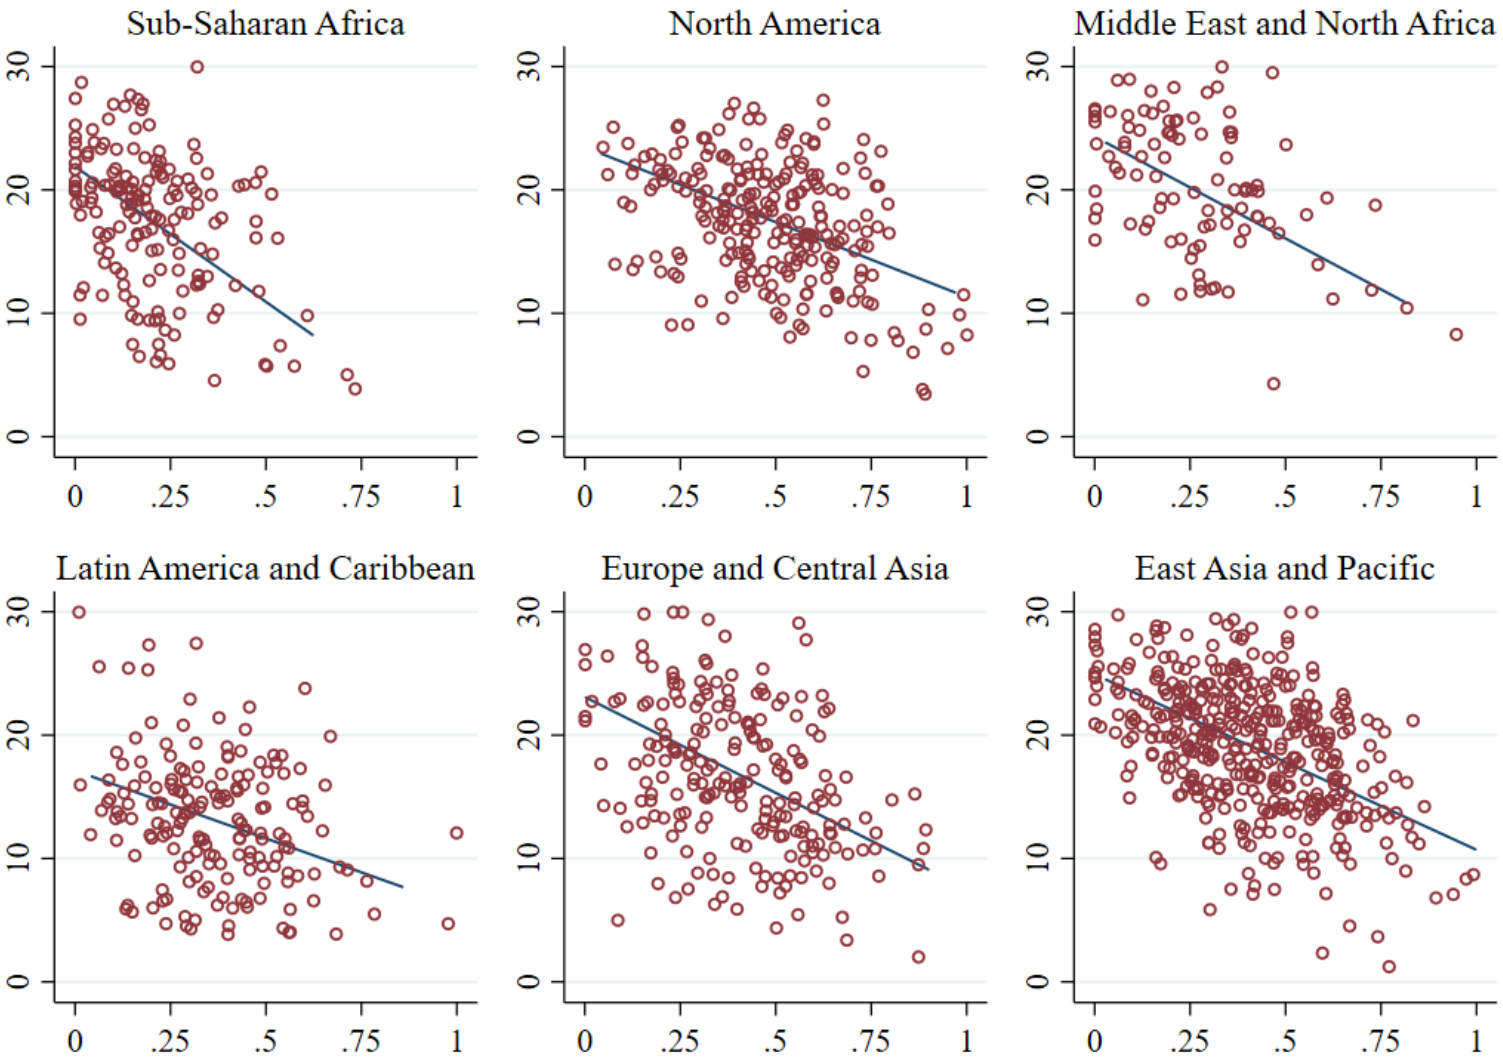
Sub-Saharan Africa
North America
Middle East and North Africa
Latin America and Caribbean
Europe and Central Asia
East Asia and Pacific
0
10
20
30
0
.25
.5
.75
1

단순선형회귀모형

단순선형회귀모형

독립변수 X와 종속변수 Y 사이의 관계를 선으로 나타내보자.

- 이른바 선형회귀모형(linear regression model)은 아래와 같이 일차방정식(linear equation)으로 설정할 수 있다.

$$Y_i = \beta_0 + \beta_1 X_i + \epsilon_i$$

- 하첨자 i가 붙어있으므로 관찰값(observation)에 따라 상이한 X_i와 Y_i, ϵ_i를 담게 된다.
- 이때 β_0를 상수(constant) 또는 절편(intercept)이라고 부르고, β_1를 기울기(slope)라고 부른다.
- 한편, β_0와 β_1를 어떻게 설정하더라도 결국 자료를 완벽하게 설명할 수는 없다. 따라서 오차항(error term) ϵ_i을 선형회귀모형에 추가한다.

단순선형회귀모형

우리는 초등수학에서 일차방정식을 그래프로 나타내기를 배웠다.

- 그 내용이 기억나지 않는다면 desmos라는 웹사이트에서 $Y = \beta_0 + \beta_1 X$를 그려보자.
- β_1를 이리저리 바꾸어서 이것이 기울기임을 확인하고, β_0를 이리저리 바꾸어서 이것이 절편임을 확인하자.
- X가 수평축이고 Y가 수직축임에 주목하자.
- 기울기는 X가 한 단위 변화할 때 Y가 변화하는 정도를 의미한다.
- 절편은 $X = 0$일 때 Y 값을 의미한다.

단순선형회귀모형

- 우리는 이미 상관분석을 배우면서 적합선(fitting line)을 이미 그려보았다.
- 마찬가지로 주어진 자료의 X와 Y 사이에 가장 잘 맞는 직선(best-fitting straight line)을 그어 그 관계를 나타내 보일 수 있다.
- 이렇게 자료를 관통하는 하나의 선을 찾는 것이 바로 회귀분석(regression analysis)의 핵심이다.

단순선형회귀모형

오차를 전반적으로 최소화하는 적합선이야말로 가장 잘 맞는 직선이다.

- 엑셀에서 그려진 적합선과 회귀식은 도대체 어떻게 추정된 것일까?
- 일단 회귀식이 추정되었다면 새로운 X_i 값이 주어질 때, (그에 대응하는) Y_i를 예측(predict)할 수 있다.
- 실제 자료 Y_i와 예측된(predicted) Y_i (혹은 $\widehat{Y}$) 간의 차이는 곧 오차(error)라고 볼 수 있다.

$$\widehat{e}_i = Y_i - \widehat{Y}_i = Y_i - (\widehat{\beta}_0 + \widehat{\beta}_1 X_i)$$

- 모집단에서는 오차, 표본에서는 잔차(residuals) e라고 구분된다(하지만 종종 잔차도 그냥 오차라고 부른다).
- 회귀식에서 추정량(estimates)에 대해서는 이렇게 ˆ(hat)을 붙인다.

단순선형회귀모형

- 예상되는 오차 $\widehat{\epsilon}_i$를 줄인다는 것은 현실 자료와 이론적 예측 사이의 괴리를 줄인다는 의미와 일맥상통한다.
- 물론 (오차 하나만 줄이는 것이 아니라) 오차를 전체적으로 줄이는 것이 중요하다.
- 단, 오차의 합을 그냥 최소화하지 않고 오차 제곱의 합(sum of squared error; SSE)을 최소화한다(Why?).
- 오차 제곱의 합을 최소화하는 β_0와 β_1을 찾음으로써, 주어진 자료를 가장 잘 설명할 수 있는 모형을 만들 수 있게 된다.

$$\underset{\beta_0,\beta_1}{\operatorname{argmin}} \sum_{i}^{n} \epsilon_i^2$$

- 이것이 바로 단순최소자승(ordinary least squares; OLS)이다.

단순선형회귀모형

연습 1. lungcancer.csv는 이것은 8개 북유럽 국가의 1인당 담배 소비량(smoke)과 인구 100만 명당 폐암 발병자수(cancer)를 나타낸다.
독립변수와 종속변수를 선택한 뒤, 둘 사이의 관계를 나타내기 위해 가장 잘 맞는 직선을 그리시오. 회귀식을 도출하고 관계를 해석하시오.

단순선형회귀모형

- 1인당 담배 소비량(smoke)이 100만 명당 폐암 발병자수(cancer)에 영향을 미친다고 보는 것이 타당하다.
- 회귀식은 다음과 같이 추정되었다.

$$E(Y_i|X_i) = 0.355 \cdot X_i + 21.511$$

- "국가의 1인당 담배 소비량이 한 단위 증가할 때, 100만 명당 폐암 발병자수는 0.355 만큼 증가한다."
- "아무도 흡연하지 않은 국가에서 100만 명당 폐암 발병자수는 21.511이다."
- 일반적으로 표현하자면, 독립변수 X의 값이 한 단위 변화(unit change)하면 회귀계수 b_1 만큼 종속변수 Y에 영향을 미친다.

단순선형회귀모형

- SPSS에서는 [분석]-[회귀분석]-[선형]을 선택한다. 왜 선형일까?
- 회귀분석의 결과표는 크게 (1) 회귀분석 통계량, (2) 분산분석, (3) 추정된 회귀식의 세 부분으로 나뉜다.
- 사실 산점도와 적합선을 먼저 그려보아 두 변수 간 관계를 미리 짐작해보고 극단치 (outliers) 존재 유무 등을 미리 살펴보아야 한다.
- 이때, 적합선은 사실 회귀식을 시각화한 것이다.

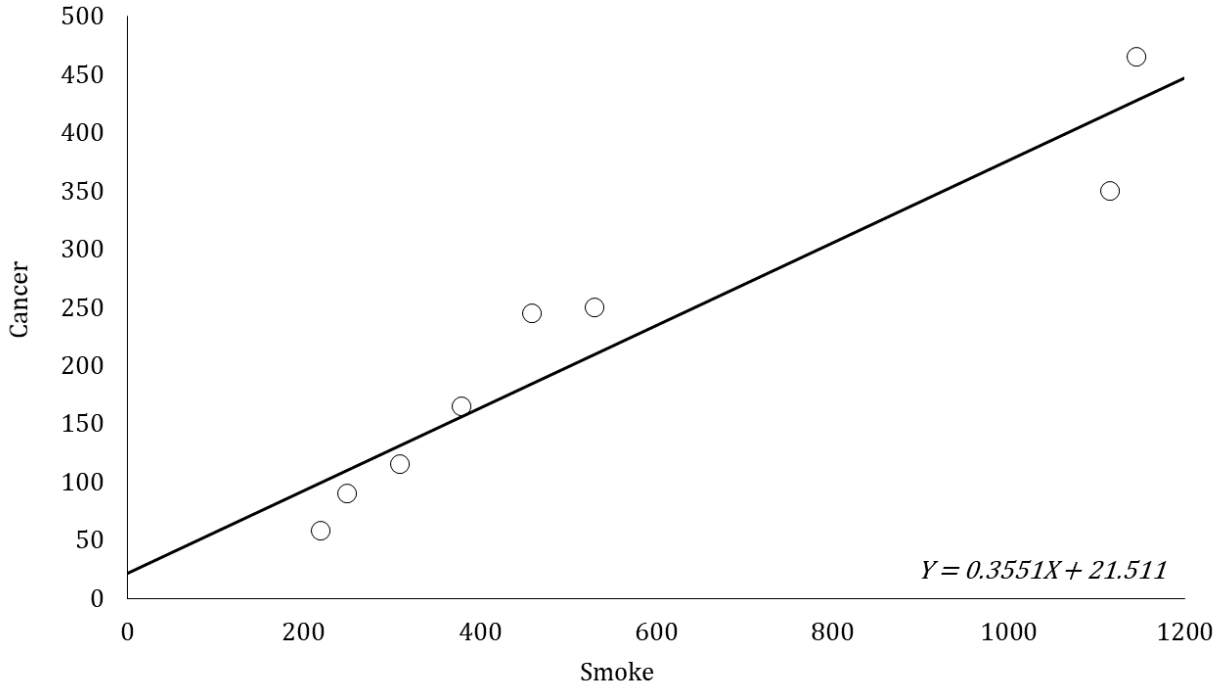

회귀계수와 상수의 유의성 검정

회귀계수와 상수의 유의성 검정

회귀분석에서도 표본을 넘어 모집단의 성격을 추론할 필요가 있다.

- 설령 우리가 미분 문제를 풀어 오차제곱합(SSE)을 최소화하는 회귀계수와 상수를 구했다고 하더라도 이것은 어디까지나 표본의 성격, 즉 통계량(statistic)일 뿐이다.
- 그렇기 때문에 모집단에서의 회귀모형과 표본에서의 회귀모형은 개념적으로 구별될 수 있다.

$$Y_i = \beta_0 + \beta_1 X_i + \epsilon_i \qquad \text{(모집단 회귀모형)}$$
$$Y_i = b_0 + b_1 X_i + e_i \qquad \text{(표본집단 회귀모형)}$$

- ϵ_i가 오차항(error term)이라고 불리우는 반면, e_i는 잔차항(residual term)이라고 불리운다.

회귀계수와 상수의 유의성 검정

- 우리는 다음과 같은 가설 구조에 따라 모집단의 성격, 즉 모수(parameter)에 대해서도 추론해야 한다.

$$H_0 : \beta_0 = 0 \qquad H_a : \beta_0 \neq 0 \qquad \text{(상수의 경우)}$$
$$H_0 : \beta_1 = 0 \qquad H_a : \beta_1 \neq 0 \qquad \text{(회귀계수의 경우)}$$

- 추론하는 대상은 모집단의 상수와 회귀계수임에 주의하자.

회귀계수와 상수의 유의성 검정

- 우리는 모집단에서 수많은 표본을 뽑아 그로부터 상수 b_0와 회귀계수 b_1를 추정한 뒤, 이것들의 표집분포를 구축해 볼 수 있다.
- 우리는 (1) 표본회귀모형 $y = b_0 + b_1 X + e$에 대해 정규성(normality)을 가정하거나 (2) 중심극한정리(central limit theorem)에 힘입어 아래 다음을 알 수 있다.

$$\beta_0 = E(\widehat{b_0})$$
$$\beta_1 = E(\widehat{b_1})$$

- 이제 (상수항와 회귀계수의) 표집분포의 표준편차를 표준오차(standard error)라고 부를 수 있다.

회귀계수와 상수의 유의성 검정

- (b_1 와 b_0 의) 표준오차는 추정값(estimates)에 대해 얼마나 확신하는가(confident)를 보여준다.

$$SE_{\widehat{b}} = \sqrt{\frac{\sum(Y_i - \widehat{Y}_i)^2/(n-2)}{\sum(X_i - \bar{X})^2}} = \sqrt{\frac{\sigma_e^2}{\sum(X_i - \bar{X})^2}}$$

- 제곱을 잠깐 제쳐놓고 보면, 분자는 오차의 분산이다!
- 분모는 독립변수의 편차제곱이다. 독립변수 X_i 의 분산이 작으면 회귀계수의 표준오차 SE_b 가 커지므로 b는 믿을 수 없게(unreliable) 된다.

회귀계수와 상수의 유의성 검정

t 분포를 사용하여 회귀계수와 상수에 대한 유의성 검정을 수행한다.

- 주어진 표본에서 회귀분석으로 추정된 회귀계수 $\widehat{b}_1$ 의 t 값은 아래와 같다.

$$t = \frac{\widehat{b}_1 - \beta_1}{SE_{b_1}} = \frac{\widehat{b}_1}{SE_{b_1}}$$

- 이때 t 분포의 자유도는 (상수와 회귀계수를 포함하여) $n-2$이다.
- 귀무가설이 옳다는 전제 아래 그린 표집분포는 t 분포한다. 표본에서 추정된 검정통계량 t 값의 위치를 확인해보고 그보다 극단적인 t 값을 얻게 될 확률, 즉 유의확률(p-value)을 계산할 수 있다.
- 만일 유의확률이 0.05보다 작다면 우리는 5% 유의수준 또는 95% 신뢰수준에서 귀무가설($H_0 : \beta_1 = 0$)을 기각하고 대립가설($H_a : \beta_1 \neq 0$)을 채택할 수 있다.

회귀계수와 상수의 유의성 검정

연습 2. CONSUMPTION.CSV 파일은 2000년-2016년 사이 분기별 미국인의 경제자료를 담고 있다. 이 자료를 SPSS로 불러들여 가처분소득(income)이 한 단위 증가할 때, 소비(consumption)가 얼마만큼 변화하는지를 나타내는 한계소비성향(marginal propensity to consume)을 추정하시오.

다중회귀모형

다중회귀모형

실제 업무나 연구에서는 다중회귀모형을 사용한다!

- 단순회귀모형(simple regression model)에서는 오로지 독립변수 X와 종속변수 Y, 딱 두 개의 변수만 고려하였다.

$$y_i = \beta_0 + \beta_1 X_i + \epsilon_i$$

- 반면, (종속변수는 여전히 1개지만) 모형 안에 k개의 독립변수가 투입된 경우를 다중회귀모형(multiple regression model)이라고 부른다.

$$y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \ldots + \beta_k X_{ki} + \epsilon_i$$

- k개의 독립변수를 모형에 투입했다면 여러 영향력은 각각에 해당되는 변수 안으로 나뉘어 흡수된다. 그러므로 다중회귀분석은 (다른 변수의 영향력으로부터 독립된) 특정 변수의 순효과(net effect) 또는 부분효과(partial effect)를 살펴보는데 유리하다.

다중회귀모형

- 가령 임금(ln_wage)을 종속변수로, 나이(age)와 교육연수(educ)를 독립변수로 하는 회귀모형을 세웠다고 하자.

$$ln_wage = b_0 + b_1 age + b_2 educ + e$$

- 다중회귀분석을 통해 "나이(age)의 효과를 통제했을 때(즉 같은 나이일 때)" 교육연수(educ)가 한 단위 변화하면 임금(ln_wage)이 얼마만큼 변화하는지 살펴볼 수 있다.

다중회귀모형

연습 3. MCAS.SAV 파일을 SPSS로 불러들여 (메사추세츠 주의 224개 학군별로 수집된) 학생 대 교사 비율, 교사의 평균 연봉, 가계소득 중앙값, 한부모가계 비율이 학업성취도 평균점수(MCAS)와 어떤 연관성을 맺고 있는지 회귀분석을 수행하고 회귀계수 및 유의성 검정 결과를 해석하시오.

다중회귀모형

다중회귀분석을 수행할 때는 (여러 변수를 사용하는 만큼) 변수의 사전 체크에 주의를 기울여야 한다.

- 여러 개의 독립변수를 모형에 한꺼번에 투입하다보면 하나하나를 꼼꼼하게 살펴보지 않고 그냥 대충 집어넣는 경우가 많다. 이것은 매우 위험하다!
- 개별 변수의 척도가 어떻게 구성되어 있는지, 분포는 어떠한지, 결측치가 있는지 등을 반드시 꼼꼼하게 살펴보아야 한다.
- 이러한 자료 전처리(data pre-processing) 과정은 대체로 지루하지만 꼭 필요하므로 산업인력 수요가 크다.