사회통계연습

모형의 적합도와 결과표 작성

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

November 11, 2022

진행 순서

1. 모형의 적합도
2. 결과표 작성

모형의 적합도

모형의 적합도

개발한 회귀모형이 현실 자료에 얼마나 적합한지 살펴보아야 한다.

- 우리가 모형을 세워 그것을 현실 자료에 맞추어(fit) 본 이상, 이것이 얼마나 잘 맞는가를 말할 수 있어야 한다. 이것이 모형의 적합도(goodness-of-fit)이다.
- 우리는 여러가지 적합도 지표 가운데 결정계수(coefficient of determination)와 분산분석만 공부한다.

모형의 적합도

먼저 결정계수를 살펴보자.

- 주어진 자료에 전체 변량(total variation)이 있다면, 이것은 (모형에 의해) 설명된 변량(explained variation)과 (그렇지 못하고) 남은 변량(residual variation)의 합이라고 분해될 수 있다.

$$\sigma^2_{total} = \sigma^2_{explained} + \sigma^2_{residual}$$

- 그렇다면 설명된 변량 $\sigma^2_{explained}$와 전체 변량 σ^2_{total}의 비율은 모형의 높은 설명력을 의미한다고 볼 수 있다.

$$R^2 = \frac{\sigma^2_{explained}}{\sigma^2_{total}} = 1 - \frac{\sigma^2_{residual}}{\sigma^2_{total}}$$

- 이것이 바로 결정계수 R^2의 직관적 의미이다. 설명된 변량과 전체 변량의 비율이므로 0과 1사이에 놓인다. 1에 가까울수록 모형은 높은 적합도를 보인다고 할 수 있다.

모형의 적합도

독립변수 X가 없을 때 종속변수 Y를 가장 잘 예측하는 요소는 무엇일까?

- 이 질문은 생각보다 매우 중요하다! 그것은 바로 종속변수의 평균 $\bar{Y}$이다(Why?). 우리는 사실 학기 초에 중심성향(central tendency)에 관해 공부하면서 이것을 은근슬쩍 배웠다.
- 이 원리는 우리에게 다음과 같은 중요한 원칙 하나를 제공한다.

  "어떤 모형을 세우던지 최소한 종속변수의 평균 $\bar{Y}$보다는 나은 설명력을 보여야 한다."
- 종속변수의 평균 $\bar{Y}$는 일종의 기준점이자 최소한의 바닥이다. 이것보다도 못한 모형은 아무런 가치도 없다(Why?).
- 한편 종속변수의 실제 값 Y_i는 일종의 천장과도 같다. 이것은 모형이 추구할 수 있는 최고의 이상(ideal)이기 때문이다.
- (직관적으로 설명한다면) 당연히 모형의 예측값 $\widehat{Y}_i$는 Y_i와 $\bar{Y}$ 사이 어딘가 놓이리라 생각할 수 있다(실제로는 꼭 그렇지 않을수도 있지만 너무 신경쓰지 말자).

모형의 적합도

- 그림을 통해서 우리는 다시 한 번 전체 변량이 잔여 변량과 설명된 변량의 합임을 직관적으로 이해할 수 있다.

$$(Y_i - \bar{Y}) = (Y_i - \widehat{Y}_i) + (\widehat{Y}_i - \bar{Y})$$

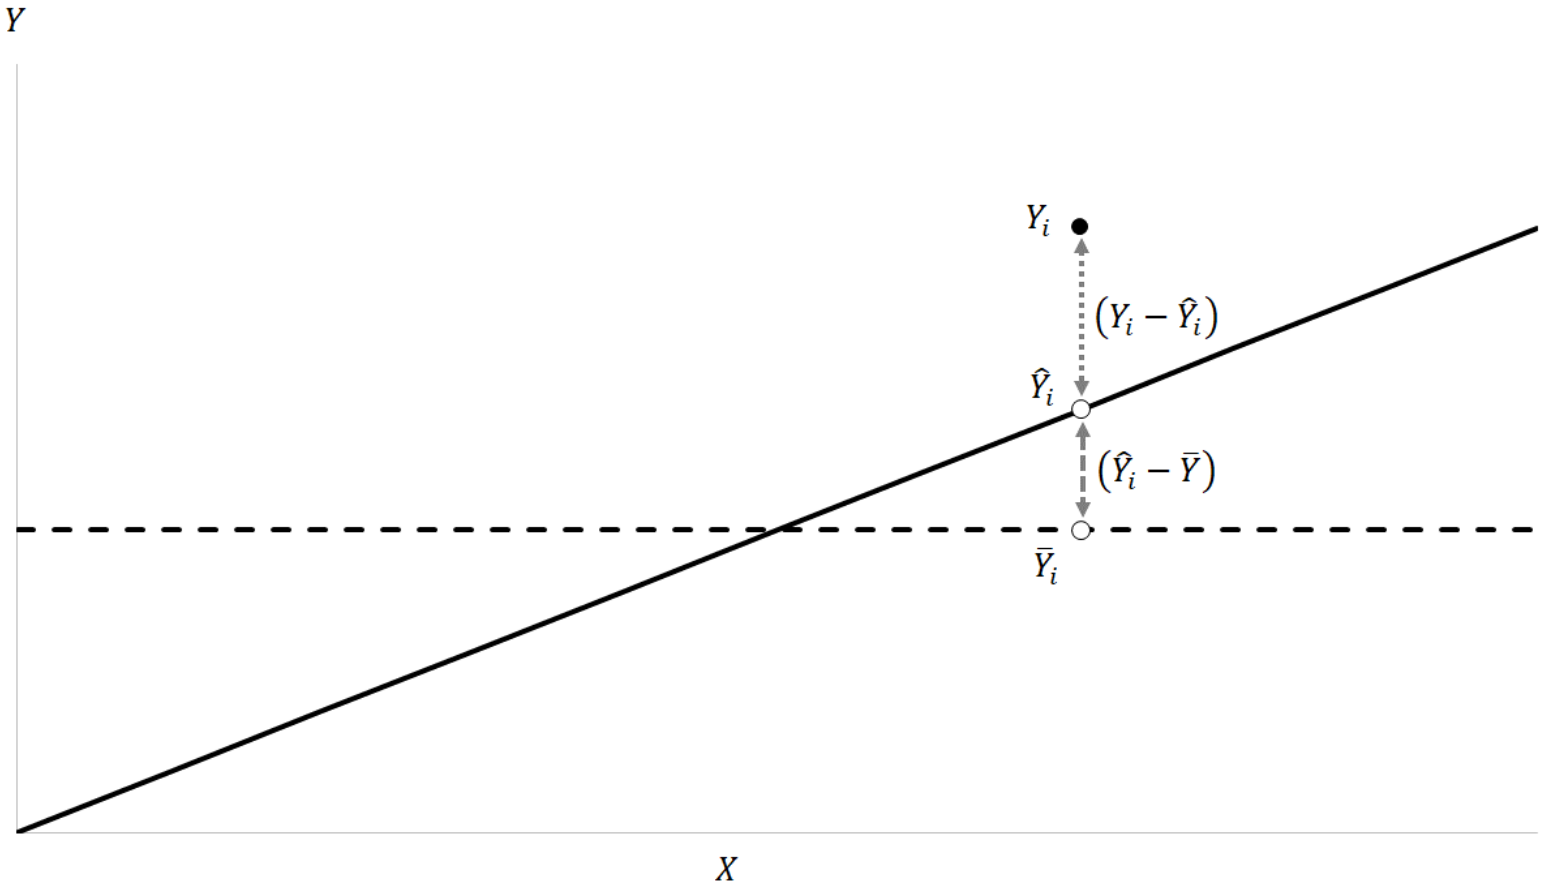

모형의 적합도

- 우리는 이제 제곱합(Sum of Squares; SS) 개념을 가지고 다음의 공식에 도달할 수 있다(증명 생략).

$$\sum(Y_i - \bar{Y})^2 = \sum(Y_i - \widehat{Y}_i)^2 + \sum(\widehat{Y}_i - \bar{Y})^2$$
$$SS_{total} = SS_{residual} \quad + SS_{explained}$$

- 이제 결정계수 R^2를 측정할 수 있다.

$$R^2 = \frac{SS_{explained}}{SS_{total}} = \frac{\sum(\widehat{Y}_i - \bar{Y})^2}{\sum(Y - \bar{Y})^2}$$
$$= 1 - \frac{SS_{residual}}{SS_{total}} = 1 - \frac{\sum(Y_i - \widehat{Y}_i)^2}{\sum(Y_i - \bar{Y})^2}$$

- 아까 그림을 통해 되새겨보면, Y_i에 더 가까운 위치에 $\widehat{Y}_i$가 놓일수록 R^2 역시 높으리라고 추측할 수 있다.

모형의 적합도

연습 4. CAR_PRICES.SAV 파일을 SPSS로 불러들여 중고차 가격(Price)을 차량의 연식(Age)으로 설명하시오. 이후 추가적으로 주행거리(Miles)를 독립변수로 추가하였을 때 모형 적합도의 개선 여부를 판단하시오.

모형의 적합도

모형 적합도 판정은 상당히 정형화되어 있다.

- "차량의 연식만을 고려한 회귀모형으로도 중고차 가격 변량의 83%를 설명한다."
- "차량 연식과 주행거리를 추가하였을 때, 이 회귀모형은 중고차 가격 변량의 84.6%를 설명한다."
- 변수를 하나 추가하였지만 통계적으로 유의하지도 않고 R는 겨우 1.6% 증가했을 뿐이다.
- 바로 아래 조정된 결정계수(adjusted R^2)는 무엇인가? 기본적으로 결정계수는 보다 많은 독립변수를 집어넣을 때 무제한적으로 팽창하는 성향이 있다. 그런데 이것은 오캄의 면도날 원칙(Occam's Razor)에 반하는 것이므로, 독립변수를 추가적으로 집어넣을 때마다 적절한 패널티를 가할 필요가 있다.
- 조정된 결정계수는 바로 이렇게 패널티가 가해진 결정계수이다.

모형의 적합도

분산분석 결과표 역시 모형 전체의 적합도를 보여준다.

- 아래와 같이 선형모형을 설정하였을 때 최악의 추정 결과는 무엇일까?

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_2 + \beta_3 X_3 + \epsilon_i$$

- 그건 (상수 빼고) 모든 회귀계수가 0이 되는 상황이다. 보다 구체적으로 말해서 "모집단에서 (상수 빼고) 모든 β가 0인 상황"이다.
- 제대로 된 모형이라면 최소한 이런 경우는 부정할 수 있어야 한다. 만일 이런 상황을 부정할 수 없다면 "이 모형은 완전히 쓸모없다" 라는 말을 부정할 수 없는 것이나 마찬가지이기 때문이다.

모형의 적합도

- 그러므로 다음과 같은 가설구조를 검증해 볼 수 있다.

$$H_0 : \beta_1 = \beta_2 = \beta_3 = 0$$
$$H_a : (\beta_1 \neq 0) \text{ or } (\beta_2 \neq 0) \text{ or } (\beta_3 \neq 0)$$

- 이 가설구조를 테스트할 수 있는 방법은 일원분산분석(one-way ANOVA)이다.

모형의 적합도

- 제6주차 때 연습한 일원분산분석의 검정통계량 F 값은 다음과 같았다.

$$F_{(k-1,n-k)} = \frac{\sigma^2_{between}}{\sigma^2_{within}} = \frac{MS_{between}}{MS_{within}} = \frac{SS_{between}/(k-1)}{SS_{within}/(n-k)}$$

- 다중회귀분석의 맥락에서 검정통계량 F 값은 다음과 같다. 단 k는 독립변수의 수를 의미한다.

$$F_{(k,n-k-1)} = \frac{\sigma^2_{explained}}{\sigma^2_{residual}} = \frac{MS_{explained}}{MS_{residual}} = \frac{SS_{explained}/k}{SS_{residual}/(n-k-1)}$$

- F 값이 클수록 유의확률(p-value)이 작아지므로 위 귀무가설을 기각할 수 있다.

모형의 적합도

- 분산분석표 안에 채워진 숫자는 다음과 같은 의미이다(교재 272).

Variance	SS	df	MS	F
Explained	$SS_{explained} = \sum(\widehat{Y}_i - \bar{Y})^2$	k	$MS_{explained}$	F
Residual	$SS_{residual} = \sum(Y_i - \widehat{Y}_i)^2$	$n-k-1$	$MS_{residual}$	
Total	$SS_{total} = \sum(Y_i - \bar{Y})^2$	$n-1$	MS_{total}	

- SPSS에서는 Explained 대신에 Regression으로 표기하고 있다.
- 계산을 직접 하는데 집착하기 보다는 그 논리 전개에 주목하여 공부하자.

모형의 적합도

이제 CAR_PRICES.SAV 자료의 회귀분석 결과에서 ANOVA표를 이해할 수 있다!

- F 값은 46.835이고 유의확률(Sig.)은 0.000이므로 0.05보다 당연히 작다. 그러므로 99.9% 신뢰수준에서 다음의 귀무가설을 기각할 수 있다.

$$H_0 : \beta_{Age} = \beta_{Miles} = 0$$

- 우리는 "모든 회귀계수가 0이다"라는 귀무가설을 기각하고 "최소한 하나의 회귀계수는 0이 아니다"라는 대립가설을 채택할 수 있었다. 다행이다~

결과표 작성

결과표 작성

회귀분석을 수행하고나서 그 결과물을 표로 정리하여 보고해야 한다.

- 김성훈·우명숙(2020)을 참고로 어떤 표들이 필요한지 살펴보자!
- 최종적으로 사용한 변수의 목록을 잘 정리하여 표로 정리했음을 기억하자.
- 회귀분석의 결과표가 어떤 식으로 이루어졌는지 잘 흉내내어 만들어보아야 한다.

결과표 작성

연습 5. eCampus에서 2021년 사회통합실태조사 원자료를 다운로드하시오. 설문지와 원자료를 불러와 자신만의 종속변수를 신중하게 선택 또는 재구성하시오. 이 변수를 설명 및 예측하기 위한 독립변수를 세 개 선택 또는 재구성하여 다중회귀분석을 수행하시오. 김성훈·우명숙 (2020)을 흉내내어 회귀분석의 결과표를 작성하고 그 해석을 적절히 제시하시오.