사회통계연습
가변수의 활용

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

November 18, 2022

진행 순서

1. 지난 주 리뷰
2. 가변수

지난 주 리뷰

지난 주 리뷰

1. 위 종속변수들을 설명하기 위하여 우리나라 17개 주요기관에 대한 신뢰도(q35_1에서 q35_17까지)의 합성지수를 독립변수로 하는 단순회귀분석을 각각 수행하시오. 이때 적절한 가설을 함께 제시하고, 김성훈·우명숙(2020)을 참고로 회귀분석의 결과표 및 시각화 또한 제시하시오. 그 해석을 적절히 제시하시오. (40점)

지난 주 리뷰

- (1) 살고 있는 동네(시군구)의 안전성에 대한 인식과 (2) 살고 있는 동네(읍면동)의 안전성에 대한 인식이 두 개의 종속변수이다.
- 우리나라 17개 주요기관에 대한 신뢰도의 합성지수를 독립변수로 한다.
- 이 합성지수의 크론바흐 알파는 약 .92 정도이므로 매우 양호하다.
- 회귀계수 및 상수에 대한 가설은 다음과 같다.

$$H_0 : \beta_0 = 0 \qquad H_a : \beta_0 \neq 0 \qquad \text{(상수의 경우)}$$
$$H_0 : \beta_1 = 0 \qquad H_a : \beta_1 \neq 0 \qquad \text{(회귀계수의 경우)}$$

지난 주 리뷰

	시군구		읍면동	
	모형1	모형2	모형3	모형4
주요기관 신뢰도	0.0214*	0.0184*	0.0183*	0.0155*
	(0.002)	(0.002)	(0.002)	(0.002)
사회적 지위		0.328*		0.307*
		(0.009)		(0.009)
상수	5.519*	3.774*	5.770*	4.137*
	(0.077)	(0.087)	(0.076)	(0.086)
사례수	8077	8077	8077	8077
결정계수	0.018	0.150	0.014	0.133
주석: 괄호 안에 표준오차. * p<0.001				

지난 주 리뷰

- 살고 있는 동네(시군구)의 안전성에 대한 인식의 추정된 회귀식은 다음과 같다.

$$E(Y|X) = 0.021 \cdot X + 5.519$$

- 우리나라 17개 주요기관에 대한 신뢰도가 한 단위 증가할수록 살고 있는 동네(시군구)의 안정성에 대한 인식은 0.021만큼 증가한다.
- 우리나라 17개 주요기관에 대한 신뢰도가 0일 경우 살고 있는 동네(시군구)의 안정성에 대한 인식은 5.519이다.
- 결정계수를 살펴보면 우리나라 17개 주요기관에 대한 신뢰의 분산은 살고 있는 동네(시군구)의 안전 인식 분산의 1.8% 정도를 설명한다.

지난 주 리뷰

- 살고 있는 동네(읍면동)의 안전성에 대한 인식의 추정된 회귀식은 다음과 같다.

$$E(Y|X) = 0.018 \cdot X + 5.77$$

- 우리나라 17개 주요기관에 대한 신뢰도가 한 단위 증가할수록 살고 있는 동네(읍면동)의 안정성에 대한 인식은 0.018점만큼 증가한다.
- 우리나라 17개 주요기관에 대한 신뢰도가 0일 경우 살고 있는 동네(읍면동)의 안정성에 대한 인식은 5.77점이다.
- 결정계수를 살펴보면 우리나라 17개 주요기관에 대한 신뢰의 분산은 살고 있는 동네(읍면동)의 안전 인식 분산의 1.4% 정도를 설명한다.

지난 주 리뷰

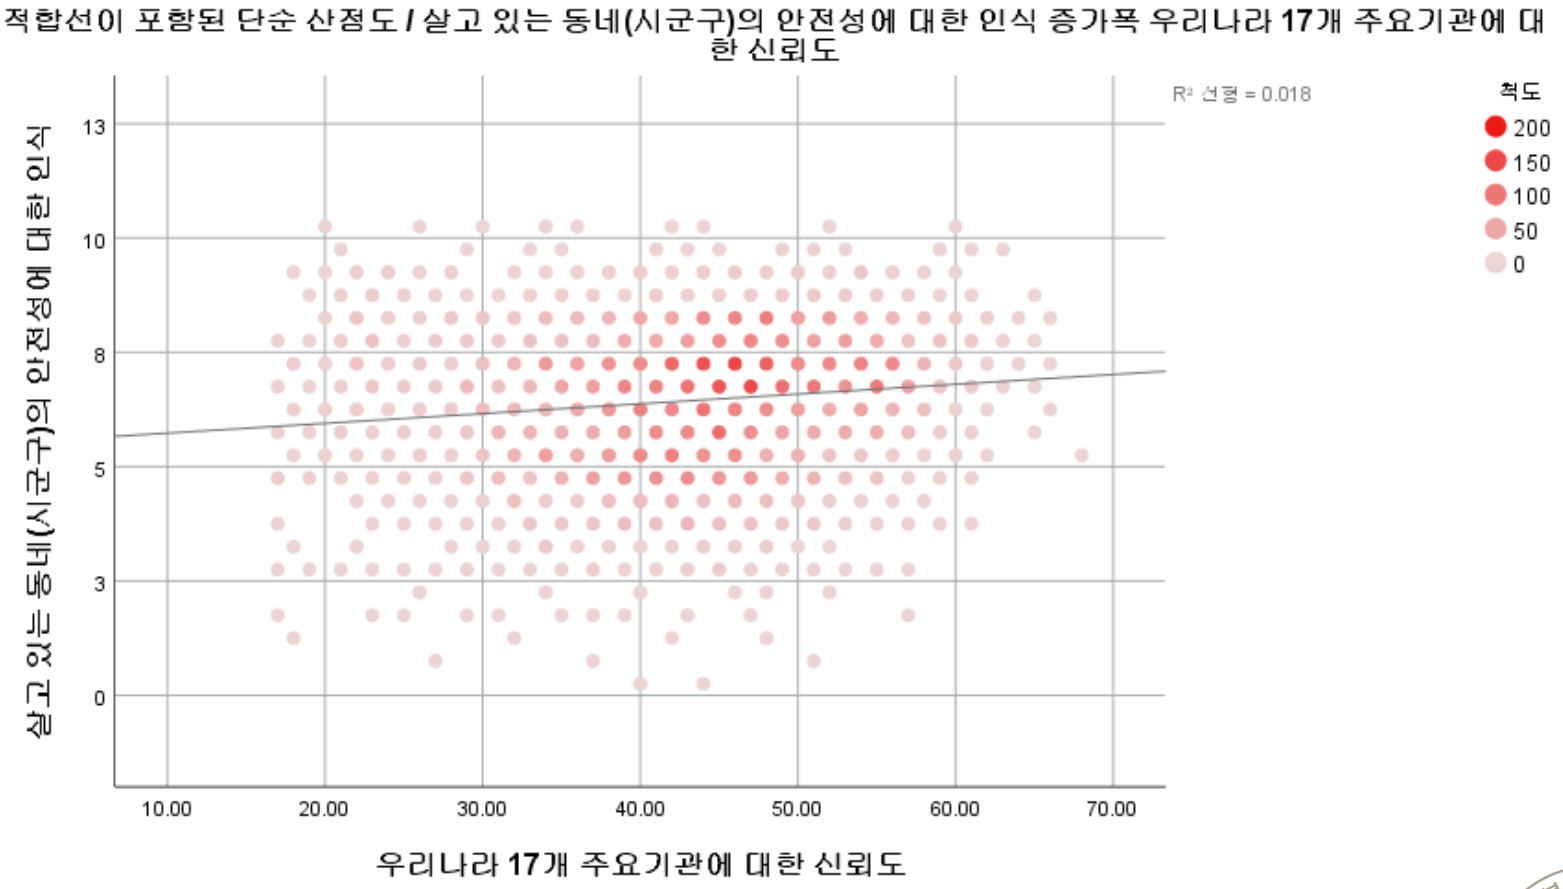
적합선이 포함된 단순 산점도 / 살고 있는 동네(시군구)의 안전성에 대한 인식 증가폭 우리나라 17개 주요기관에 대한 신뢰도
R² 선형 = 0.018
척도
200
150
100
50
0
13
10
8
5
3
0
10.00
20.00
30.00
40.00
50.00
60.00
70.00
살고 있는 동네(시군구)의 안전성에 대한 인식
우리나라 17개 주요기관에 대한 신뢰도

지난 주 리뷰

2. 그 다음에는 자신의 사회적 지위에 대한 인식(q4)을 추가적인 독립변수로 고려하는 다중회귀분석을 각각 수행하시오. 마찬가지로 적절한 가설을 함께 제시하고, 결과표 또한 작성하시오. 모형의 적합도 개선 여부에 대해 논하시오. (60점)

지난 주 리뷰

- 회귀계수 및 상수에 대한 가설은 다음과 같다.

$$H_0 : \beta_0 = 0 \qquad H_a : \beta_0 \neq 0 \qquad \text{(상수의 경우)}$$
$$H_0 : \beta_1 = 0 \qquad H_a : \beta_1 \neq 0 \qquad \text{(주요기관 신뢰 회귀계수의 경우)}$$
$$H_0 : \beta_2 = 0 \qquad H_a : \beta_2 \neq 0 \qquad \text{(사회적 지위 회귀계수의 경우)}$$

- 추정된 회귀식은 다음과 같다(이때 X_1는 주요기관 신뢰, X_2는 사회적 지위 변수임).

$$E(Y|X) = 0.018X_1 + 0.328X_2 + 3.774 \qquad \text{(시군구의 경우)}$$
$$E(Y|X) = 0.015X_1 + 0.307X_2 + 4.137 \qquad \text{(읍면동의 경우)}$$

지난 주 리뷰

- "주요기관에 대한 신뢰를 통제하였을 때, 사회적 지위가 1점 증가하면 시군구 동네의 안전성 인식은 0.328점 증가한다."
- 해석은 무척 주의해야 한다. 특히 다른 변수를 통제에 관한 언급이 명시적으로 없으면 무조건 감점이다!
- "주요기관에 대한 신뢰와 사회적 지위가 모두 0점일 때, 인식된 시군구 동네의 안전성 인식은 3.77점이다."
- 상수 해석도 주의해야 한다. 많은 연습이 없으면 반드시 점수를 잃는다!

지난 주 리뷰

- 결정계수를 살펴보면 우리나라 17개 주요기관에 대한 신뢰도와 자신의 사회적 지위에 대한 인식의 분산은 살고 있는 동네(시군구)의 안정성에 대한 인식 분산의 15%를 설명한다.
- 우리나라 17개 주요기관에 대한 신뢰도와 자신의 사회적 지위에 대한 인식의 분산은 살고 있는 동네(읍면동)의 안정성에 대한 인식의 분산의 13.3% 를 설명한다.
- 자신의 사회적 지위에 대한 인식 독립변수가 추가되면서 모형 적합도가 대폭 개선되었다!

지난 주 리뷰

총평

- 산점도를 잘 나타내야 한다(투명화 또는 덜덜떨기 등의 기법을 활용할 것).
- 다중회귀분석을 수행할 때, 모든 변수에 대해 산점도를 하나하나 그릴 필요는 없다. 그러나 가장 중요한 독립변수와 종속변수의 관계를 나타내는 산점도 하나 정도는 그려볼 수 있다.
- 퍼센트를 잘 해석하자(가령 0.018은 1.8%이지 18%가 아니다).
- 사소한 것에서 실수가 대단히 잦다. 꼼꼼히 살피고 재검토할 것. 이걸로 점수를 잃는다.
- 가설을 세웠다면 기각 여부 또한 반드시 밝혀야 한다.

가변수

가변수

회귀분석에서 질적변수는 다룰 수 없는 걸까?

- 지금까지 회귀분석에서는 등간(interval) 또는 비율(ratio) 척도로 이루어진 양적변수만 고려하였다.
- 그 해석은 "X가 한 단위 증가할 때, Y는 β만큼 증가(또는 감소)한다"와 같았다.
- 그러나 명목(nominal) 또는 서열(ordinal) 척도와 같은 질적변수(qualitative variable)를 분석할 수는 없는 것일까?

가변수

- 이 질문에는 사실 두 가지 측면이 담겨져 있으므로 나누어 살펴보아야 한다.
- 첫째, 종속변수가 질적 변수라면 어떨까? 대답은 “할 수 있다” 이다.
- 다만 학부 수준에서 배우는 단순최소자승(OLS) 알고리즘으로는 그런 경우를 분석하는데 한계가 있고, 원칙적으로는 대학원 수준의 범주형 자료분석(categorical data analysis)을 공부해야 한다(그러나 우리는 나중에 한다!).
- 가령 노조원 신분(1=노조가입; 2=미가입) 또는 주관적 행복도(1=불행함; 2=보통임; 3=행복함) 등도 종속변수로 삼아 회귀분석할 수 있다.

가변수

회귀분석에서도 질적 차이를 부각시켜 해석할 수 있다!

- 둘째, 독립변수가 질적 변수라면 어떨까? 이때도 대답은 “할 수 있다” 이다.
- 게다가 단순최소자승(OLS) 알고리즘까지도 평범하게 사용할 수 있다!
- 다만 회귀식에 질적변수를 그대로 투입해서는 안된다(Why?). 질적변수의 회귀계수를 한 번 해석해보자.

가변수

회귀분석에서 사용하려면 질적변수는 먼저 가변수로 바꾸어야 한다.

- 인종(1=백인; 2=흑인; ...), 종교(0=없음; 1=기독교; 2=불교; ...), 리커트(Likert) 척도로 측정된 만족도(1=매우 불만족; 2=다소 불만족; 3=다소 만족; 4=매우 만족) 등은 원칙적으로 모두 질적변수로 분류될 수 있다.
- 이런 변수들은 그대로 회귀분석에서 독립변수로 사용할 수 없다. 해석이 안되기 때문이다.
- 그런데 경우에 따라서 리커트 척도만큼은 그대로 사용하기도 한다(Why?).
- 질적변수들은 일단 가변수(dummy variable)로 바꾸어야 해석할 수 있게 된다.

가변수

- 가변수란 처방, 조건, 또는 상황 등이 존재하면(present) 1로, 그것이 부재하면(absent) 0으로 더미 코딩(dummy coding)된 변수이다.
- 예를 들어, 처치(treatment)에 관한 가변수라면 '받았다(1)' 또는 '안받았다(0)' 중 하나의 값을 갖는다.
- "성별이 여성이다"에 관한 가변수라면 '여성이다(1)' 또는 '여성이 아니다(0)' 중 하나가 된다.
- 더미 코딩할 때 반드시 상호배타적(mutually-exclusive)이고 전체포괄적(all-inclusive)인 범주를 준비하고 적용해야만 한다.

가변수

회귀분석에서 가변수의 작동 원리와 해석은 매우 간단하다.

- 종속변수 Y가 쓰기 점수(write)인 단순회귀식을 다음과 같이 상정하자.

$$Y = \beta_0 + \beta_1 X$$

- X가 양적변수인 경우 해석은 다음과 같다:

  (1) "X가 한 단위 증가할 때 Y가 β_1만큼 변화한다."
  (2) "X가 0일 때, Y는 β_0와 같다."

- 독립변수 X가 가변수인 성별(1=여자; 0=남자)인 경우에 해석은 다음과 같다.

$$\widehat{Y}_{남} = \widehat{\beta}_0 \qquad (\text{if } X = 0)$$
$$\widehat{Y}_{여} = \widehat{\beta}_0 + \widehat{\beta}_1 \qquad (\text{if } X = 1)$$

- 남녀 간 $\widehat{Y}$의 쓰기 점수 격차는 $\widehat{Y}_{여} - \widehat{Y}_{남} = \widehat{\beta}_1$이다.
- 그런데 가변수의 회귀계수가 바로 $\widehat{\beta}_1$다!

가변수

가변수의 회귀계수는 곧장 남녀 간 차이를 말해준다.

- 남자를 지칭하는 가변수와 여자를 지칭하는 가변수를 따로 회귀모형에 투입할 필요는 없다. 그 정보는 중복된 것이기 때문이다(Why?).
- 중요한 것은 '회귀모형에 넣지 않은 가변수 쪽을 비교 대상으로 삼는다'는 사실이다 (Why?).
- 아래와 같이 회귀식이 추정된 경우에 가변수 해석은 다음과 같다.

$$Religiosity = 1.81 + 0.75Female$$

- "여자의 종교성 점수는 남자보다 0.75점 높다."
- "남자의 종교성 점수는 평균적으로 1.81점이다."

가변수

연습 1. HSB2.SAV 파일을 SPSS로 불러들여 쓰기 점수(write)를 종속변수로, 인종변수(race)를 독립변수로 하는 단순회귀분석을 실시하고 그 결과를 해석하시오.

가변수

연습 2. HSB2.SAV 파일을 SPSS로 불러들여 학교프로그램 유형(prog)을 종속변수로, 수학 점수(math)를 독립변수로 하는 단순회귀분석을 실시하고 그 결과를 해석하시오.

가변수

연습 3. galton.csv 파일을 SPSS로 불러들여 부모의 키로 본인의 키를 추정하는 회귀식을 구성하시오. 결과를 해석하시오. 본인의 성별을 추가하였을 때 결과를 해석하고 모형적합도가 개선되는지 여부 또한 평가하시오.