사회통계연습
가변수의 활용

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

November 25, 2022

진행 순서

1. 지난 주 리뷰
2. 질적 종속변수에 대한 선형회귀분석: 아이디어
3. 종속변수가 가변수인 경우

지난 주 리뷰

지난 주 리뷰

eCampus에서 2021년 통일의식조사 원자료와 설문지를 다운로드하시오. 당신은 통일 후 사회문제가 얼마나 개선될지 여부(uni09_01에서 uni09_06까지)를 설명하고자 한다.

1. 통일 후 사회문제가 얼마나 개선될지 여부를 하나의 합성지수로 구성하시오. 이 합성지수를 종속변수로 하고, 이를 설명하기 위하여 성별(d01), 연령(d02), 월평균 가구소득(d10_08_15), 조사지역 규모(d06)을 독립변수로 한 회귀분석을 수행하시오. 그 결과를 적절히 해석하시오. (40점)

지난 주 리뷰

- 종속변수인 통일 후 사회문제의 개선 정도를 역코딩하고 합성지수를 구성한다. 내적 일관성을 보고한다. 당연히 결측치 처리를 먼저 한다.
- 성별과 조사지역 규모는 각각 가변수와 범주형 변수이지만, 성별만 통계적으로 유의하므로 이를 적절히 해석한다. 기준집단을 명확히 해야 한다!
- (기준집단이 남성이라면) "다른 변수를 통제했을 때, 여성은 남성에 비해 평균적으로 통일 후 사회문제에 대한 개선 기대가 0.597만큼 낮다."
- (성별 기준집단은 남성 그리고 조사지역 규모 기준집단이 대도시라면) 여성, 0세, 월평균 가구소득 범주값이 0, 조사지역 규모는 대도시인 경우 통일 후 사회문제 개선 기대 평균점수는 15.48이다."

지난 주 리뷰

2. 그 다음, 위 모형에 추가하여 북한에 관련한 이해(nk07_01에서 nk07_08까지), 남북한 사회의 인지된 차이(nk09_01에서 nk09_10까지)까지도 독립변수로 살펴보는 회귀분석을 실시하시오. 그 결과를 적절히 해석하시오. (60점)

지난 주 리뷰

- 추가 독립변수인 (1) 북한에 대한 이해와 (2) 인지된 차이는 모두 역코딩하는 편이 바람직하다(Why?). 역코딩은 꼭 해야 하는 것은 아니지만 해석이 모호해지기 쉽고, 정말로 모호하게 썼으면 무조건 틀린다.
- "다른 변수를 통제했을 때, 남북한 사회의 인지된 차이가 한 단위 커질수록 통일 후 사회문제 개선 기대는 0.209점 씩 감소한다."
- 자기가 쓴 해석을 읽어보고 문장이 정말로 말이 되는지 고민해야 한다.

지난 주 리뷰

- 회귀분석 결과를 해석할 때는 지난 주에 설명한 체크리스트처럼 빠짐없이 보고해야 한다.
- 기준집단이 무엇인지 명확히 제시해야 한다. 만약 기준이 남성이라면 그 해석은 ‘’ 여성일 경우 남성에 비해 ..하다”라고 해야 한다.
- 만약 회귀식을 $E(Y|X) = 15.862 - 0.597X_1 + 0.007X_2 - 0.186X_3$와 같이 썼다면, 대체 X_1과 X_2, X_3가 어떤 변수를 뜻하는지 제시할 것.
- 필요에 따라 역코딩을 해야 하고, 변수의 값이 높아질수록 무엇을 의미하는 말하는지 항상 살피고 해석에 주의해야 한다.
- 리코딩이나 역코딩을 했다면 꼭 어떻게 했는지 제시해야 한다. “... 변수를 리코딩 했다”만 말하면 어떻게 리코딩했는지 알 수 없다. 리코딩 방식에 따라 해석이 매우 달라지므로 꼭 제시해줘야 한다.

지난 주 리뷰

- 유의성 검정 결과를 보고 해석할 필요가 있는 변수는 꼭 해석 해주어야 한다.
- 유의하지 않으면 해석할 필요가 없다!
- 해석에 중요한 결과표만 간결하게 제시할 것. 굳이 분석의 모든 과정을 첨부할 필요가 없다.

질적 종속변수에 대한 선형회귀분석: 아이디어

질적 종속변수에 대한 선형회귀분석: 아이디어

종속변수가 질적변수라면 회귀분석을 사용할 수 있을까?

- 지난 주 우리는 "회귀분석이 가능하긴 한데 보통최소제곱(OLS) 알고리즘으로는 곤란하다"고 배웠다.
- 그러나 이렇게 쉽게 포기하기엔 연구나 실무에서 이런 상황이 제법 흔하다. 가령,

  (1) "지난 대선 투표에 참여 여부(0=불참, 1=참여)를 설명할 수 있는 개인적 특성과 사회적 조건은 무엇인가?"
  (2) "여가활동의 종류(0=무관심형, 1=관람형, 2=참여형, 3=혼합형)를 예측할 수 있는 사회경제적 속성은 무엇인가?"
  (3) "소득수준은 주관적 행복도(1=매우 불행, 2=다소 불행, 3=불행하지도 행복하지도 않음, 4=다소 행복, 5=매우 행복)에 어떤 영향을 미칠까?"

- 결국 종속변수가 질적변수인 경우도 어떻게든 분석할 수 있어야 한다!

질적 종속변수에 대한 선형회귀분석: 아이디어

- 요약하면 종속변수가 질적변수라면 세 가지 시나리오를 다음과 같이 상정할 수 있다.

  (1) 종속변수가 가변수인 경우
  (2) 종속변수가 범주형 변수인 경우
  (3) 종속변수가 서열척도인 경우

- 내가 하려는 분석이 어떤 상황인지를 먼저 식별하고 적절한 방식을 선택해야 한다!
- 회귀분석 결과의 시각화 기법을 함께 학습하자!

종속변수가 가변수인 경우

종속변수가 가변수인 경우

종속변수가 가변수인 경우 그냥 OLS 회귀분석을 사용해 볼 수 있다.

- 만일 종속변수 Y가 가변수(0=투표 불참, 1=투표 참여)이고, 독립변수 X가 교육연수라면 다음의 회귀식은 어떤 의미를 가질까?

$$E(Y|X) = \widehat{\beta}_0 + \widehat{\beta}_1 X$$

- "교육연수 X가 한 해 증가할 때 투표 참여 여부 Y는 $\widehat{\beta}_1$ 만큼 증가(또는 감소)한다."
- "교육연수 X가 0일 때, 투표 참여 여부 Y는 $\widehat{\beta}_0$ 이다."
- 이상하게 들릴까? 사실 잘 따져보면 그렇지만도 않다!

종속변수가 가변수인 경우

왜냐하면 종속변수가 0 또는 1이라면 그것이 백분율처럼 해석될 수 있기 때문이다!

- 종속변수가 가변수라서 0 또는 1이 아니라, 이게 진짜 양적변수라서 0과 1 사이에 있는 어떤 백분율 값이라고 상상해보자. 그리고 다시 해석해보자.
- "교육연수 X가 한 해 증가할 때 투표 참여 확률 Y는 $\widehat{\beta}_1$ 만큼 증가(또는 감소)한다."
- "교육연수 X가 0일 때, 투표 참여 확률 Y는 $\widehat{\beta}_0$ 이다."
- 여기서는 "여부"가 아니라 "확률"로 바뀌었을 뿐인데, 해석이 자연스러워졌다.
- 사실 여부와 확률의 핵심적인 차이는 0과 1 사이에 어떤 값이 존재하는가에 달려있다.

종속변수가 가변수인 경우

- 종속변수가 가변수라서 사실 0과 1 사이에 어떤 값을 가질 수 없지만, 마치 그럴수 있는 것처럼 상정하는 접근방법을 선형확률모형(linear probability model)이라고 부른다.

$$E(Y|X) = P(Y = 1|X) = \widehat{\beta}_0 + \widehat{\beta}_1 X$$

- 해석할 때는 아까처럼 "여부" 대신 "확률"로 간다!

종속변수가 가변수인 경우

연습 1. lowbwt.sav 파일을 SPSS로 불러들여 엄마의 마지막 월경시 체중(lwt)을 독립변수로, 출생시 체중(bwt)을 종속변수로 한 회귀식을 추정하고 그 결과를 해석하시오. 다음으로 같은 독립변수를 사용하되, 저출생체중아 여부(low)를 종속변수로 한 별도의 회귀식을 추정하고 그 결과를 해석하시오. 두 모형을 비교하시오.

종속변수가 가변수인 경우

	모형 1 (OLS)		모형 2 (OLS)	
	bwt		low	
엄마의 마지막 생리전 체중	4.430*	(1.713)	-0.003*	(0.001)
상수	2369.2***	(228.5)	0.646***	(0.146)
F	6.686*		5.524*	
결정계수	0.0345		0.0287	
사례수	189			
노트: 괄호 안에 표준오차. * p<0.05, ** p<0.01, *** p<0.001.				

지난 주 리뷰

- 먼저 bwt를 종속변수로, lwt를 독립변수로 삼아 OLS 회귀분석을 수행한다.
- "엄마의 체중이 1 파운드 증가하면 아이의 출생시 체중이 4.43g 증가하고, 이는 95% 신뢰수준에서 통계적으로 유의하다."
- 다음으로 low를 종속변수로, lwt를 독립변수로 삼아 OLS 회귀분석을 수행한다 (선형확률모형).
- "엄마의 체중이 1 파운드 증가하면 아이의 출생시 저체중일 확률이 0.3% 감소하고, 이는 95% 신뢰수준에서 통계적으로 유의하다."

종속변수가 가변수인 경우

- 우리에게 가장 이상적인 상황은 첫번째처럼 자료가 주어졌을 때이다.

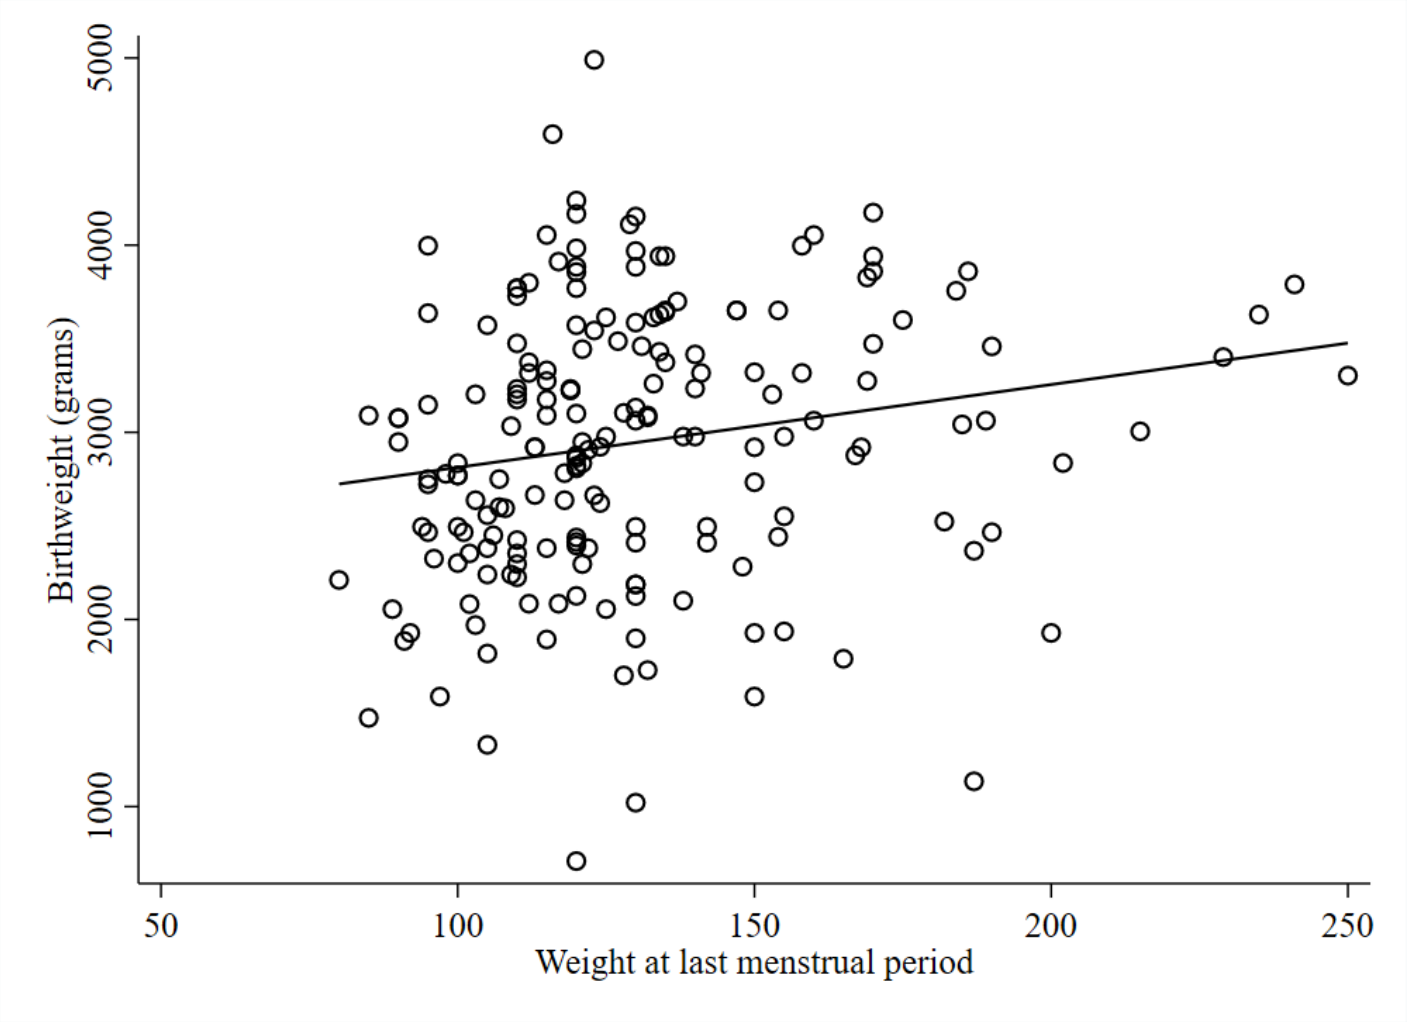

종속변수가 가변수인 경우

- 하지만 후자로 자료가 주어졌을 수도 있다. 두 변수의 관계는 다음과 같다.

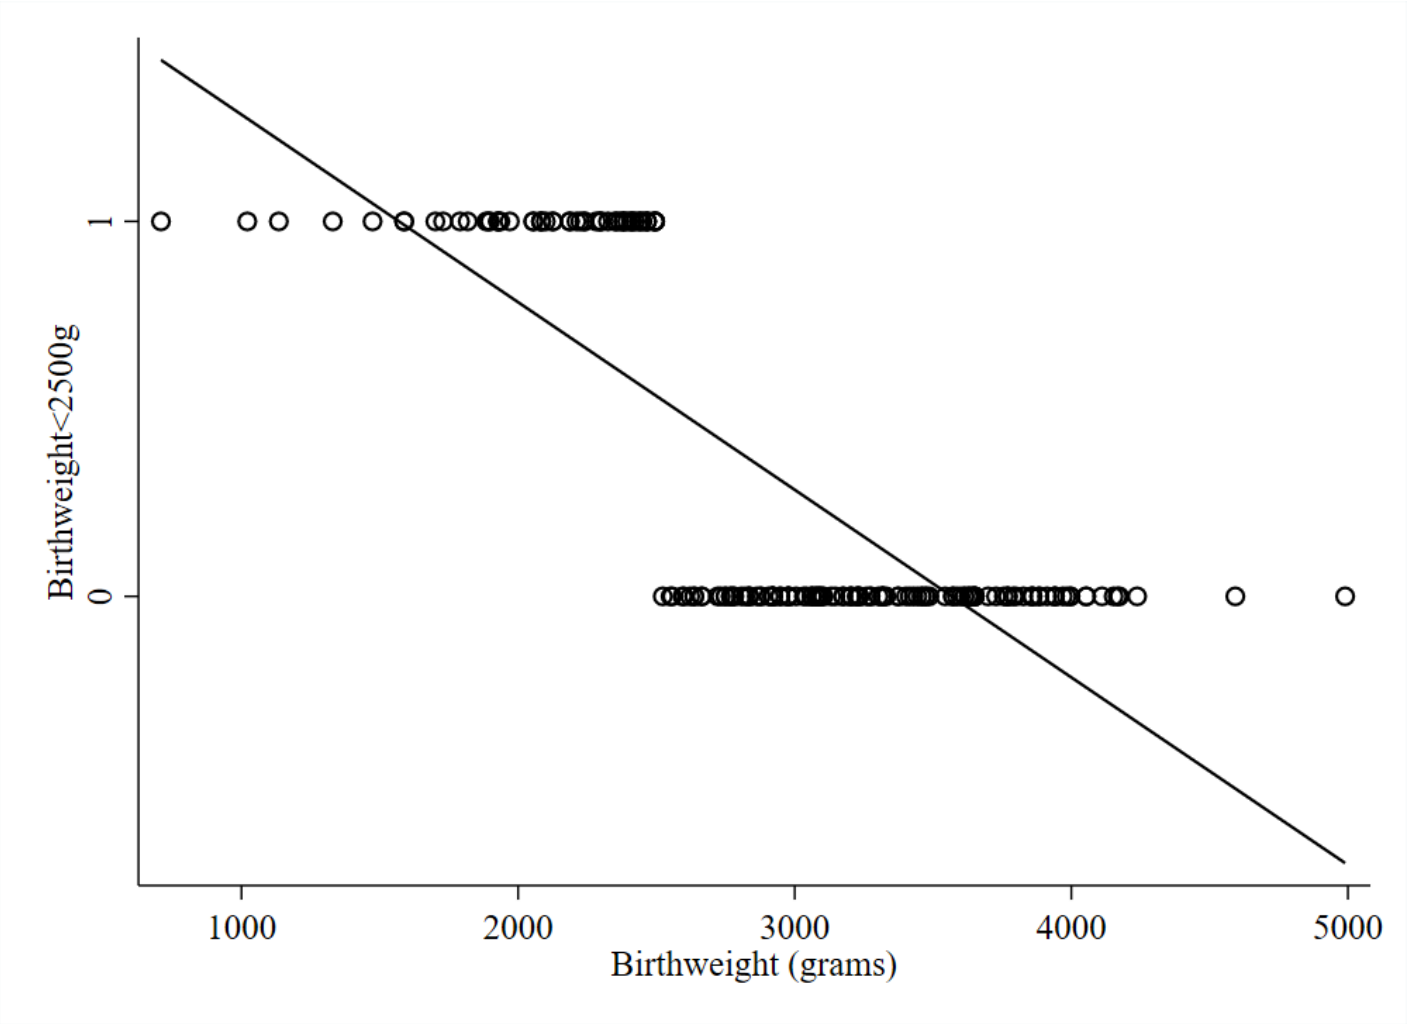

종속변수가 가변수인 경우

- 이때는 보통최소제곱(OLS)이 아니라 (우리가 배운 적 없는) 최대우도법(maximum likelihood estimation; MLE)을 통해 회귀계수와 상수를 추정해야 한다.
- 함부로 말하기는 조심스럽지만, (특수한 상황이 아니라면) OLS 알고리즘과 MLE 알고리즘의 추정량은 결국 비슷한 값을 갖는 경우가 많다.

종속변수가 가변수인 경우

- 선형확률모형을 해석할 때는 단순히 회귀식만 제시하기 보다 시각화하는 쪽을 추천한다(Why?).
- 시각화를 하려면 먼저 아래의 예측확률(predicted probability)을 계산해야 한다.

$$P(Y = 1|X) = \widehat{\beta}_0 + \widehat{\beta}_1 X$$

- 선형회귀분석을 실시하면서 "저장"에서 "비표준화 예측값"을 선택하여 $\widehat{Y}$을 새로 만들어 저장하자!
- 이제 엄마의 마지막 월경시 몸무게(lwt)와 $\widehat{Y}$의 연관성을 보여주는 산점도를 그려보자!

종속변수가 가변수인 경우

- OLS로 계산된 예측확률과 MLE로 계산된 예측확률 간 상관계수는 0.99이다.

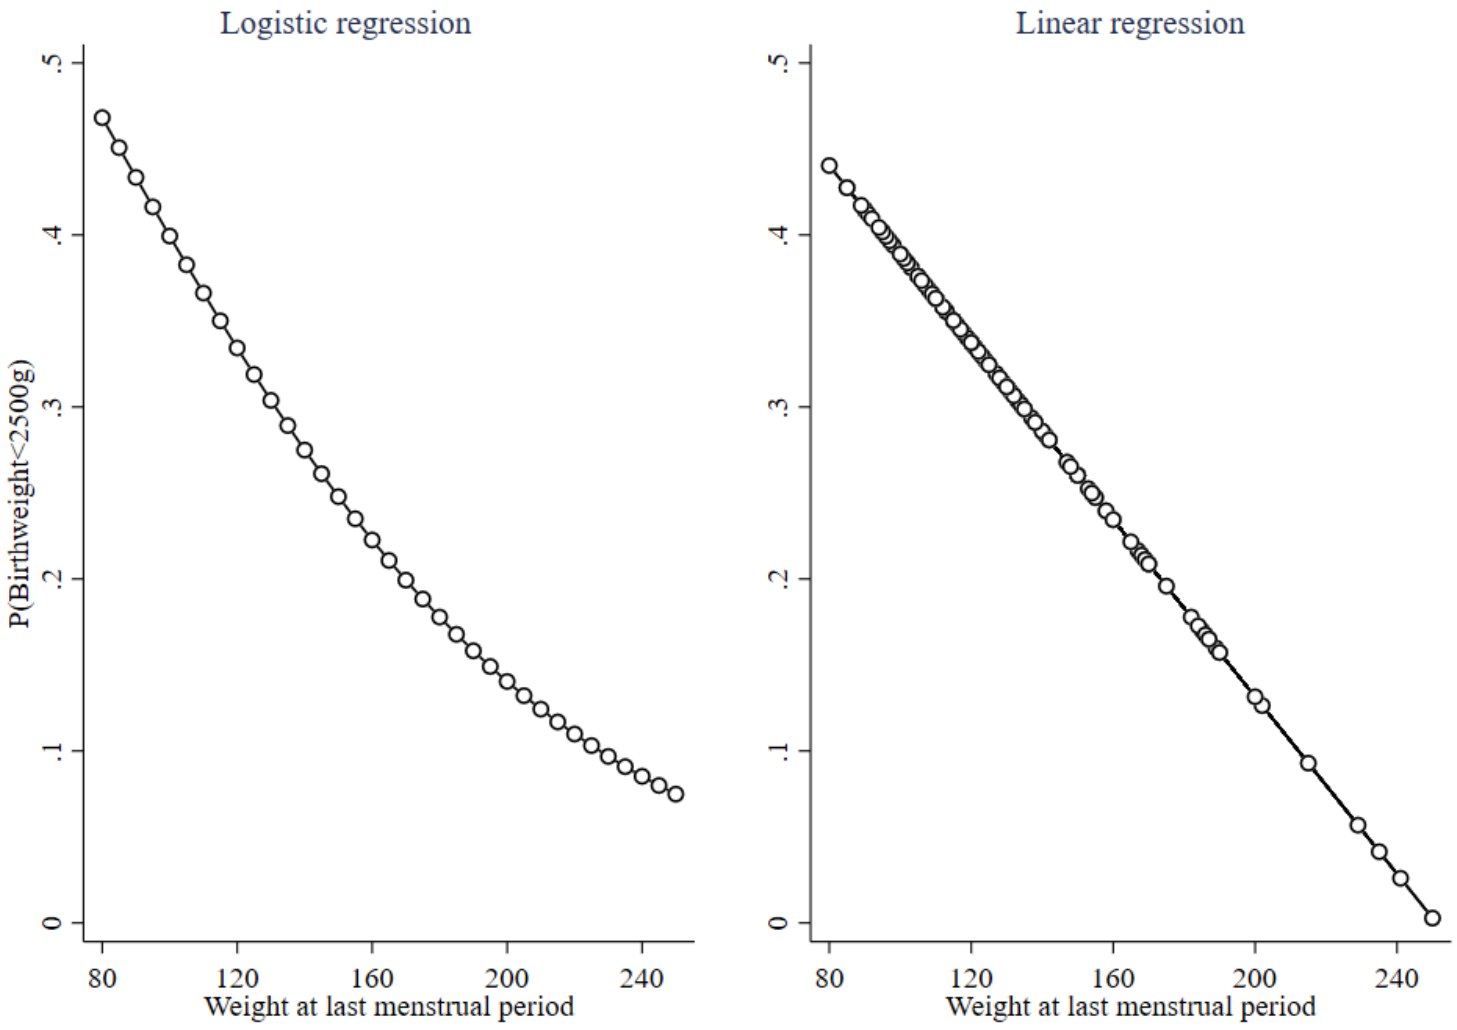

종속변수가 가변수인 경우

연습 2. lowbwt.sav 파일을 SPSS로 불러들여 저출생체중아 여부(low)를 종속변수로 하고, 산모연령(age), 임신중 흡연 여부(smoke), 고혈압(ht), 자극성 자궁(ui), 엄마의 마지막 월경시 체중(lwt), 인종(race), 미숙아 출산력(ptl) 그리고 산과 방문수(ftv)를 독립변수로 하는 회귀식을 추정하고 그 결과를 해석하시오. 인종에 따른 저출생체중아 출산확률을 시각화하시오.

종속변수가 가변수인 경우

- 우리가 관심을 가진 독립변수(independent variable of interest)는 범주형 변수이므로 가변수로 바꾸어 회귀분석을 수행해야 한다.
- 그런데 가변수이므로 아까처럼 산점도와 적합선을 그릴 수는 없다(Why?).
- 대신 양적변수와 질적변수의 관계를 살펴보기에 적절한 상자-수염 그림을 그리면 된다!
- 인종(race)과 $\widehat{Y}$ 사이 연관성을 살펴보자.
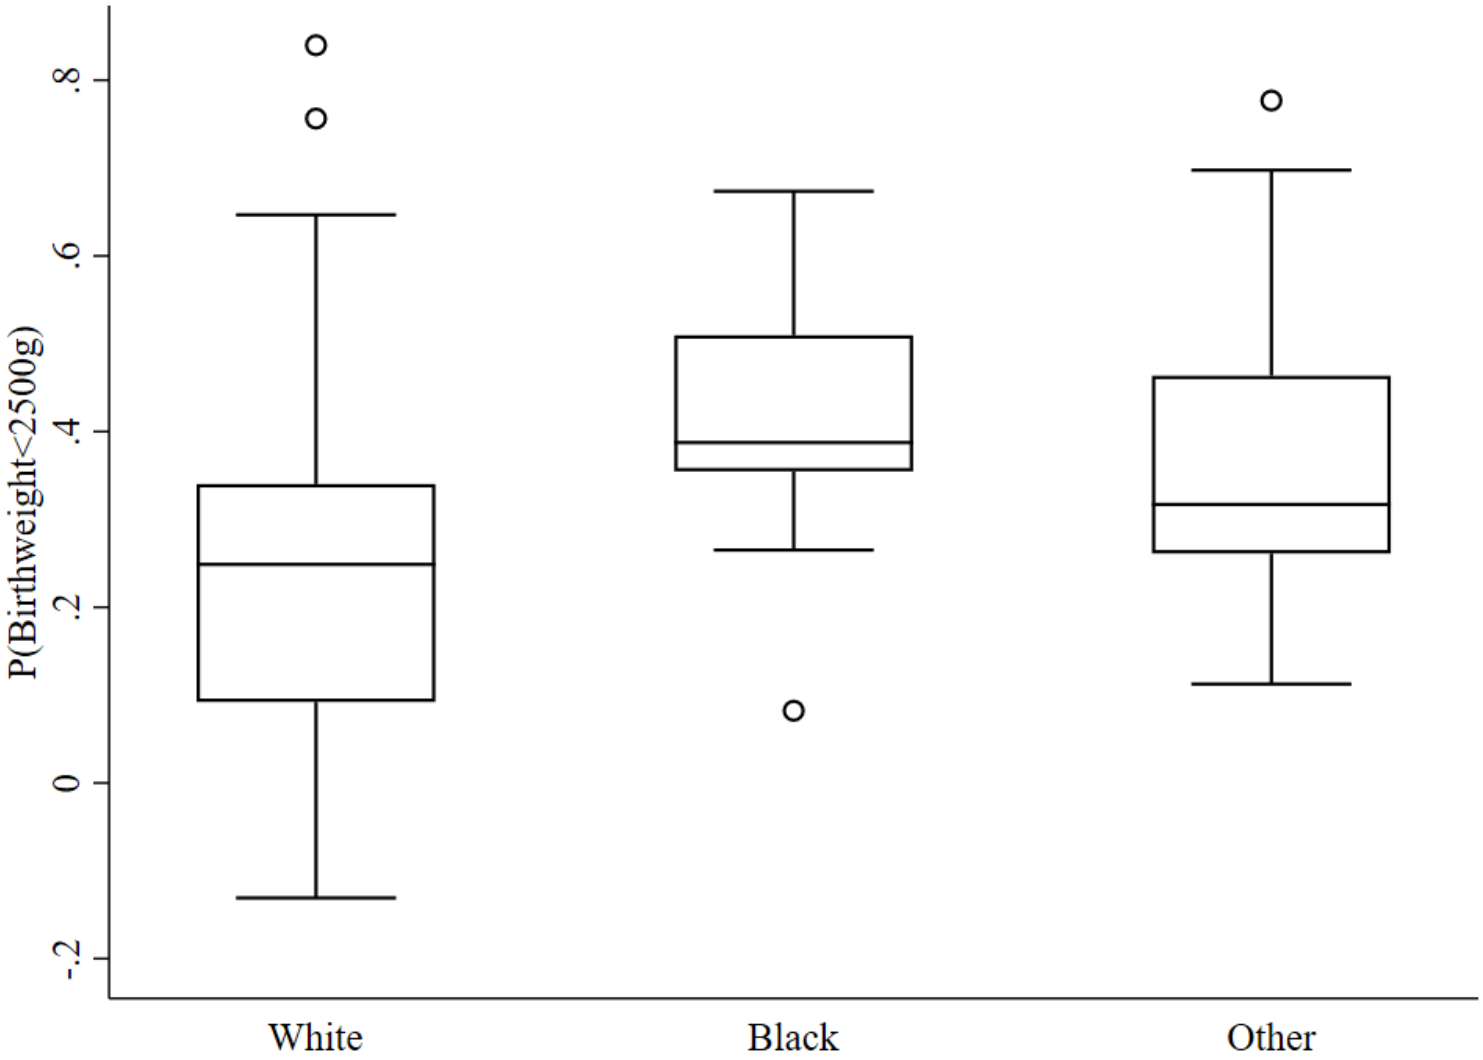
종속변수가 가변수인 경우