사회통계연습
가변수의 활용

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

November 25, 2022

진행 순서

1. 종속변수가 범주형 변수인 경우
2. 질적 종속변수에 대한 선형회귀분석: 문제점
3. 종속변수가 서열척도인 경우

종속변수가 범주형 변수인 경우

종속변수가 범주형 변수인 경우

종속변수가 범주형 변수인 경우 가변수로 바꾸어 선형확률모형을 사용한다.

- 만일 종속변수 Y가 범주형 변수일 때 독립변수로는 어떻게 분석하였는지 다시 떠올려보자.
- 이때는 기준집단(reference group)을 하나 정해 그것만 빼고 나머지를 가변수로 만들어 독립변수로 회귀모형에 투입하였다.
- 종속변수인 경우도 마찬가지로 생각하면 된다. 하나 기준집단을 정해 그것은 뺀다.
- 나머지는 가변수를 종속변수로 하는 선형확률모형과 완전히 똑같다.

종속변수가 범주형 변수인 경우

연습 3. EMPLTYPE.sav 파일을 SPSS로 불러들여 고용 유형(WGSTAT)을 종속변수로, 성별(SEX), 도시 거주 여부(URBAN), 교육수준(EDUC), 연령(AGE)을 독립변수로 하는 회귀식을 추정하고 그 결과를 해석하시오.

종속변수가 범주형 변수인 경우

- WGSTAT을 더미변수로 바꿀 때는 측도에 조심해야 한다. SPSS는 이런 부분에서 쓸떼없는 배려를 한다.
- (기준집단으로 상용직을 삼는다면) 응답자가 상용직이 아니라 임시직일 확률을 분석하기 위해, 일용직인 응답자를 분석에서 잠깐 제외해야 한다!
- 이렇게 해야만 분석할 때 (일용직은 아예 생각하지 않고) 상용직이냐 임시직이냐에만 분석의 초점을 두게 된다.
- 마찬가지로 상용직이 아니라 일용직일 확률을 분석하려면 임시직인 응답자를 분석에서 제외해야 한다.
- 다소 귀찮지만, [데이터]-[케이스 선택]에서 일용직 혹은 상용직을 분석에 앞서 배제하자. 이때는 ~= 기호를 사용한다.

종속변수가 범주형 변수인 경우

- 만약 선택변수에서 그것들을 배제하지 않고 분석하면 어떻게 될까?
- 그러면 상용직이 아니라 임시직일 확률을 분석한 것이 아니게 된다. 일용직인 사람들이 자료에 포함되어 있으므로 상용직 또는 일용직이 아니라 임시직일 확률을 분석한 셈이 된다(Why?).
- 가변수 자료를 곰곰히 살펴보고 그 이유를 따져보자!
- 회귀분석 단계에서 "선택변수" 기능은 별로 시각화에서 혼동하기 쉽기 때문에 당장은 추천하지 않는다(Why?).

종속변수가 범주형 변수인 경우

- 가령 연령에 따라 상용직이 아니라 일용직이 될 확률을 시각화해보자.

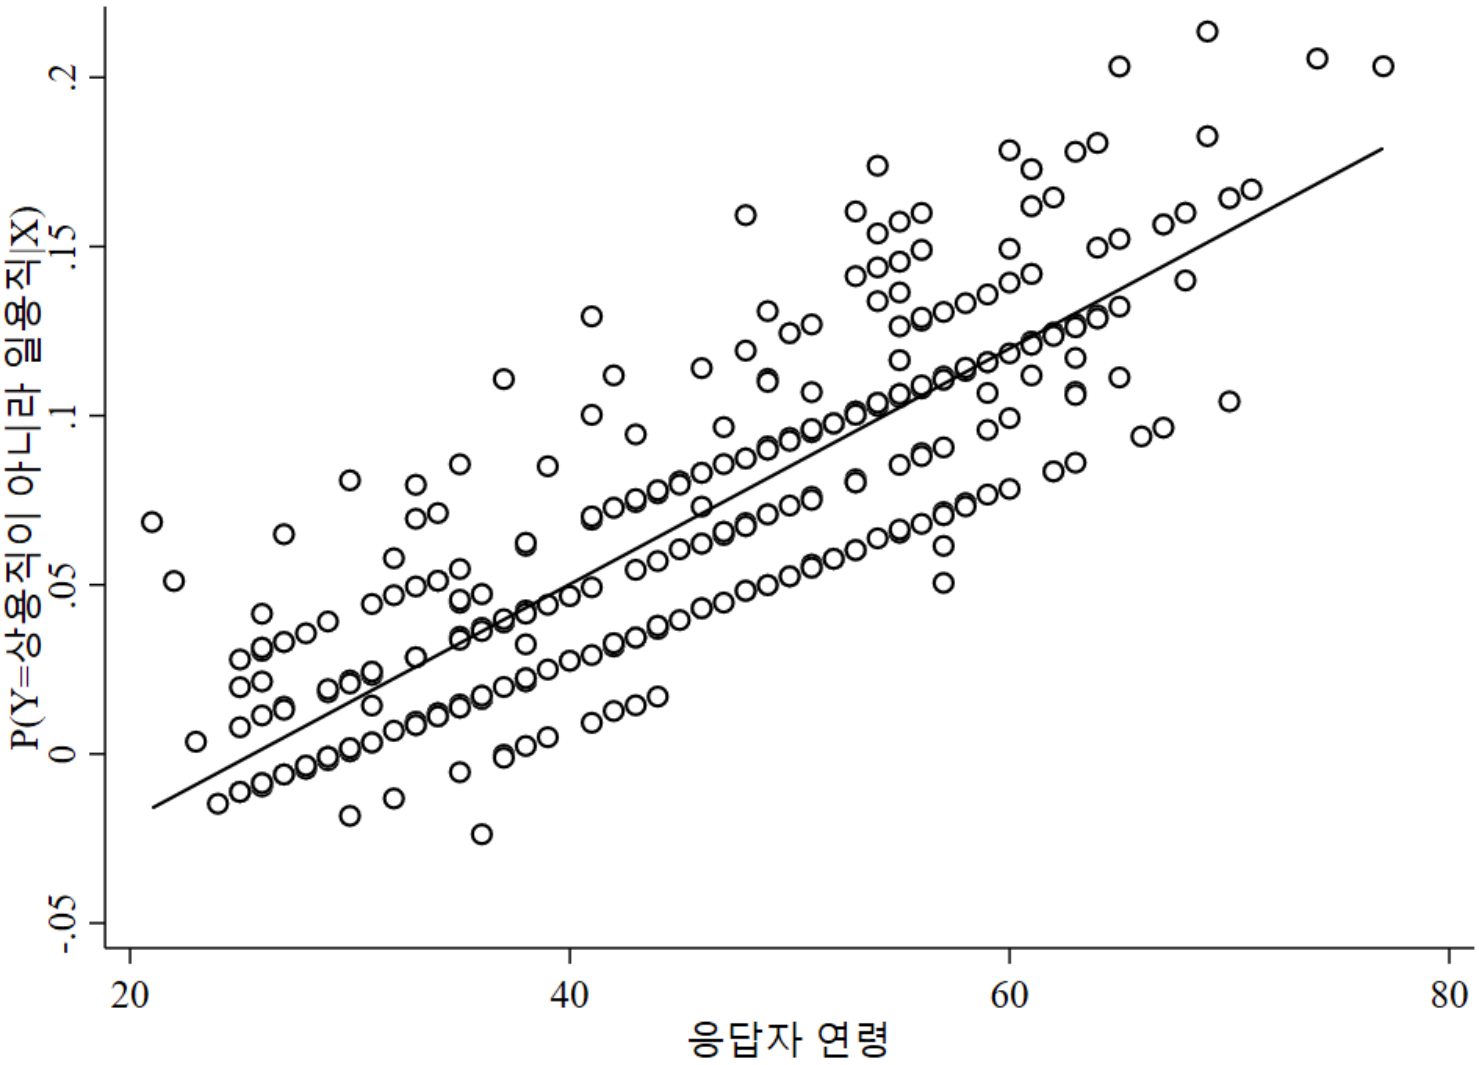

종속변수가 범주형 변수인 경우

- 가변수인 성별에 따라 상용직이 아니라 일용직이 될 확률을 시각화해보자.

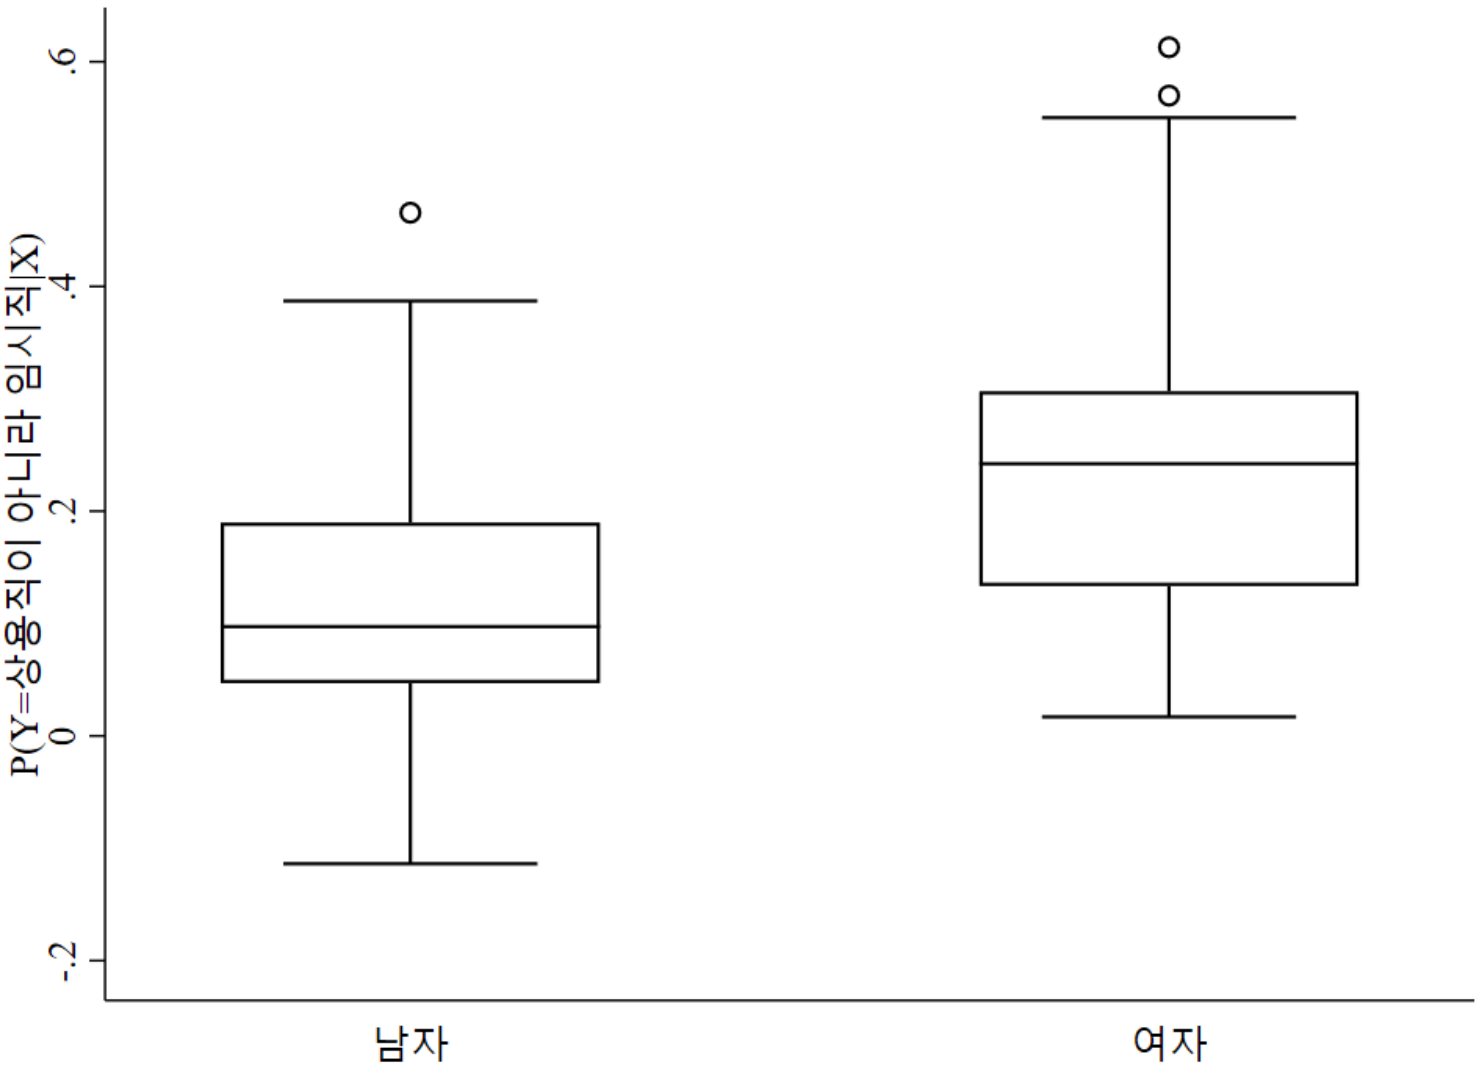

질적 종속변수에 대한 선형회귀분석: 문제점

질적 종속변수에 대한 선형회귀분석: 문제점

그런데 이래도 괜찮은 것일까?

- 종속변수가 가변수 혹은 범주형 변수일 때, OLS 알고리즘을 사용한 선형회귀모형을 그대로 사용하면 몇 가지 문제가 있는 것으로 알려져 있다.
- 첫번째 문제는 선형회귀모형의 가정, 특히 등분산성(homoscedasticity)에 위배된다는 점이다.
- 두번째 문제는 말도 안되는 예측확률이 나온다는 점이다(e.g., 확률이 0보다 작거나 1보다 큼).
- 그러나 그러한 문제에도 불구하고 (1) 그 심각성이 상대적으로 적다는 것과 (2) 이 문제를 극복할 수 있는 더 좋은 분석 기법은 좀 어렵다는 것을 고려할 수 밖에 없다.

질적 종속변수에 대한 선형회귀분석: 문제점

더 나은 대안은 무엇일까?

- 이 문제를 극복하기 위해 오래전부터 가중치(weights)를 활용하는 방법 등이 검토되었다.
- 하지만 근래에는 종속변수가 가변수라면 로지스틱 회귀모형(logistic regression model) 또는 프로빗 회귀모형(probit regression model)이 보다 널리 사용된다.
- 종속변수가 가변수인 경우에는 이분(binary) 로지스틱/프로빗 회귀모형이, 종속변수가 범주형 변수인 경우에는 다항(multinomial) 로지스틱/프로빗 회귀모형이 적합하다.
- 이런 한계와 대안이 있음을 기억하고 선형확률모형을 사용하자!

종속변수가 서열척도인 경우

종속변수가 서열척도인 경우

종속변수가 서열척도인 경우 그냥 선형회귀모형을 사용한다.

- 만일 종속변수 Y가 서열척도(ordinal scale), 특히 리커트 척도인 경우 기존의 해석법을 적당히 적용해 볼 수 있다.

$$E(Y|X) = \widehat{\beta}_0 + \widehat{\beta}_1 X$$

- 가령 종속변수 Y가 주관적 건강(subjective health)이고 1점(=매우 건강하지 않음)에서 5점(=매우 건강함)까지의 서열척도라고 하자.
- 독립변수 X가 소득수준(십 만원 단위)이라면, "소득이 십 만원 증가할 때마다 주관적 건강은 $\widehat{\beta}$점 만큼 증가한다"고 일단 해석할 수 있다.

종속변수가 서열척도인 경우

- 종속변수는 1, 2, 3, 4, 5 사이에서 변화할 뿐이므로 완전한 양적변수는 아니고, 당연히 해석도 완전한 것은 아니다.
- 훨씬 더 추천하고 싶은 방법은, 높은 타당성과 높은 신뢰성(특히 내적 일관성)을 갖춘 여러 문항들을 더하여 합성지수를 만들고 이를 선형회귀모형으로 분석하는 것이다!
- 그러나 그런 문항을 도저히 찾을 수 없고, 분석하고자 하는 문항이 리커트 척도 딱 하나 뿐인데 만일 리커트 척도가 짝수 개의 항목을 가지고 있다면 이분화 (dichotomization)할 수도 있다.
- 4점 리커트 척도(1=매우 불행, 2=다소 불행, 3=다소 행복, 4=매우 불행)인 경우라면 선형확률모형을 사용하기 위해 0=불행, 1=행복으로 단순화할 수 있기 때문이다!
- 그러나 리커트 척도가 홀수 개의 항목을 가지고 있어 나누기도 애매하면 그냥 선형회귀모형을 사용하자.

종속변수가 서열척도인 경우

문항의 측도를 잘 살펴보고 함부로 서열성을 예단해서는 안된다.

- 어떤 문항이 주어졌을 때, 이것이 범주형 변수인가 아니면 서열척도인가를 잘 따져보고서 분석방법을 결정해야 한다.
- 서열척도가 아니라 사실 범주형 변수인데 함부로 선형회귀모형을 적용해서는 안된다.
- 가령 범주형 변수인 고용형태(1=일용직, 2=임시직, 3=상용직)는 미묘하게 서열척도인 것처럼 보이기도 한다. 그렇다고 이것을 그대로 선형회귀모형으로 분석하면 납득하기 어려운 해석에 부딪친다.

종속변수가 서열척도인 경우

기존 방식에는 문제가 있고, 물론 더 나은 대안도 있다.

- 선형회귀모형으로 해석하려다보면 이상한 예측값(가령 1보다 작거나 5보다 큰 값)이 도출되거나 하는 등의 한계를 갖는다.
- 훨씬 더 바람직한 접근방법 중 하나는 서열(ordinal) 로지스틱/프로빗 회귀모형이다.
- 그러나 이런 모형은 (OLS 알고리즘이 아니라) MLE 알고리즘을 채택하고 작동 원리와 해석법을 당장 배우기엔 다소 어렵다.
- 이런 한계와 대안이 있음을 기억하고 그냥 선형회귀모형을 사용하자!

종속변수가 서열척도인 경우

연습 4. nhanes2f.sav 파일을 SPSS로 불러들여 주관적 건강(health)을 종속변수로, 성별(female), 인종(black), 연령(age), 당뇨병 유병 여부(diabetes)을 독립변수로 하는 회귀식을 추정하고 그 결과를 해석하시오. 회귀분석 결과에서 발견한 (1) 연령과 주관적 건강 그리고 (2) 당뇨병 유병 여부와 주관적 건강 간의 관계를 시각화하시오.

종속변수가 서열척도인 경우

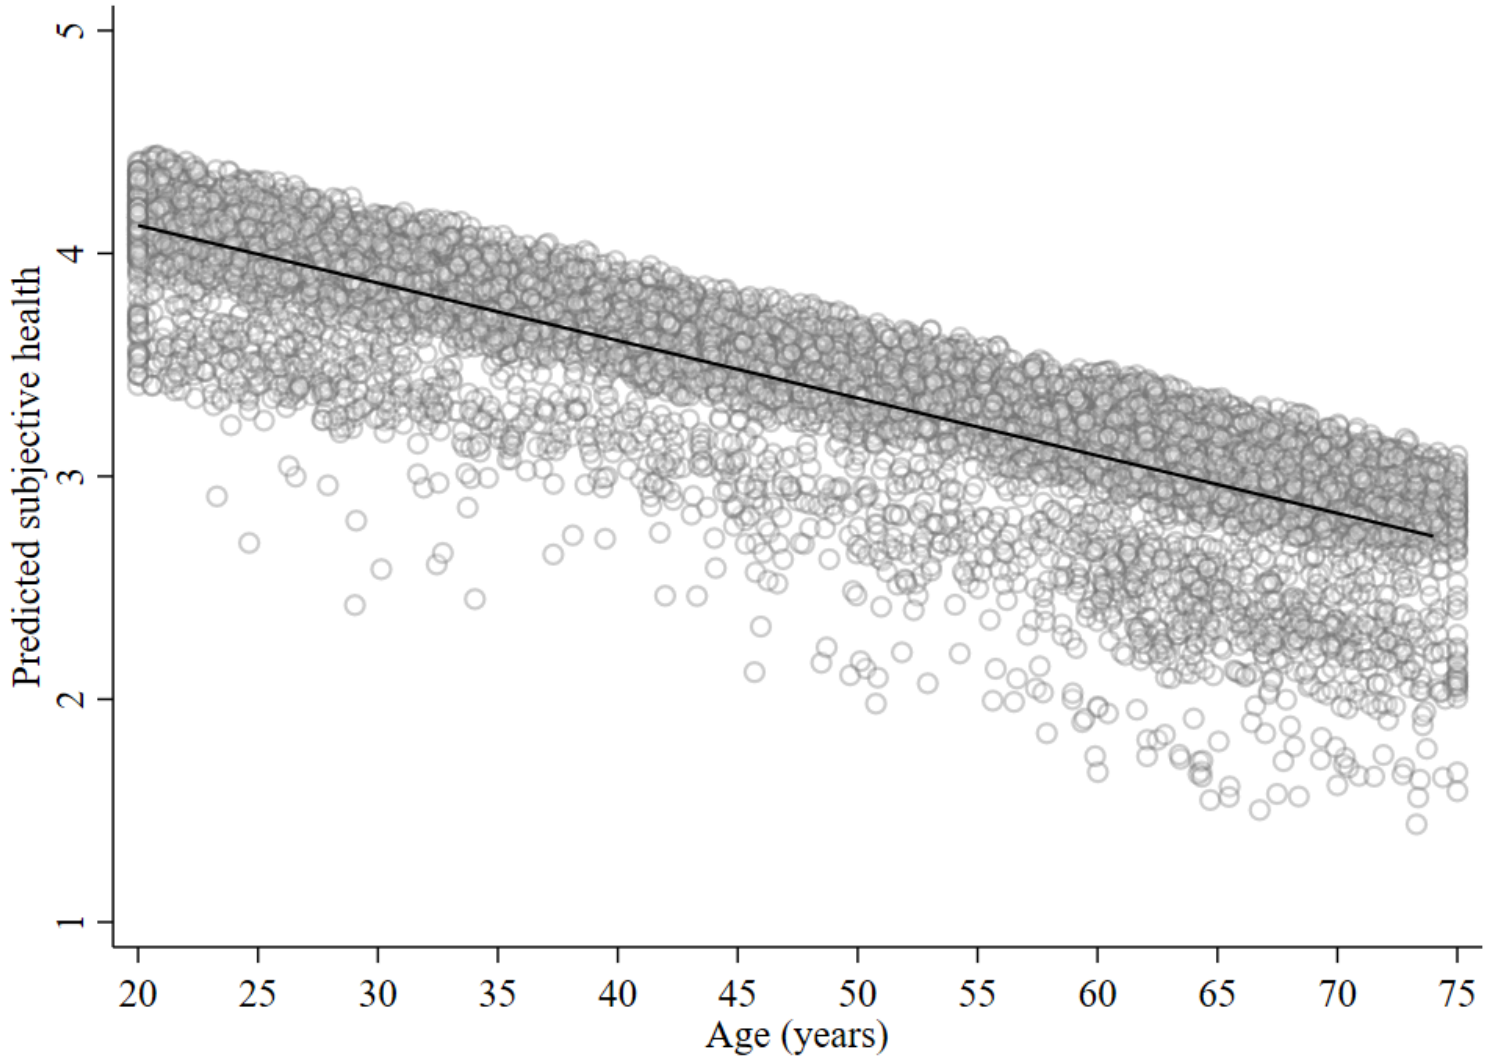
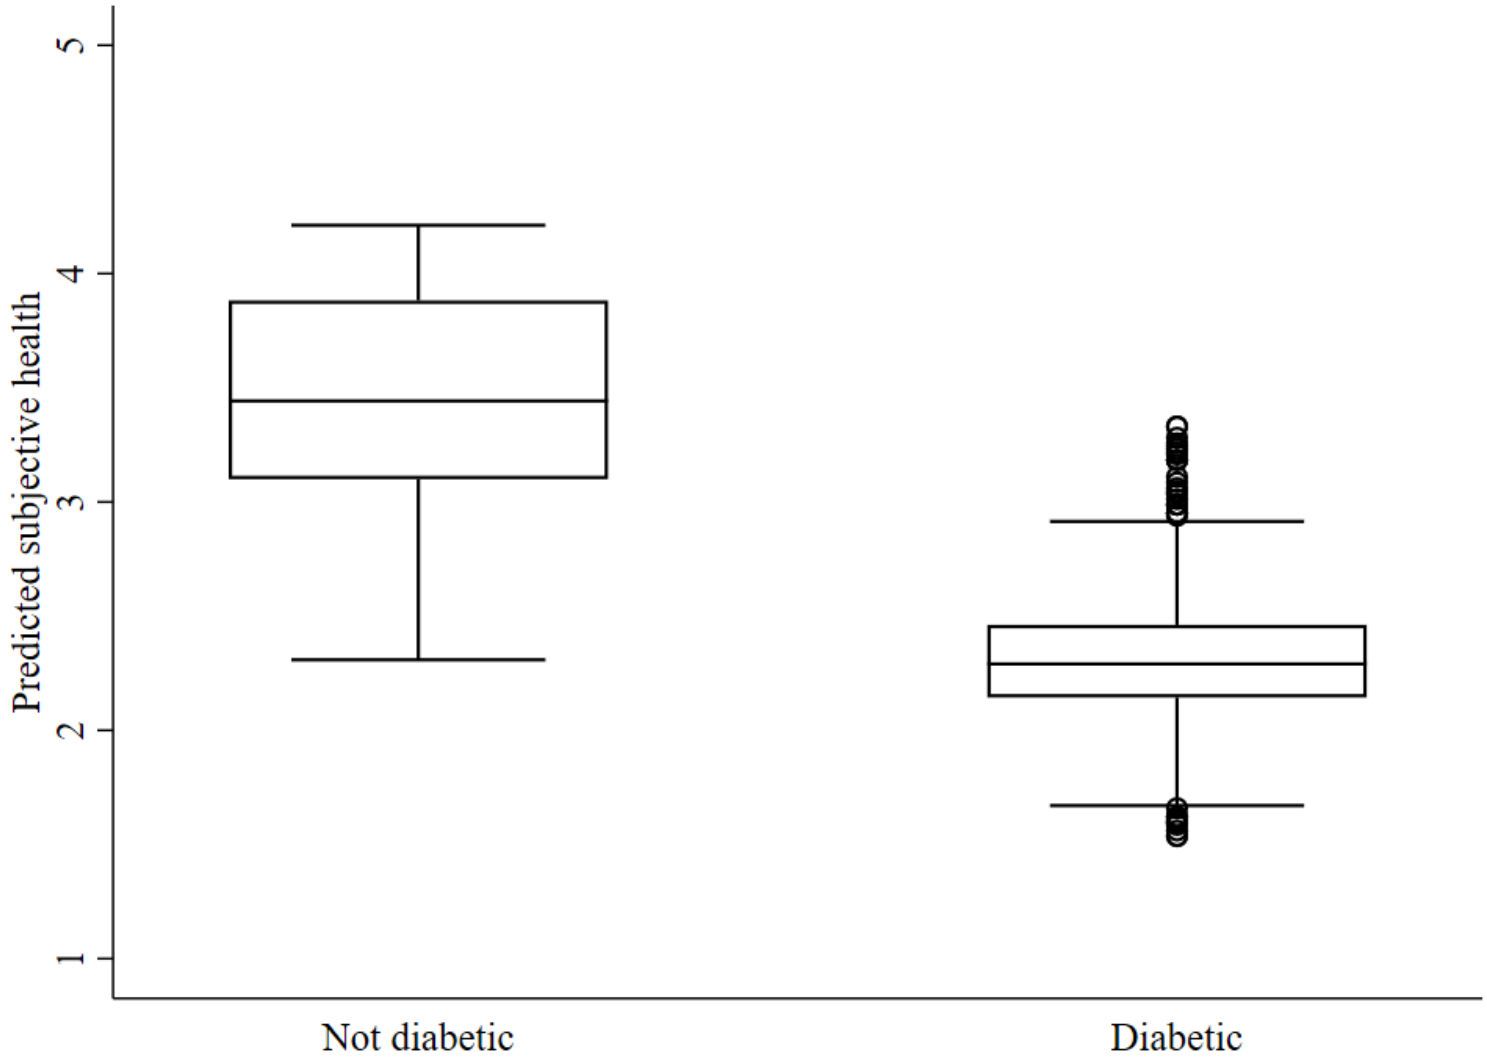
종속변수가 서열척도인 경우