사회통계연습
자료변환과 기술통계

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

September 8, 2023

진행 순서

1. 지난 주 리뷰
2. 자료변환과 응용
3. 기술통계

지난 주 리뷰

지난 주 리뷰

1. 이 자료에는 몇 개의 변수와 관측치가 있는지 서술하시오. (10점)

2. 이 자료에 각 변수는 무엇을 의미하는지 그리고 척도가 무엇인지 일목요연하게 정리된 표를 작성하시오. (40점)

지난 주 리뷰

변수		척도
state	지역	명목척도
region	지역 위치	명목척도
pop	1990 인구 수	비율척도
area	지역 크기	비율척도
density	인구밀도	비율척도
metro	번화가 인구 밀집 비율	비율척도
waste	1인당 폐기물 양 / 톤	비율척도
energy	1인당 소비 에너지	비율척도
miles	1인당 연간 주행 거리 / 마일	비율척도
toxic	1인당 배출한 독성 물질	비율척도
green	1인당 배출한 온실가스/톤	비율척도
house	91년도 하원의원 투표율	비율척도
senate	91년도 상원의원 투표율	비율척도
csat	평균 종합 SAT 점수	등간척도
vsat	평균 언어 SAT 점수	등간척도
msat	평균 수학 SAT 점수	등간척도
percent	SAT를 치르는 고등학교 졸업생 비율	비율척도
expense	학생지출총액	비율척도
income	중위 가계 소득	비율척도
high	25%이상 고등학교 졸업 비율	비율척도
college	25%이상 학사 학위가 있는 비율	비율척도

지난 주 리뷰

3. 이 자료의 관찰단위는 무엇이고 왜 그렇게 생각하는지 서술하시오. (20점)

4. 이 자료의 income 변수를 만들기 위해서는 먼저 기초자료가 필요하다. 그러한 기초자료의 관찰단위는 무엇이고 무엇이고 왜 그렇게 생각하는지 서술하시오. (30점)

지난 주 리뷰

총평

- 변수와 관측치 갯수를 반대로 적어 제출한 경우 간혹 있었다.
- 비율척도를 등간척도로 적은 학생들이 많았다.
- 변수명만 보고 척도를 판단해서는 안되고 레이블(label)과 척도를 꼼꼼히 살펴봐야 한다. 절대영 개념도 따져보아야 한다.
- 교재와 지난 학기 강의록으로 복습을 해야 한다. 척도 식별은 기초가 되므로 실패하면 시험에서 확실히 망한다.
- 관찰단위(unit of observations)에 대해서도 복습할 것!

자료변환과 응용

자료변환과 응용

척도 간에는 변환이 가능하지만 오로지 일방향으로만 가능하다!

- 자료변환(data transformation)을 특히 재부호화(recoding)라고 부른다(기억이 안나면 복습하자).
- 정보량에 차이가 있기 때문에 변환하는 순간 "사라진 정보"는 복원 불가능하게 된다.
- 즉 정보가 많은 쪽에서 정보가 적은 쪽으로만 변환 가능하다(Why?).
- 예를 들면 비율척도로 측정된 월평균 소득은 다음과 같이 서열척도로 변환할 수 있지만, 그 역은 성립하지 않는다.

비율척도	서열척도
100만원 미만	1
100만원 이상 ~ 200만원 미만	2
200만원 이상 ~ 400만원 미만	3
400만원 이상	4

자료변환과 응용

재부호화는 정보상실로 이어지지만 해석상의 편의를 위해 유용할 수 있다.

- 가령 우리는 "그 사람 월급은 481만원이야" 표현 대신 "그 사람 돈 매우 많이 벌어" 라는 표현을 사용한다(Why?).
- 언어적 표현(oral presentation)은 수학 특유의 엄밀성(rigorousness)을 상실하지만, 인간 사회에서의 의사소통에 유용하다.

비율척도	서열척도	언어적 표현
100만원 미만	1	"돈을 매우 못 벌어"
100만원 이상~200만원 미만	2	"돈을 다소 못 벌어"
200만원 이상~400만원 미만	3	"돈을 다소 많이 벌어"
400만원 이상	4	"돈을 매우 많이 벌어"

자료변환과 응용

연습 1. INCOME.SAV 자료를 SPSS에서 불러들여 앞서 제시된 기준대로 (비율척도를 서열척도로) 재부호화하시오.

자료변환과 응용

재부호화의 기준은 잘 생각해야 한다.

- 언어적 표현은 그 자체로 상당한 설득력을 갖게 된다(Why?). 그러나 기준점(cutpoint 또는 threshold)에 따라 사실을 왜곡할 수 있다.
- 위의 재부호화 기준(recoding scheme)이 타당한지는 맥락에 달려있다.
- 사회통계를 연습한다는 것은 결국 통계적 결과물에 대한 언어적 표현을 연습하는 것이기도 하다(Why?).

자료변환과 응용

어떤 재부호화하는 조금 다른 상황에서 이루어진다.

- 많은 사회조사에서는 성별 변수를 {남성=1, 여성=2}으로 부호화(encoding)한다.
- 이것은 분석에 그대로 사용될 경우 해석이 다소 불편하다(Why?).
- 그러므로 성별 변수는 주로 {남성=0, 여성=1} 또는 {여성=0, 남성=1}으로 재부호화된다.

자료변환과 응용

연습 2. INCOME.SAV 자료를 SPSS에서 불러들여 앞서 제시된 기준 중 하나를 사용하여 성별을 재부호화하시오. 적절히 변수 및 입력값 레이블 (label) 또한 부여하시오.

자료변환과 응용

사회통계학에서는 설문조사로 수집된 자료를 분석하는 경우가 많다.

- 최근 동향을 보면 데이터 수집방식이 훨씬 더 다원화되었지만 여전히 설문조사는 중요한 자료의 원천이다.
- 사회현상에 관해 개인의 가치와 태도에 대해 설문할 때 리커트 척도(Likert scale)가 압도적으로 많이 사용된다.
- 한편 많은 사회조사에서는 리커트 척도의 초기 부호화 기준을 종종 거꾸로 되어있다. 다시 말해, 문항에 가장 적극적인 가치/태도를 보일 경우 가장 작은 값이 부여된다.
- 하지만 문항에 가장 적극적인 가치/태도를 보일 경우 가장 큰 값이 부여되는 편이 보다 직관적이므로 역부호화가 필요하다(Why?).

자료변환과 응용

※ 이번에는 귀하의 전반적인 가치관에 대해서 여쭈어 보겠습니다.

HAPPY
66. 귀하의 요즘 생활을 고려할 때 전반적으로 얼마나 행복 또는 불행하다고 생각하십니까?

____ ① 매우 행복하다
____ ② 다소 행복하다
____ ③ 별로 행복하지 않다
____ ④ 전혀 행복하지 않다
____ (8) 선택할 수 없음

FAMSATIS
67. 모든 것을 고려해 봤을 때, 가족과의 관계에 얼마나 만족하십니까?

____ ① 전적으로 만족한다
____ ② 매우 만족한다
____ ③ 다소 만족한다
____ ④ 만족하지도 불만족하지도 않는다
____ ⑤ 다소 불만족한다
____ ⑥ 매우 불만족한다
____ ⑦ 전적으로 불만족한다
____ (8) 선택할 수 없음

68. 귀하는 다음의 각 상황에 대해서 옳다고 생각하십니까, 아니면 옳지 않다고 생각하십니까?

		전적으로 옳지 않다	대부분 옳지 않다	때에 따라 옳지 않다	전혀 잘못되지 않았다	선택할 수 없음
SEXATT1	1) 남녀가 결혼 전에 성관계를 갖는 것	①	②	③	④	(8)
SEXATT2	2) 결혼한 사람이 배우자가 아닌 사람과 성관계를 갖는 것	①	②	③	④	(8)
SEXATT3	3) 동성의 성인끼리 성관계를 갖는 것(동성애)	①	②	③	④	(8)

한국종합사회조사(KGSS)에서 사용된 리커트 척도의 예제

자료변환과 응용

연습 3. VALUE.SAV 자료를 SPSS에서 불러들여 HAPPY와 FAMSATIS 변수를 역부호화하시오. 또한 SEXATT1, SEXATT2, SEXATT3의 세 변수를 그대로 사용할 수 있는지 판단하고, 만약 필요하다면 적절히 재부호화하시오.

기술통계

기술통계

우리는 기술통계를 통해 자료를 요약한다.

- 기술통계(descriptive statistics)는 자료를 요약하는 목적을 가지고 있으므로 요약통계(summary statistics)라고도 부를 수 있다.
- "자료를 요약하라" 라는 말은 곧 기술통계를 제시하고 이를 언어적으로 표현하라는 말과도 같다.
- 자료를 요약하라고 했는데 자료를 그대로 복사해서 붙여넣으면 멍청한 짓이다(Why?).

기술통계

무엇보다, 가장 먼저, 자료의 척도를 옳게 식별해야 한다!

- 어떤 비율척도일수록 보다 다양한 기술통계를 활용할 수 있다(교재 24페이지).

변수유형	척도	추가되는 연산	요약 통계량
질적변수	명목척도	셈	빈도(frequency)와 구성비(percentage) 최빈값(mode)
	서열척도	순위 측정	중앙값(median) 범위(range)
양적변수	등간척도	덧셈/뺄셈	산술평균(arithmetic mean) 분산(variance)과 표준편차(standard deviation)
	비율척도	곱셈/나눗셈	기하평균(geometric mean) 조화평균(harmonic mean)

기술통계

기술통계는 주로 중심성향과 산포성향으로 나뉘어 보고된다.

- 중심성향(central tendency)는 자료를 대표하는(representative) 값이 자료의 가운데 어딘가에 위치해 있다라는 아이디어에 기반한다.
- 주로 세 가지 통계가 중심성향을 파악하기 위해 사용된다:

  (1) 평균(mean)
  (2) 중앙값(median)
  (3) 최빈값(mode)

- 셋 중 어느 것이 가장 좋은가? 평균, 중위값, 최빈값이 모두 같거나 비슷하면 뭘 써도 상관없다.
- 한편 평균은 극단값(outliers; extremes)에 민감하므로 극단값이 자료 속에 끼어있는 경우 평균이 커진다.

기술통계

중심성향으로만 충분히 자료를 잘 요약할 수 있을까? 사실은 그렇지 않다.

- 다음의 데이터가 주어졌다: {-10, 0, 0, 10}
- 평균, 중앙값, 최빈치는 각각 얼마인가?
- 다음의 데이터가 주어졌다: {-100, 0, 0, 100}
- 평균, 중앙값, 최빈치는 각각 얼마인가?
- 두 데이터는 정말로 같은가? 중심성향에 근거하여 두 데이터가 잘 요약되었나?

기술통계

그러므로 관찰값들이 얼마나 흩어져 있는가를 측정하는 통계가 필요하다.

- 산포성향(dispersion tendency)는 자료를 대표하는(representative) 값이 자료의 흩어진 정도에서 나타난다는 아이디어에 기반한다.
- 주로 세 가지 통계가 산포성향을 파악하기 위해 사용된다:

  (1) 범위(range)
  (2) 사분위수간 범위(interquartile range; IQR)
  (3) 분산(variance) 또는 표준편차(standard deviation)

기술통계

연습 4. INCOME.SAV 자료를 SPSS에서 불러들여 월평균 가구소득 INCOM0의 기술통계를 보고하시오.