사회통계연습
집계화와 기술통계표 구성

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

September 8, 2023

진행 순서

1. 표준화
2. 기술통계표
3. 집계화

표준화

표준화

어떤 변수를 비교분석하기 앞서 표준화가 필요할 수 있다.

- 분산(variance) σ^2은 편차의 제곱합(sum of squared deviations)이다. 그러므로 본래 단위가 cm라면 분산의 단위는 cm^2가 된다(Why?).

$$\sigma^2 = \frac{1}{N}\sum_{i=1}^{N}(x_i - \mu)^2$$

- 분산과 공분산(covariance)은 공통적으로 단위민감성(unit sensitive)이라는 이슈가 있다(즉 단위가 달라지면 분산도 달라진다).
- 변수를 무척도(scale-free)로 만들기 위해 표준화(standardization)가 필요하다.

표준화

- 확률분포(probability distribution)에서 이미 원점수(raw score) X를 Z 점수(Z score)로 표준화하는 법을 배웠다.

$$Z = \frac{X - \mu}{\sigma}$$

- 어떤 변수를 Z 점수로 표준화하면 자동적으로 그 변수의 평균은 0, 표준편차는 1이 된다(Why?).
- (다른 표준화 기법도 많이 있지만) Z 점수는 가장 널리 쓰이는 표준화 기법 중 하나로 종종 정규화(normalization)라고도 한다.
- SPSS에서는 [분석]-[기술통계량]-[기술통계]에서 '표준화 값을 변수로 저장'을 활성화한다.

표준화

연습 5. INCOME.SAV 자료를 SPSS에서 불러들여 월평균 가구소득 INCOM0의 Z 점수를 계산하시오. 이 표준화 점수의 평균 및 표준편차를 원점수의 평균 및 표준편차와 비교하시오.

기술통계표

기술통계표

기술통계를 확인했다면 이를 보고해야 한다.

- 기술통계를 표(table)와 그림(figure)으로 잘 요약해야 한다!
- 표 안에 들어가야 하는 정보는 대체로 정해져 있다: (1) 평균(또는 중앙값), (2) 표준편차(또는 분산), (3) 최소값 및 최대값.
- 먼저 표를 깔끔하게 만들어 보고하고 이를 언어적으로 표현한다. "이 변수의 평균은 얼마이고 표준편차는 얼마이다. 최소값과 최대값은 각각 얼마와 얼마이다."
- 리커트 척도의 평균이나 표준편차 따위를 그대로 보고하는 것은 좋지 않다(Why?).

기술통계표

연습 6. INCOME.SAV 자료를 SPSS에서 불러들여 성별, 연령, 학력, 월평균 가구소득에 관한 기술통계표를 만들고 해석하시오.

기술통계표

기술통계표는 깔끔하게 어느 정도 꾸며져야 한다.

- 기술통계표를 꾸밀 때는 엑셀을 활용하는 것이 바람직하다. 적절한 폭과 넓이를 갖추어야 한다. 과도한 칸막이는 피하자.
- 기존 문헌에서 표를 어떻게 꾸몄는가를 보고 흉내내서 연습해야 한다.
- 최종적으로는 한글이나 마이크로소프트 워드에 복사하여 붙여넣자.

기술통계표

기술통계표는 표본의 성격을 묘사하는데도 흔히 사용된다.

- 김춘애(2013)를 살펴보고 어떤 차이가 있는지 살펴보자. 이 경우에는 표본 수 N이 보고되어 있다.
- 이민아(2014)를 살펴보고 해석해보자. 여기서는 t-검정 결과가 보고되어 있지만 지금은 무시하자.

집계화

집계화

자료는 가공되기 전 아무런 정보도 전달하지 못한다.

- 어떤 가공도 가해지기 전 (원석같은) 자료를 원자료(raw data)라고 부른다.
- 원자료는 많은 가능성을 내포하고 있지만 그 자체로는 구체적인 정보를 보여주지 않는다.
- 특정한 정보를 캐내려면 그에 맞는 방향으로 점차 가공을 해나가야하며 그 가공은 결국 집계화(aggregation)의 방식에 따라 이루어진다.

집계화

흔히 집계화는 선거 결과에 비유된다.

- 수십만 장의 투표용지 뭉치로는 선거 결과를 알 수 없다.
- 하나하나 개표하여 각 후보에 던져진 표의 수를 세어야(count) 한다.
- 최종 결과표에는 전체 투표수를 분모로, 후보별 득표수를 분자로 한 비율(proportion)로 표현된다.

집계화

(선거 결과에서 그러하듯) 집계화는 변수를 하나의 숫자로 요약하는 과정이다.

- 다시 말해, 집계화는 요약통계(=기술통계)를 계산하는 과정에서 자연스럽게 이루어진다.
- 집계화는 요약통계의 과정에 다름아니다.
- 기술통계는 반드시 결과표를 제시하려는 목적으로만 수행되는 반면, 우리는 집계화를 별도로 수행하여 인위적으로 집계자료(aggregate data)를 생산할 수 있다.

집계화

- 우리나라 통계청에서 제공하는 통계 자료는 거의 대부분 집계자료이다. 가령 [2020년 의료기관 시군구(대전,세종,충북,충남)별 진료실적 현황-전체]를 보자.
- 현재 이 자료의 관찰단위(unit of observations)는 무엇인가?
- 화면 상단 [주석정보]를 클릭하여 집계되기 직전 자료의 관찰단위가 무엇인지 짐작해보자.
- 집계화 이전 자료가 어떤 형태일지 상상해보자. 이 자료는 다시 어떤 자료로부터 집계화되었을지 상상해보자.

집계화

집계화는 몇가지 장단점을 갖는다.

- 집계화가 높게 올라갈수록 프라이버시 침해(infringement of privacy) 위험이 낮아진다.
- 가령 개별 환자 자료를 인터넷에 올릴 수는 없지만 집계자료 뿐이라면 프라이버시 걱정없이 필요한 정보만을 제공할 수 있다.
- 프라이버시 문제 때문에 (집계화 이전) 원자료는 종종 공개되지 않는다.
- 하지만 한 번 집계화된 자료는 집계화되기 이전의 정보를 상실하므로 되돌아갈 수 없다. 따라서 집계화된 목적 자체와 상이한 목적의 분석에는 더이상 사용되기 어렵다.
- 따라서 "집계자료 말고 원자료를 달라"는 연구자와 이를 거부하는 자료생성기관 사이의 씨름이 종종 벌어진다.

집계화

연습 7. INCOME.SAV 자료를 SPSS에서 불러들여 월평균 소득액의 평균 및 표준편차를 성별을 관찰단위로 하는 집계자료를 생산하시오. 다음으로 같은 변수의 평균 및 표준편차를 성별-최종학력별로 집계자료를 생산하시오.

집계화

집계화를 수행할 때는 분석의 목적을 미리 고려해야 한다.

- 집계화는 SPSS에서 [데이터]-[데이터 통합]으로 쉽게 할 수 있다(데이터 통합은 aggregation의 이상한 번역이다).
- 진짜 수행하려고 하는 분석의 목적을 고려하여 분석단위(unit of analysis)를 결정해야 하므로 그에 걸맞는 수준으로 집계화를 수행한다.
- 분석을 개인 단위로 수행할 예정이라면(즉 분석단위가 개인이라면) 집계화는 대체로 필요없다(Why?).
- 반면, 지역별 혹은 국가별로 분석을 수행하고 싶다면 그에 걸맞게 집계화한 자료를 사용해야 한다.

집계화

연습 8. GOD.SAV 자료를 SPSS에서 불러들여 신에 대한 믿음을 다음과 같은 단위로 집계화하시오: (1) 첫번째 관찰단위는 거주지역(N_TOWN), (2) 두번째 관찰단위는 국가별(B_COUNTRY), (3) 세번째 관찰단위는 국제지역별(regionWB), 마지막으로 (4) 네번째 관찰단위는 전세계. 각각의 집계자료를 다른 이름으로 저장하시오.

집계화

원자료를 얻는 것이 생각보다 중요하다!

- 일단 집계화를 할 줄 알면 그건 아무것도 아니라는 것을 알 수 있다(사람들이 잘 모르니까 이걸 돈주고 고용하는거지 한 번 배우면 뚝딱 해치울 수 있다).
- 그런데 집계화는 일방향성을 갖기 때문에 일단 집계화된 자료는 원자료만큼 쓸모가 없는 경우가 많다.
- 그러므로 상황이 허락되는한 (집계자료보다는) 원자료를 수집해야 한다!

끝!

와~ 즐거운 숙제다~