사회통계연습
시각화(I)

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

September 15, 2023

진행 순서

1. 지난 주 리뷰
2. 도수분포표와 히스토그램
3. 트리맵과 오자이브

지난 주 리뷰

지난 주 리뷰

1. 1. 평균 수심이 10cm인 하천에서 장거한이 익사하고 말았다. 이 미스테리를 설명하시오. (10점)

- 평균만으로는 자료의 산포를 알 수 없다. 사람이 빠져죽을만큼 깊은 곳이 얼마든지 있을 수 있다.
- 평균값은 하천의 중심성향을 나타낸 것일 뿐이므로 평균 만으로 전체 하천의 수심을 이해하기에는 무리가 있다.
- 즉 장거한이 익사한 곳은 하천 중에서도 평균에 비해 깊은 극단값에 위치해 있을 가능성을 간과할 수 없다.
- "엎드렸다" 틀림(2022년 실제답안 사례).

지난 주 리뷰

2. 범위, 사분위수간 범위, 분산의 장단점을 통계학적으로 논하시오. (20점)

- 범위는 계산이 단순하나(장점) 극단치에 취약함(단점).
- 사분위수간 범위는 극단치에 강건하나(장점), 자료를 최대한 활용하지 않음(단점).
- 분산은 자료를 최대한 활용하나(장점) 단위에 민감(unit sensitive)함(단점).

지난 주 리뷰

3. SAMPLE.SAV를 활용하여 표본의 특성을 나타내는 표를 작성하시오. 이때 황정미(2010)의 기술통계표를 참고하여 이와 최대한 유사한 형태로 만드시오. 이때 SAMPLE.SAV와 황정미(2010)가 사용한 자료는 같은 것이 아니므로, 구성이 똑같지 않은 변수(e.g., 지역, 지역크기, 직업)에 대해서는 (SAMPLE.SAV에서) 주어진 변수를 그대로 활용하되, 연령 및 가구소득 수준만큼은 황정미(2010)의 재부호화 기준(recoding scheme)을 그대로 흉내내시오. (70점)

지난 주 리뷰

	기술통계량		
		사례수	%
지역	서울	221	19.5
	경기	336	29.6
	강원	36	3.2
	충청	124	10.9
	경상	292	25.7
	전라	114	10.1
	제주	11	1.0
거주지역 규모	큰 도시	459	40.5
	큰 도시 주변	295	26.0
	작은 도시	239	21.1
	시골마을	135	11.9
	외딴 곳	3	0.3
	무응답	3	0.3
성별	남자	481	42.4
	여자	653	57.6
연령	10대	11	1.0
	20대	115	10.1
	30대	150	13.2
	40대	177	15.6
	50대	279	24.6
	60대 이상	402	35.4
학력	무학	53	4.7
	초등(국민)학교	126	11.1
	중학교	111	9.8
	고등학교	389	34.3
	전문대학(2·3년제)	138	12.2
	대학교(4년제)	290	25.6
	대학원(석사과정)	23	2.0
	대학원(박사과정)	2	0.2
	무응답	2	0.2

지난 주 리뷰

직업	군인	1	0.1
	관리자	26	2.3
	전문가 및 관련 종사자	130	11.5
	사무 종사자	203	17.9
	서비스 종사자	135	11.9
	판매 종사자	149	13.1
	농림어업 숙련 종사자	89	7.8
	기능원 및 관련 기능 종사자	54	4.8
	장치,기계조작 및 조립종사자	60	5.3
	단순노무 종사자	119	10.5
	무응답	168	14.8
월평균 가구소득 수준	100만원 이하	124	10.9
	101-200만원	157	13.8
	201-300만원	173	15.3
	301-500만원	294	25.9
	501-1000만원	289	25.5
	1000만원 초과	42	3.7
	모름/무응답	55	4.9
전체		1134.0	100.0

지난 주 리뷰

총평

- 표를 깔끔하게 만들어야 한다(소수점 반올림, 선 명확하게 긋기, 칸 크기 등). 문제가 있으면 감점하였다.
- 꼭 결측값(missing values)을 "모름/무응답"으로 정리하여야 한다.
- 범주를 만들 때는 "이상·이하"와 "초과·미만"을 혼동하지 말 것.
- (소득에 지역이 들어가 있거나 나이에 학력이 들어가 있는 등) 범주 설정이 잘못되면 감점.
- (강의계획서에 명시한 대로) 파일명에 자기 이름을 적지 말라고 했다. 학번만 적는다.
- 재제출은 최대한 삼가해야 하며, (꼭 해야한다면) 메일 본문에라도 재제출이라고 적어야 한다.

도수분포표와 히스토그램

도수분포표와 히스토그램

가장 중요한 단일변수 시각화 기법은 빈도분포표와 히스토그램이다.

- (명목척도나 서열척도로 측정한) 질적변수가 주어져 있으면 각 범주별로 하나하나 세서(tally) 빈도분포표 안에 요약할 수 있다.

ID	female	IQ	income	socialclass
1	1	135	250	1
2	0	110	310	2
3	1	128	1500	3
4	0	98	122	2
5	1	106	450	2
6	0	102	190	1

socialclass	Frequency	Perc.	Cum. Perc.
1	2	33.33%	33.33%
2	3	50.00%	83.33%
3	1	16.67%	100.00%

도수분포표와 히스토그램

- 이렇게 만들어진 빈도분포표를 그림으로 나타내면 곧 막대차트(bar chart) 또는 히스토그램(histogram)이 된다.
- 도수분포표와 히스토그램 그리고 막대차트는 본질적으로 같은 정보를 전달한다 (Why?).

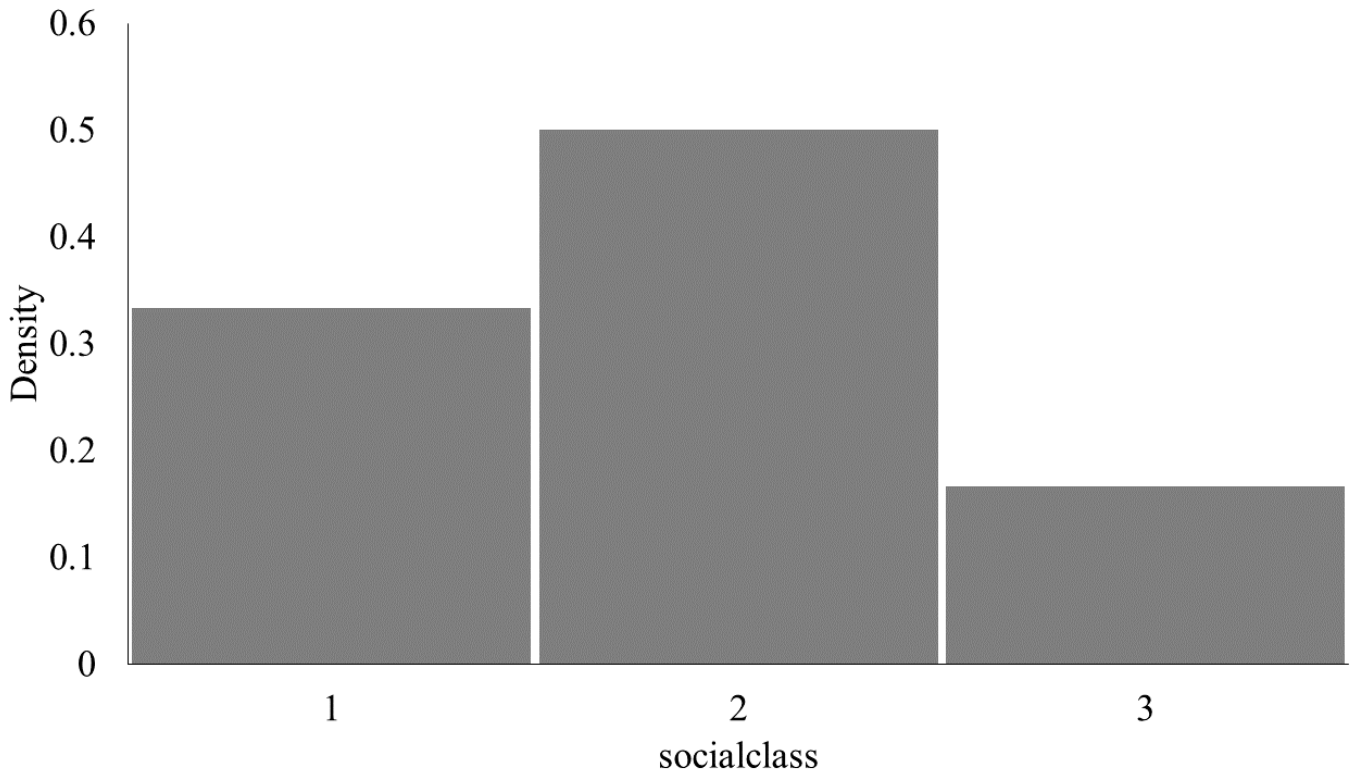

도수분포표와 히스토그램

연습 1. NHANES.SAV 자료에서 주관적 건강(health)의 빈도분포표와 히스토그램(또는 막대차트)을 작성하고 이를 해석하시오.

도수분포표와 히스토그램

- 교과서에 따르면 히스토그램은 양적변수에 대응하고, 막대차트는 질적변수에 대응하지만 현실적으로는 거의 같다.
- 양적변수는 질적변수로 바꿀 수 있으므로 결국 범주형 자료로 재부호화하면 쉽게 시각화할 수 있기 때문이다([변환]-[다른 변수로 코딩변경]).
- 만약 양적변수가 주어졌다면 (재부호화하기 앞서) 합리적인 기준점(cutpoint 또는 threshold)을 잡기 위해 기술통계표를 먼저 확인보아야 할 필요가 있다(Why?).

도수분포표와 히스토그램

연습 2. NHANES.SAV 자료에서 이완기 혈압(bpdiast)의 빈도분포표와 히스토그램(또는 막대차트)을 작성하고 이를 해석하시오. 자신이 선택한 구간설정의 근거에 대해서도 논의하시오.

도수분포표와 히스토그램

- 일단 양적변수라도 빈도분포표와 히스토그램을 그려보고 어디에 숫자가 집중되어 있는지 살펴보자.
- 이러한 집중 전후로 구간을 나누는 것도 괜찮은 전략이 된다.
- 각 범주별로 관측치가 적당히 균형을 갖춰 분배되도록 주의하자.

도수분포표와 히스토그램

응답의 척도가 같다면 여러 변수들을 하나의 표 안에 정리할 수 있다.

- 만일 여러 변수들이 동일한 부호화 기준(coding scheme)을 사용하고 있다면(e.g., 리커트 척도), 변수를 행(rows)에 놓고 퍼센트를 열(columns)에 놓는 하나의 도수분포표로 요약할 수도 있다.
- 가령 리커트 척도로 측정된 질문 10개가 있다고 하자. (10개의 빈도분포표를 따로 만들기보다) 하나의 표로 10개의 질문을 일목요연하게 정리하는 것이 낫다.

	A	B	C	D	E	F
1						
2	성관계에 대한 태도	전적으로 옳지 않다	대부분 옳지 않다	때에 따라 옳지 않다	전혀 잘못되지 않았다	
3	혼전성교	17.60%	13.40%	28.90%	40.10%	
4	혼외성교	70.70%	18.90%	7.40%	3.10%	
5	동성성교	51.60%	15.60%	13.80%	18.90%	
6	(참고: 반올림으로 인해 합이 100%와 다를 수 있음)					
7						
8						

도수분포표와 히스토그램

연습 3. VALUE.SAV 자료를 SPSS에서 불러들여 성관계에 대한 태도 세 변수에 관한 통합형 빈도분포표와 막대차트를 작성하고 그 결과를 해석하시오.

도수분포표와 히스토그램

- SPSS에서 세 변수들의 빈도분포표를 출력하고 이를 엑셀로 옮겨서 편집하자.
- 표는 예쁘게 꾸며야 한다. 필요에 따라 전치행렬(transposed matrix)을 사용하자.
- SPSS에서 한 번에 이런 표를 만들 수도 있지만 잘 사용되지 않으므로 이 방식을 사용하자.

트리맵과 오자이브

트리맵과 오자이브

트리맵은 불균등한 현실을 폭로하기에 좋다.

- 자료에 위계성이 뚜렷하면 뚜렷할수록 트리맵(treemap)은 독자에게 신선한 충격을 안겨준다(e.g., "불균형 문제가 이렇게 심했어?")
- 최근 계산과학(computational science) 및 계산 알고리즘의 혁신 웨이브에 힘입어 인기몰이를 하고 있다.
- 각 사각형의 면적은 개별 항목별로 주어진 값에 비례한다(area-based visualization).
- 트리맵은 SPSS보다는 엑셀을 사용하자.

트리맵과 오자이브

연습 4. 온실가스 에너지 목표관리 명세서 주요정보.xslx를 엑셀에서 불러들여 온실가스 배출량 트리맵을 작성하시오.

트리맵과 오자이브

- 법인명과 온실가스 배출량만을 개별적으로 복사하여 새 탭에 붙여넣자. 자료를 이리저리 정렬(sort)하여 이상한 값을 제거해야 한다.
- 온실가스 배출량 변수를 하이라이트하여 [삽입]-[트리맵]을 선택한다.
- 법인명이 레이블로 나오는 편이 보기 좋으므로 [차트 요소]에서 [데이터 레이블]을 선택해야 한다.
- 약간의 꾸미기는 역시 필요하다.

트리맵과 오자이브

오자이브는 구간별 누적백분율을 시각화한다.

- 오자이브(ogive)의 x축은 (나타내고자 하는 변수의) 도수(frequency) 혹은 계급구간(class interval)을 나타내고, y축은 누적백분율(cumulative percentage)을 나타낸다.

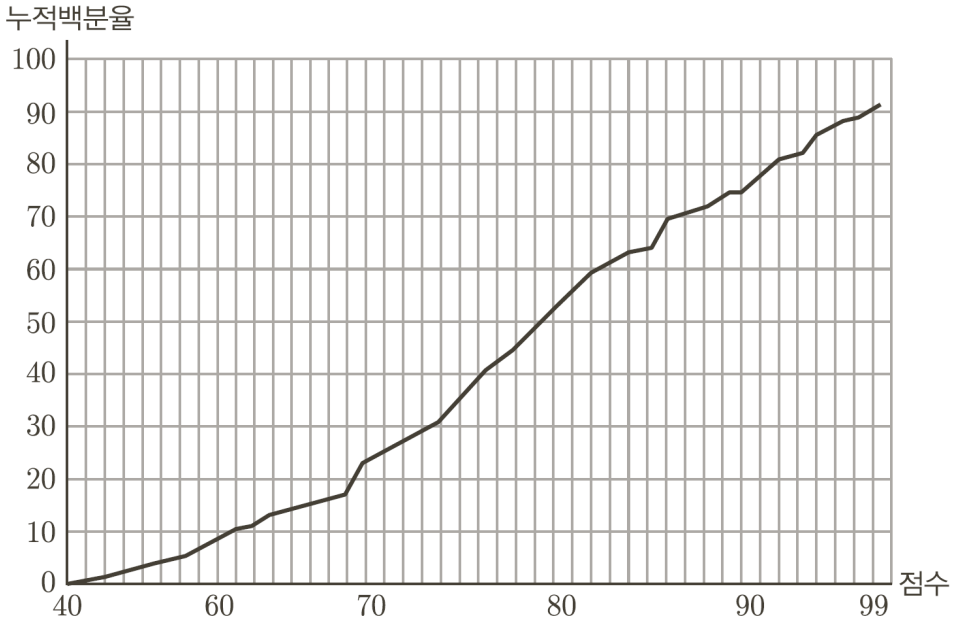

트리맵과 오자이브

연습 5. INCOME.SAV 자료에서 월평균 가구소득을 오자이브로 시각화하고 그 함의를 해석하시오.

트리맵과 오자이브

- SPSS에서는 [그래프]-[차트 작성기]에서 '선형 차트'를 먼저 고르고 x축에 월평균 가구소득을 넣는다. "통계량"을 '누적 퍼센트'로 바꾸어야 한다.
- 이 오자이브의 의미를 해석해보자.
- 오자이브와 로렌츠 곡선(Lorenz curve)은 (소득불평등을 나타내는) 이른바 지니계수(gini coefficient)와 직결된 시각화 기법이다.
- 두 시각화 기법의 공통점과 차이점을 생각해보자!