# 사회통계연습
## 시각화(II)

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

September 15, 2023

# 진행 순서

1. 둘 이상 변수간 연관성의 시각화
2. 상자-수염 그림과 막대차트 비교
3. 산점도와 적합선
4. 시간과 공간의 시각화

# 둘 이상 변수간 연관성의 시각화

# 둘 이상 변수간 연관성의 시각화

둘 이상 변수 사이의 관계를 시각화한다면 분석 방법도 조금 달라진다.

- 지금까지 단일변수(univariate)가 있는 자료의 시각화를 다루었다면 지금부터는 둘 이상의 변수(bivariate or multivariate)가 있는 자료의 시각화에 대해 공부하자.
- "주어진 모든 변수들의 척도를 정확하게 판단하고" 어떤 시각화를 할 것인지 결정한다.

# 둘 이상 변수간 연관성의 시각화

변수가 두 개인 경우를 예로 들어보자.

- (1) 두 변수 모두 질적변수(e.g., 리커트 척도 문항 2개)라면 교차표(cross-tabulation)와 막대차트를 그려 연관성을 표현할 수 있다. 유의성 검정을 위해 $\chi^2$ 분석($\chi^2$ analysis)을 사용할 수 있다.
- (2) 한 변수는 질적변수(e.g., 성별), 나머지 변수는 양적변수(e.g., 월평균 소득)라면 상자-수염 그림(Box-Whisker plot)을 그려 비교할 수 있다. 유의성 검정을 위해 $t$-검정($t$-test)과 일원분산분석(ANOVA)을 사용할 수 있다.
- (3) 두 변수 모두 양적변수(e.g., 월평균 소득과 수학연수)라면 산점도(scatterplot)를 그려 비교할 수 있다. 유의성 검정을 위해 상관분석(correlation analysis)과 회귀분석(regression analysis)을 사용할 수 있다.

# 상자-수염 그림과 막대차트 비교

# 상자-수염 그림과 막대차트 비교

상자-수염 그림도 단일한 양적변수 시각화에서 자주 사용된다.

- 상자-수염 그림(Box-Whisker plot)은 중심경향과 산포경향의 주요 요약통계량을 그림 하나로 전달한다는 장점이 있다.
- 특히 상자-수염 그림을 통해 이상점(outliers)도 한눈에 파악할 수 있다.

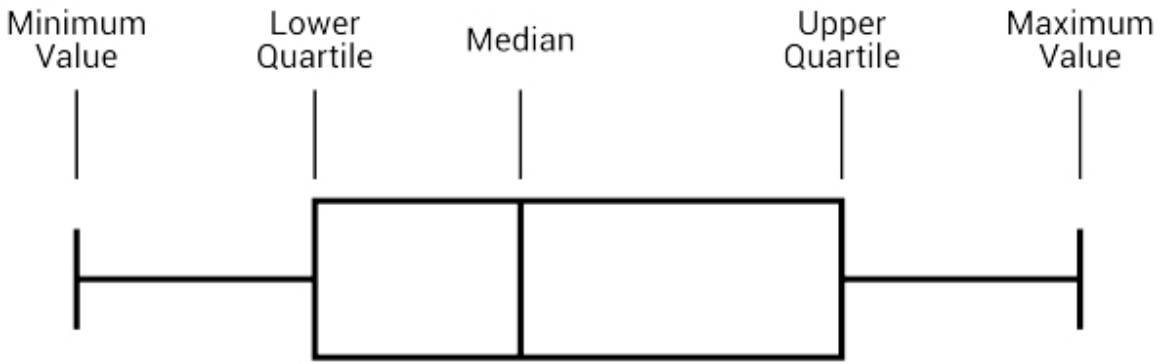

# 상자-수염 그림과 막대차트 비교

- 사실 겨우 하나의 변수를 요약하기 위해 상자-수염을 그리는 경우는 거의 없고 (Why?), 여러 변수의 상자-수염 그림을 나란히 비교할 수는 있다.
- 이때는 사실 (여러 개의 양적변수를 비교하는 것이 아니라) 양적변수인 배달시간과 질적변수인 음식 종류 사이의 연관성을 살펴본 것임에 주의해야 한다(Why?).

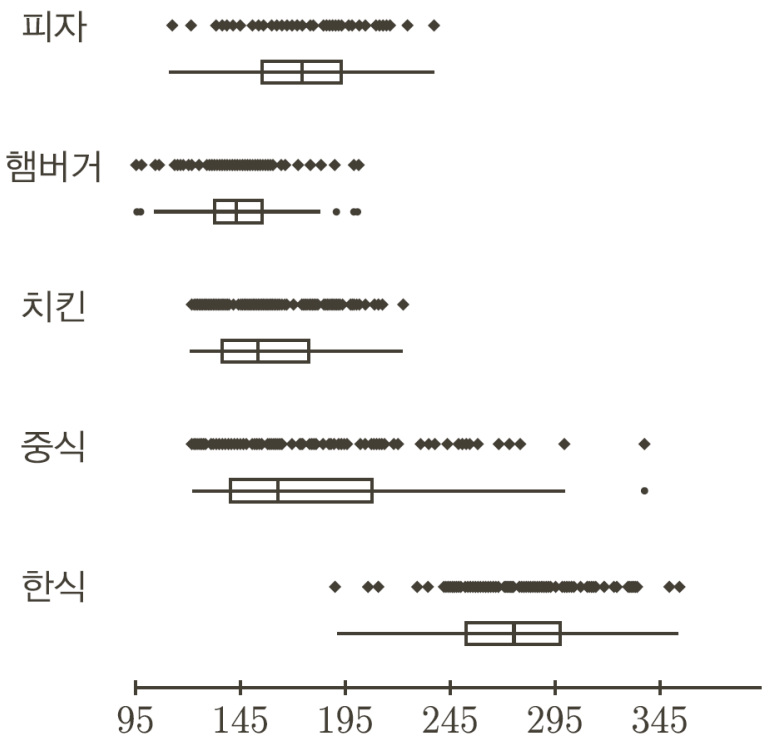

# 상자-수염 그림과 막대차트 비교

연습 6. NHANES.SAV 자료에서 성별(sex)과 이완기 혈압(bpdiast)의 연관성을 상자-수염 그림으로 시각화하시오.

# 상자-수염 그림과 막대차트 비교

질적 변수와 질적 변수의 관계는 어떻게 시각화할 수 있을까?

- 상자-수염 그림이 질적 변수와 양적 변수의 관계를 시각화한다면, 막대차트는 질적 변수와 질적 변수의 관계를 시각화하는데 사용될 수 있다.
- 어떻게 이런 그림을 그릴 수 있을까?

# 상자-수염 그림과 막대차트 비교

연습 7. VALUES.SAV 자료에서 가족관계 만족도(FAMSATIS)와 성별(SEX)의 연관성을 시각화하시오.

# 상자-수염 그림과 막대차트 비교

- '수평누적 막대도표'를 선택한다. 'X에 군집: 색상 선정'에 FAMSATIS를 넣고 $x$ 축에는 SEX를 넣는다.
- 그래프를 적당히 꾸미고 불필요한 레이블과 블럭은 삭제하자.
- 'X에 군집: 색상 선정'에 SEX를 넣고 $x$축에 FAMSATIS를 넣는다면 그림이 달라진다(Why?).

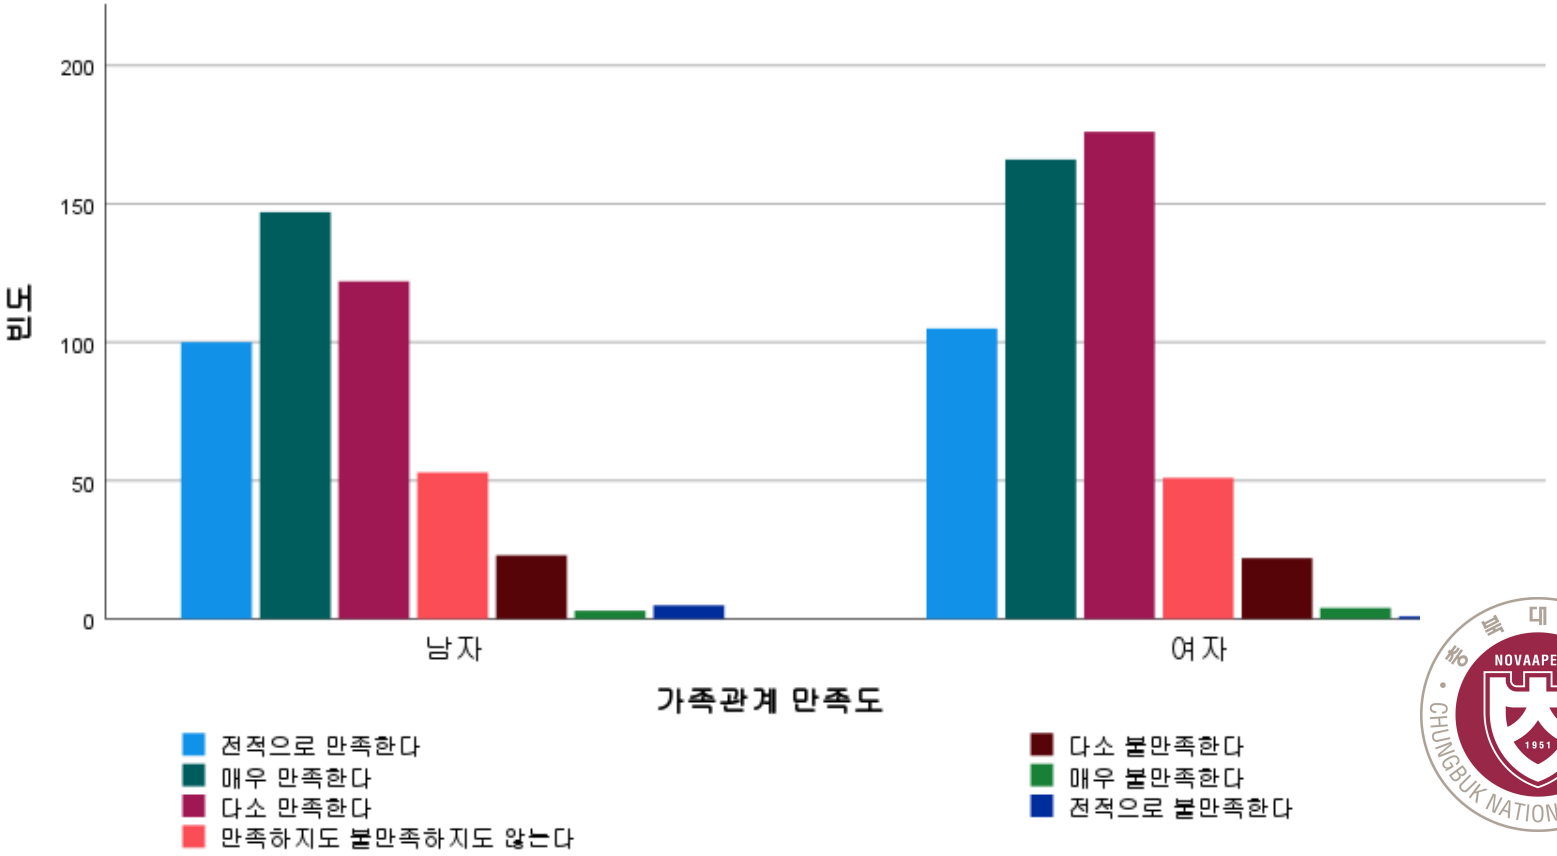

# 산점도와 적합선

# 산점도와 적합선

두 양적변수의 연관성을 살펴보기 위해 산점도를 활용할 수 있다.

- 산점도란 두 양적변수 $X$와 $Y$가 주어졌을 때 하나의 관측치(observation)를 하나의 벡터(vector) $(X, Y)$로 파악한 다음, 이것들을 데카르트 좌표계(Cartesian coordinates) 위에 뿌린 것이다.

| ID | MATH | ENG |
|---|---|---|
| 1 | -2 | 1.5 |
| 2 | 3 | 2 |
| 3 | -1 | -1 |
| 4 | 1 | -3 |

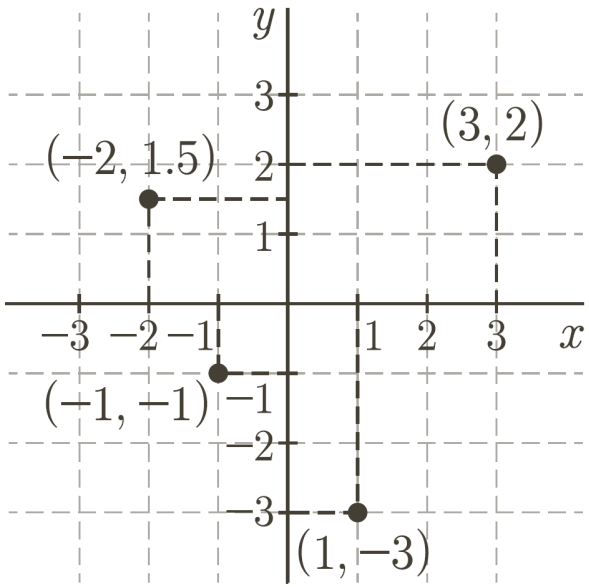

# 산점도와 적합선

연습 8. NHANES.SAV 자료에서 키(height)와 몸무게(weight)의 연관성을 시각화하시오.

# 산점도와 적합선

- 산점도와 더불어 “여러 점들 사이의 추세를 나타내는 선”, 즉 적합선(fitting line)을 그려 두 변수 사이의 관계를 또렷하게 시각화할 수 있다. SPSS에서는 ‘선형 적합선’을 체크한다.
- 여러 개의 연속변수 사이의 연관성은 산점도 행렬(scatterplot matrix)로 나타낼 수 있으며 이때는 [차트 작성기]의 ‘산점도 행렬’을 사용한다.
- SPSS 보다는 엑셀에서 산점도를 그리는 편이 좀 더 예쁜 것 같다. 다만 산점도 행렬은 SPSS에서 그릴 수 없다.

# 산점도와 적합선

연습 9. CORN.SAV 자료에서 옥수수와 콩의 실제 헥타르당 재배면적과 위성사진 픽셀 사이의 연관성을 시각화하고 해석하시오.

# 시간과 공간의 시각화

# 시간과 공간의 시각화

자료가 시간에 따라 변화하는 추세도 시각화 할 수 있다.

- 시계열 자료(time-series data)란 "시간에 따라 관측된 데이터"이다. 대표적인 예로 일별 주가지수나 연간 강수량 등을 생각해 볼 수 있다.
- 시계열 자료를 분석하는 시계열 분석(time-series analysis)은 이미 경제학 분야에서 엄청나게 발전하여 특히 금융공학 쪽에서 고도의 기법이 연구되고 있다(베이지안 시계열 분석이나 머신러닝 금융공학 등).
- 하지만 사회학에서는 시계열 자료나 시계열 분석이 거의 다루어지지 않는다(Why?).
- 관찰된 시계열 데이터는 사실 몇 가지 요소가 결합된 혼합물이다: 추세성(trends), 계절성(seasonality)/주기성(cyclicity), 잡음(noise).

# 시간과 공간의 시각화

연습 10. KLEIN.SAV 자료에서 1920년에서 1941년 사이 민간부문 임금지불액(wagepriv)과 공공부문 임금지불액(wagegovt)의 시계열도표를 각각 시각화하고 서로 비교하시오.

# 시간과 공간의 시각화

- 하나 이상의 시계열 변수를 한 그림에 집어넣으려면 [차트 작성기]가 아니라 [레거시 대화 상자]에서 [선형 차트]를 골라야 한다.
- "단순"이 아니라 "다중" 그리고 "케이스 집단들의 요약값"이 아니라 "개별 변수의 요약값"을 선택해야 한다.
- '선 표시'에는 그리려고 하는 시계열 변수를 집어넣고, '범주축'에는 시간 변수를 집어넣으면 된다.

# 시간과 공간의 시각화

- ASA (2004)를 보면 1973년부터 2002년까지 환경을 보호하는데 돈을 너무 적게 쓴다고 믿는 미국인의 비율이 어떻게 증감하는지 보여준다.
- 이런 자료를 어떻게 만들 수 있을까? 먼저 (1) 연도별로 위 명제에 동의 여부를 나타낸 더미변수를 평균으로 집계화하고, (2) 그 자료로 시계열 시각화를 수행하면 된다.
- 더미변수의 평균은 곧 비율이라는 점을 다시 떠올리자(Why?).
- Joffe and Weitz (2010: 65)를 보고 임신단계별로 임신중절 찬반 여부의 시각화를 살펴보자. 조사하는 두 변수는 무엇인가? 그 두 변수의 척도는 무엇인가?

# 시간과 공간의 시각화

자료가 공간에 따라 어떻게 분포하는가도 시각화 할 수 있다.

- 공간자료(spatial data)란 "공간에 따라 관측된 데이터"이다. 대표적인 예로 지역별 인구수 등을 생각해 볼 수 있다.
- 공간자료는 이른바 지리정보시스템(geographical information system; GIS)의 발전에 힘입어 큰 관심을 받고 있다. 지리학 분야 뿐 아니라 사회학에서도 중요하게 다루어져 왔다.

# 시간과 공간의 시각화

- 공간자료는 적어도 세 구성요소로 이루어져 있다: (1) 위도(latitude), (2) 경도(longitude), (3) 자료값(data value).

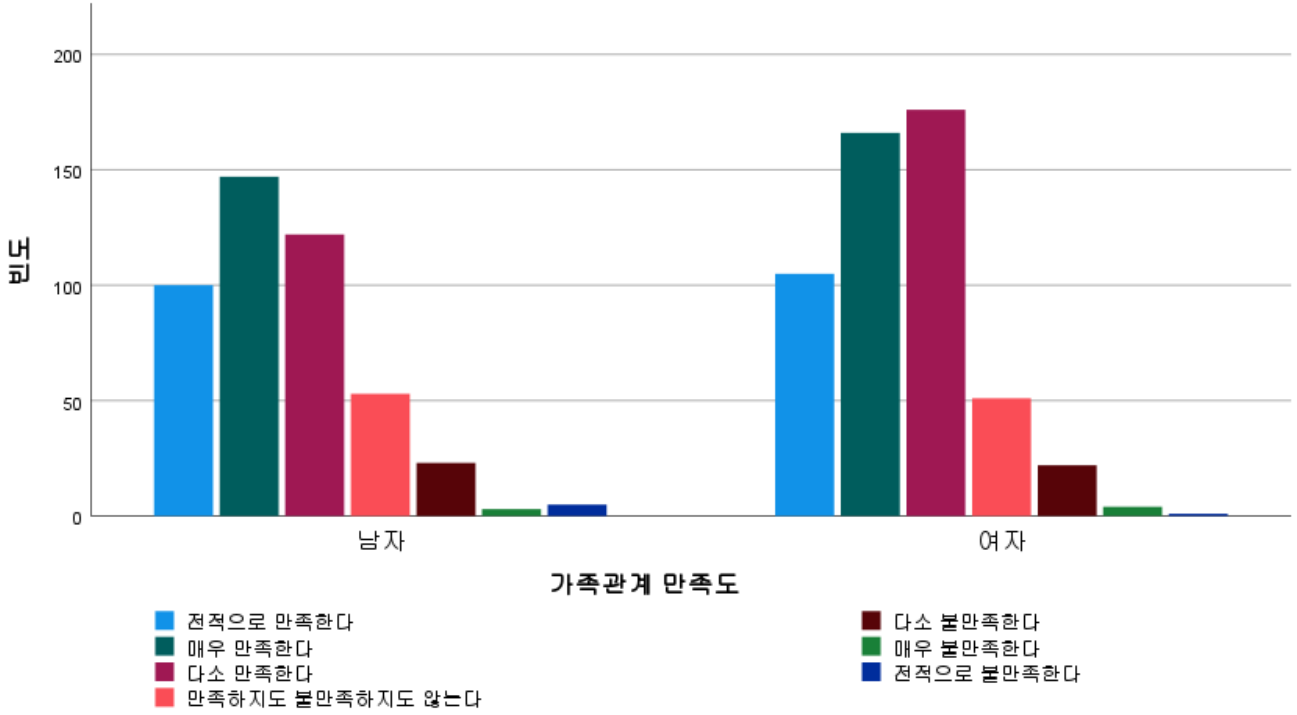

# 시간과 공간의 시각화

연습 11. PHARMACY.SAV 자료에 주어진 위도와 경도로 산점도를 그려보고 공간자료의 구조를 파악하시오.

# 시간과 공간의 시각화

- 위도와 경도가 주어져 있지 않고 지명이 텍스트(text)로 주어졌다면 이른바 지오코딩(geocoding) 단계를 거쳐야 한다.
- e.g., "충북 청주시 서원구 충대로 충북대학교" → 36.6287° N, 127.4606° E
- 공간자료란 결국 위도와 경도와 함께 주어지는 정보라고 할 수 있다(Why?).

# 시간과 공간의 시각화

연습 12. KOSIS 국가통계포털에서 [행정구역(시군구)별, 성별 인구수]를 다운로드받고 엑셀에서 불러들이시오. 남녀인구비율을 나타내는 공간자료를 시각화하시오.

# 시간과 공간의 시각화

- 아쉽지만 엑셀은 본래 지리정보시스템이 아니므로 한국의 고유한 지명을 제대로 인식하지 못하는 문제가 있다(엑셀 버전이 낮으면 아예 지오코딩이 지원되지 않는다).
- 가령 세종시와 강원도는 이름을 제대로 인식하지 못해 지오코딩에 실패하였다(Why?).
- 지도에서 레이블이 나타나도록 설정하고 제대로 지명이 인식되고 있는지 여부를 재확인해야 한다.
- 본격적인 실무나 연구에서는 공간자료분석을 위해 (1) ArcGIS나 QGIS같은 지리정보시스템 소프트웨어를 사용하거나, (2) 최소한 Tableau와 같은 비즈니스 인텔리전스(Business Intelligence; BI)를 사용한다.

끝!

와~ 이번 숙제는 정말 쉽네~