사회통계연습

자료구조의 재배열

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

September 27, 2024

진행 순서

1. 자료구조 재배열
2. 자료관리 종합연습

자료구조 재배열

자료구조 재배열

분석목적에 따라 자료를 뒤틀어 다른 꼴로 바꾸어야 할 때가 있다.

- 분석의 목적에 따라 긴 꼴(long form)과 넓은 꼴(wide form)로 자료구조를 재배열(reshaping)해야 하는 상황이 나온다.
- 자료의 본질은 변하지 않는다. 다만 형태만 바뀌는 것에 지나지 않는다.

자료구조 재배열

- 아래 예제는 넓은 꼴에서 긴 꼴로 자료를 변환할 때 어떻게 달라지는지 보여준다.
- (Weight과 BP 대신) Key와 Value가 새로 생겼다. 그리고 기존의 구체적인 값들은 Value 안에 들어갔다.

Name	Weight	BP
John	150	120
Smith	170	130

Name	Key	value
John	Weight	150
John	BP	120
Smith	Weight	170
Smith	BP	130

자료구조 재배열

- 아래의 또다른 예제는 긴 꼴에서 넓은 꼴로 자료를 변환하는 상황을 보여준다.

country	year	metric
x	1960	10
x	1970	13
x	2010	15
y	1960	20
y	1970	23
y	2010	25
z	1960	30
z	1970	33
z	2010	35

country	yr1960	yr1970	yr2010
x	10	13	15
y	20	23	25
z	30	33	35

자료구조 재배열

대체 왜 이런 재배열이 필요할까?

- 그 상황을 직접 부딪쳐보면 그 필요성을 이해할 수 있다.
- 만약 국가별로 metric을 종속변수로, year를 독립변수로 하는 회귀분석을 수행한다면 자료가 어떤 꼴일 때 더 편리할까?
- 만약 국가별로 metric의 시계열 도표(time-series plot)를 작성하고 싶다면 자료가 어떤 꼴일 때 더 편리할까?
- 문제는 적절한 배열의 형태를 파악하고 이를 제대로 수행하기가 몹시 어렵다는 점이다!
- (자료 결합과 마찬가지로) 혼동스럽기 때문에 상당한 경험과 연습을 필요로 한다.

자료구조 재배열

- SPSS에서는 [데이터]-[구조변환]으로 들어가서 예시 그림을 자세히 들여다보자.
- (1) '선택한 변수를 케이스로 구조변환'이 넓은 꼴에서 긴 꼴로 재배열한다.
- (2) '선택한 케이스를 변수로 구조변환'이 긴 꼴에서 넓은 꼴로 재배열한다.
- 예시 그림 위아래는 결국 좌우를 반대로 그린 셈이다!
- 강의안에서 본 예제와 비교하면서 이해하자.

자료구조 재배열

연습 5. BODYFAT.SAV 자료의 배열을 파악하고 다른 꼴로 재배열하시오.

자료구조 재배열

연습 6. 재배열된 BODYFAT.SAV 자료를 다시 원래 형태로 복구하시오.

자료구조 재배열

- 넓은 꼴에서 긴 꼴로 재배열하였다면 지수1과 trans1 같은 변수들이 나타난다.
- 여기서 지수1은 사실 Key이고, trans1은 사실 Value임을 알 수 있다(Why?).

Name	Weight	BP
John	150	120
Smith	170	130

→

Name	Key	value
John	Weight	150
John	BP	120
Smith	Weight	170
Smith	BP	130

자료구조 재배열

연습 7. Y1_STD_EDU.SAV 자료의 꼴을 파악하고 다른 형태로 재배열하시오.

자료구조 재배열

연습 8. 변환된 Y1_STD_EDU.SAV 자료를 다시 원래 형태의 꼴로 복구하시오.

자료관리 종합연습

자료관리 종합연습

연습 9. Y1_STD_EDU.SAV 자료와 Y2_STD_EDU.SAV 자료에서 각각 사회 자기의 총점을 계산하시오. 다른 변수들은 모두 삭제하고 전자에 후자를 결합하시오. 두 변수들의 연관성을 시각화하시오(결측치 처리에 주의할 것).

자료관리 종합연습

연습 10. NLSWORK_IND.SAV 자료에 NLSWORK_OCC.SAV 자료를 결합하기 위해 적절한 공통식별자를 확인하시오. 적절한 결합을 수행한 뒤, 개인 임금(ln_wage)과 업계평균 임금(avg_wage)의 격차를 나타내는 변수를 새로 계산하시오. 이 임금 격차 변수와 도심지역 거주(c_city) 변수 사이의 연관성을 시각화하시오(에러 메세지에 주의할 것).

자료관리 종합연습

연습 11. PROD.SAV 자료에는 1970년부터 1986년까지 미국 48개 주(state)에서 공공자본스톡(public capital stock)과 민간자본스톡(private capital stock)이 담겨 있다. 이 자료의 분석단위(unit of analysis)가 현재 무엇인지 판단하고 이를 주-연도(state-year)로 변환하시오.