사회통계연습

χ^2 분포, F 분포 그리고 ANOVA

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

October 13, 2023

진행 순서

1. 지난 주 리뷰
2. χ^2 분포와 F 분포
3. 일원분산분석의 논리

지난 주 리뷰

지난 주 리뷰

1. EFFECTS.SAV를 사용하여 K-다이어트를 수행하였을 때 예전 몸무게(BEFORE)와 이후 몸무게(AFTER)에 차이가 나타났다고 할 수 있는지 가설을 세우고 95% 신뢰수준에서 통계적으로 검정하시오.

지난 주 리뷰

- K-다이어트를 수행했을 때 예전 몸무게 μ_1와 이후 몸무게 μ_2에 차이가 있는지 알고 싶어하므로, 귀무가설은 "K-다이어트 전후로 예전 몸무게와 이후 몸무게에 차이가 없다"고 설정할 수 있고, 대립가설은 "K-다이어트 전후로 예전 몸무게와 이후 몸무게에 차이가 있다"고 설정할 수 있다.
- 몸무게 변수에 999라는 이상값이 있는데 이는 당연히 결측치 임시값으로 보아야 한다 (Why?). 이를 적절히 처리하지 않으면 안된다.
- 이제 쌍체표본 t 검정을 수행하면 t값으로 9.257을 얻을 수 있다(결측치 처리를 안하면 다른 값을 얻는다).
- 이때 양측검정 유의확률이 0.001보다 작으므로 99.9% 신뢰수준에서 통계적으로 유의하게 귀무가설을 기각할 수 있다.
- 즉 K-다이어트 전후로 몸무게에 분명히 차이가 있다는 결론을 내릴 수 있다!

지난 주 리뷰

2. MEDCOND.SAV를 SPSS에서 불러들여 각종 제한사항의 비율을 성별에 따라 비교하는 표를 작성하고 유의성 검정 결과를 보고하시오. 이때 표에는 (노령을 제외한) 모든 제한사항의 총합계 역시 성별로 비교하는 내용을 추가하시오.

지난 주 리뷰

- 가설구조는 다음과 같다(뒤바꾼다면 옳게 t검정의 방향과 일치시켜야 한다).

$$H_0 : \mu_{여} - \mu_{남} = 0$$
$$H_a : \mu_{여} - \mu_{남} \neq 0$$

- 귀무가설은 "성별에 따른 각 제한사항의 비율이 차이가 없다"이고, 대립가설은 "성별에 따른 각 제한사항의 비율이 차이가 있다"가 된다.
- 너무 당연하게도 결측치는 숨겨져 있으므로 알아서 제거해야 한다.
- 자료의 형태를 봤을 때 독립표본이므로 각각의 변수에 대해 독립표본 t 검정을 수행한다.
- 총합계를 합성지수(composite index)로 사용하며 지시대로 노령은 제외한다.
- Levene의 등분산 검정 결과에 따라 유의확률이 0.05보다 크면 등분산을 가정한 결과를, 유의확률이 0.05보다 작으면 등분산을 가정하지 않은 결과를 사용한다!

지난 주 리뷰

변수	여성			남성			격차	t값
	표본	평균/비율	표준편차	표본	평균/비율	표준편차		
골절, 관절부상	829	0.08	0.27	769	0.08	0.27	0.00	0.01
관절염, 류머티즘	828	0.16	0.37	769	0.08	0.27	0.08	5.09***
심장질환	828	0.05	0.21	769	0.03	0.17	0.02	1.64
호흡문제, 폐질환, 천식	828	0.04	0.21	768	0.05	0.21	-0.00	-0.09
뇌졸중	828	0.01	0.11	768	0.01	0.11	-0.00	-0.17
당뇨병	828	0.05	0.22	769	0.04	0.20	0.01	1.00
고혈압	828	0.10	0.30	769	0.10	0.30	0.00	0.17
등, 목의 문제	827	0.17	0.38	769	0.11	0.31	0.06	3.74***
암	828	0.01	0.12	769	0.01	0.10	0.01	1.00
치아 및 구강질환	829	0.18	0.39	768	0.21	0.41	-0.02	-1.13
시력문제	828	0.22	0.42	768	0.22	0.42	0.00	0.09
청각문제	828	0.04	0.21	768	0.07	0.25	-0.02	-2.09*
치매	827	0.01	0.08	768	0.00	0.05	0.00	1.05
우울/불안/정서상 문제	829	0.09	0.29	768	0.04	0.18	0.06	4.78***
정신지체	828	0.00	0.05	768	0.01	0.07	-0.00	-0.91
비만	828	0.10	0.30	768	0.08	0.27	0.02	1.36
기타	827	0.05	0.22	768	0.03	0.17	0.02	1.98*
총합계	825	1.38	1.94	766	1.16	1.66	0.22	2.43*

주: †p<.1, *p<.05, **p<.01, ***p<.001

지난 주 리뷰

3. Y2_STD_EDU.SAV와 Y3_STD_EDU.SAV는 같은 아동들을 초등학교 2학년 시기와 3학년 시기에 추적 조사한 자료이다. 회인은 "1년 전후로 신체자기에 관한 총점(합산점수)이 동일하다"라는 귀무가설을 세웠다. 적절한 대립가설을 제시하고 이에 관해 검정하시오.

지난 주 리뷰

- 귀무가설은 “초등학교 2학년과 3학년의 1년 전후 신체자기 총점(합산점수)은 동일하다”이고, 대립가설은 “초등학교 2학년과 3학년의 1년 전후 신체자기 총점(합산점수)은 동일하지 않다.”가 된다.
- 아쉽게도 결측치 제거는 이미 자료에서 설정이 되어 있었다.
- Y2_STD_EDU.SAV 자료와 Y3_STD_EDU.SAV 자료에서 변수 계산을 통해 각각의 신체자기에 관한 총점을 구한다.
- 학생 아이디 sid로 결합한다면 쌍체표본 t 검정을 수행하고, 그냥 아랫쪽에 덧붙였다면 독립표본 t 검정을 수행할 수 있다(Why?).

지난 주 리뷰

총평

- 가설을 전혀 쓰지 않는 경우가 좀 있었다(당연히 좋지 않다). 귀무가설(=영가설)과 대립가설을 혼동하는 경우도 있었다. 귀무가설을 기각한 뒤, 귀무가설대로 해석하는 황당한 경우도 있었다.
- 결측치를 처리하지 않은 경우가 매우 많았다.
- 문제를 대충 읽는 경우도 적지 않았다(비율을 성별에 따라 비교하라고 했는데 그러지 않거나, 노령을 분명히 포함하지 말라고 했는데 포함한 경우 등).
- 2번 문제에서는 여러 제한사항을 각각으로도 나타내야 한다. 종합 점수만 보고해선 안된다(점수 차감). 가설은 꼭 세워야하며 대체 어떤 귀무가설을 기각할 것인지 말 것인지를 분명히 해야 한다.

χ^2 분포와 F 분포

χ^2 분포와 F 분포

일단 하나의 표본분산 s^2에 대해 상상해보자.

- 우리는 모집단에서 표본을 무한히 계속 뽑고 그것들의 분산 s^2를 구해 분산의 표집분포를 상상해 볼 수야 있다
- 이때 표본 크기 n이 작다면 분산의 표집분포는 오른쪽 꼬리가 길어질 것이다(long tail). 그 이유는 생각보다 단순한데, 분산의 계산 과정에서 제곱을 하다보면 큰 값이 우연히 많이 나오기 때문이다.
- 하지만 아쉽게도 표본분산 s^2에 관한 직접적인 이론 분포는 없다!

χ^2 분포와 F 분포

- 평균 $\bar{x}$의 경우 소표본일 때 t 분포, 대표본일 때 Z 분포라는 이론적 확률분포를 가졌다.
- 반면 분산 s^2의 경우 직접적인 이론적 확률분포가 없고, "표본분산 s^2와 모분산 σ^2 간의 비율"에 관한 이론적 확률분포인 χ^2 분포(chi-square distribution)를 대신 사용한다.

$$\chi^2_{n-1} = \frac{(n-1)s^2}{\sigma^2}$$

- 말하자면 단일표본의 분산 s^2의 표집분포가 아니라, $(n-1)s^2/\sigma^2$ 비율의 표집분포를 상상해야 한다!

χ^2 분포와 F 분포

χ^2 분포는 오로지 자유도 $n-1$에 의해 모양이 결정된다.

- χ^2 분포는 소표본일 때 비대칭적이고 오른쪽으로 꼬리가 길다.
- Z 값에 제곱을 하다보면 우연히 큰 값이 나타나기 쉽고 표본이 작다보면 그 값이 튀어보이기 때문이다(Why?).

$$\chi_k^2 = Z_1^2 + Z_2^2 + \ldots + Z_k^2 = \sum \left(\frac{x-\mu}{\sigma}\right)^2$$

- 그러나 대표본이 될수록 정규분포의 모습에 점점 근사한다(Why?).
- χ^2 값은 결국 분산들의 비율이므로 항상 양수값을 갖는다.

$$\frac{(n-1)s^2}{\sigma^2} \geq 0$$

χ^2 분포와 F 분포

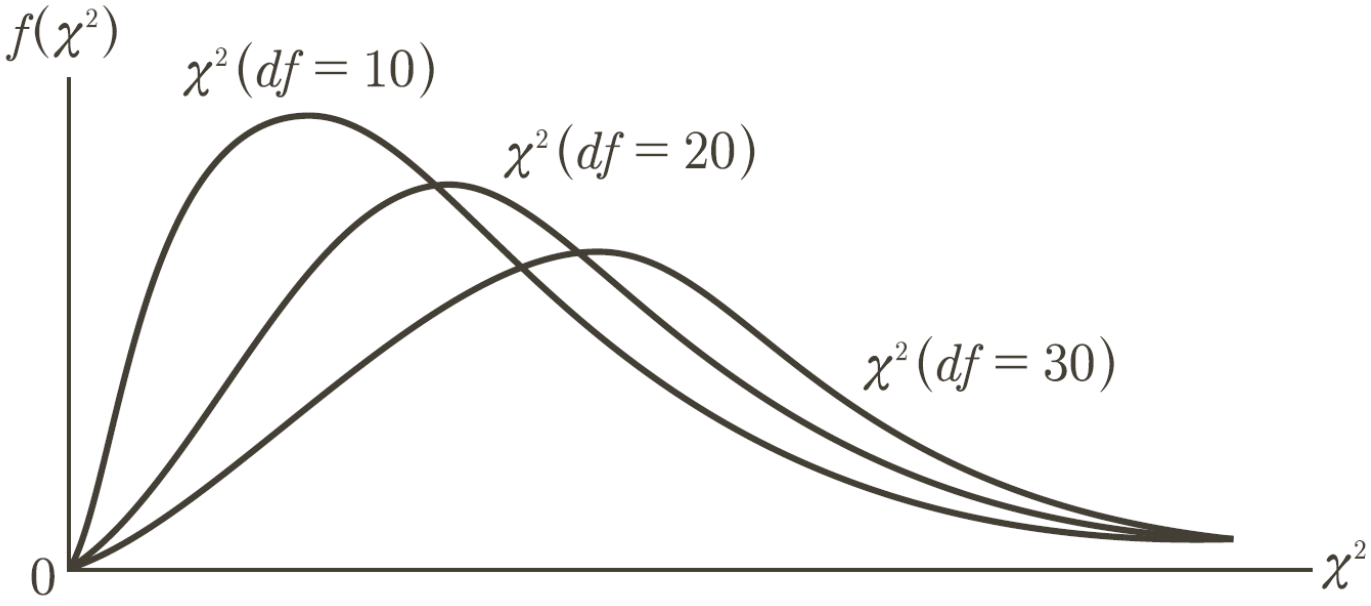

χ^2 분포와 F 분포

현실에서는 분산비교가 더 중요하고 이는 F 분포에 따라 수행된다.

- "단일모집단의 분산"에 관한 가설 검정이 χ^2 분포를 이용하는 반면, "두 모집단의 분산의 비율"에 관한 가설 검정은 F 분포를 이용한다(교과서 190).
- F 분포의 확률밀도함수(probability density function; PDF)는 다음과 같이 정의된다.

$$F_{(n_1-1,n_2-1)} = \frac{\chi_1^2/(n_1-1)}{\chi_2^2/(n_2-1)}$$

- 조금만 생각해보면 F 분포는 각각의 "단일모집단의 분산"을 설명하는 χ^2 의 비율임을 쉽게 파악할 수 있다(Why?).

χ^2 분포와 F 분포

- 우리는 두 표본의 분산의 차(difference)를 구하려는 것이 아니라 비(ratio)를 구하려는 것이므로 두 χ^2 값이 서로 비슷할수록 F 값은 (0이 아니라) 1에 접근하리라 예상할 수 있다.
- F 값은 두 개의 χ^2 분포의 비로 구성되므로 항상 양수(+)이다.
- F 분포는 두 개의 자유도 $n_1 - 1$와 $n_2 - 1$에 따라 그 형태가 결정된다. 이것도 χ^2가 하나의 자유도 $n - 1$를 파라미터로 받아 그 형태가 결정되는 것과 유사하다.
- 두 개의 자유도가 작을 때는 우측 꼬리가 길다. 두 개의 자유도가 점점 커지면 정규분포에 점점 근사한다.
- χ^2 분포와 마찬가지로 대칭적인 형태가 아니다.
- 일단 χ^2 분포 자체에 익숙해져야 F 분포에 대해서도 쉽게 이해할 수 있다.

χ^2 분포와 F 분포

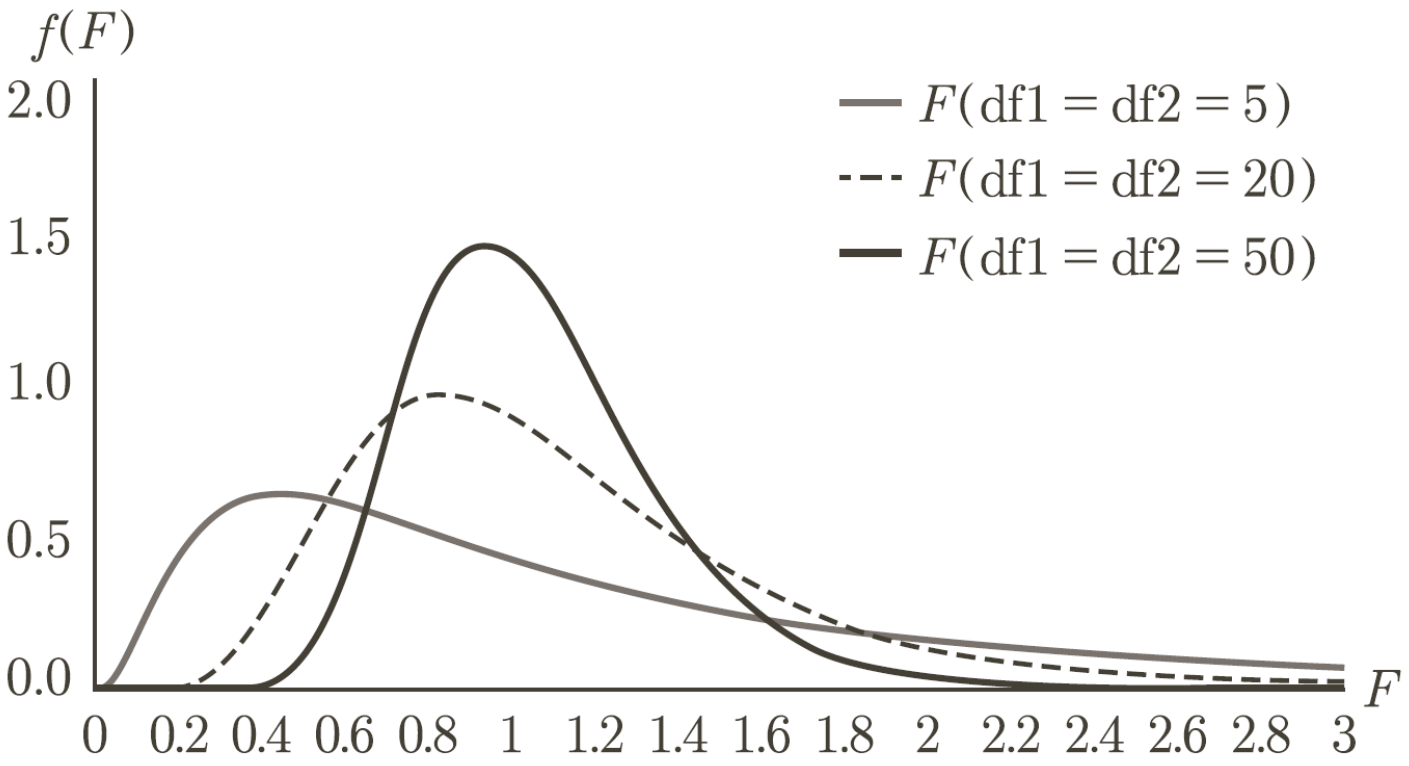
$f(F)$
2.0
1.5
1.0
0.5
0.0
0 0.2 0.4 0.6 0.8 1 1.2 1.4 1.6 1.8 2 2.2 2.4 2.6 2.8 3
F
$F(\mathrm{df1} = \mathrm{df2} = 5)$
$F(\mathrm{df1} = \mathrm{df2} = 20)$
$F(\mathrm{df1} = \mathrm{df2} = 50)$

χ^2 분포와 F 분포

검정통계량 F 값을 계산할 때 몇 가지 주의할 점이 있다.

- 검정통계량 F 값은 비율이기 때문에 어느 쪽이 분자가 되는지 주의해야 한다.
- 많은 교과서에서 분산이 큰 쪽을 반드시 분자로 놓도록 가르친다. 그러면 F 값은 반드시 1 또는 그보다 커지므로 양측검정은 사라지고 오로지 단측검정만 생각하면 된다(Why?).
- 우리도 이 설명 방식을 따른다.
- 분자분모 설정에 따라 분산비교를 위한 F 검정의 가설구조는 오로지 우측 단측검정만을 따르게 된다.

$$H_0 : \frac{\sigma_1^2}{\sigma_2^2} \leq 1$$

$$H_a : \frac{\sigma_1^2}{\sigma_2^2} > 1$$

일원분산분석의 논리

일원분산분석의 논리

분산분석으로 표본(=변수)의 분산에 관한 가설검정을 수행한다.

- Ronald Fisher는 F 분포를 만들고 그것을 절묘하게 활용하는 분산분석(Analysis of Variance; ANOVA)도 개발했다.
- 일원분산분석(one-way ANOVA)은 분산분석에 속한 여러 기법들의 가장 기초가 된다.
- 분산분석의 기본적인 개념을 학습하는데 유용할 뿐 아니라, 실제로도 여러가지 맥락에서 자주 사용된다.
- 사실 심리학을 제외한 다른 사회과학 분야에서는 실험자료(experimental data) 대신 관찰자료(observational data)가 더 폭넓게 사용된다. 다시 말해, 분산분석이 폭넓게 사용되기 어렵다.

일원분산분석의 논리

일원분산분석의 검정통계량도 F 값이다.

- 일원분산분석은 F 분포를 사용하며 그 원리는 앞서 설명한 두 모집단 분산에 대한 가설검정과 같다.

$$F_{(n-1,n-k)} = \frac{MS_{between}}{MS_{within}} = \frac{SS_{between}/(k-1)}{SS_{within}/(n-k)}$$

- 이때, 두 제곱합(sum of squares; SS)은 각각 다음과 같다.

$$SS_{between} = \sum(\mu_j - \mu)^2$$
$$SS_{within} = \sum(Y_{ij} - \mu_j)^2$$

- 분자인 $MS_{between}$는 실험처리에 의한 효과(treatment effect)로 볼 수 있고, 분모인 MS_{within}는 임의오차(random error)에 지나지 않는다.

일원분산분석의 논리

집단 간 분산이 클수록 그리고 집단 내 분산이 작을수록 F 값은 커진다.

- 수리적으로 따지고 들어갈 필요조차 없다. 사실 F 값이 갖는 의미는 상식적으로 너무나 명확하다!
- 두 표본이 주어졌을 때, 표본 간에는 차이가 크고 표본 내에는 차이가 작다면, 두 모집단은 서로 다른 것이다.
- 두 표본이 주어졌을 때, 표본 간에는 차이가 작고 표본 내에는 차이가 크다면, 두 모집단은 서로 다르다고 할 수 없다.
- 따라서 F 값이 크다는 것은 두 모집단은 서로 다름을 시사한다.

일원분산분석의 논리

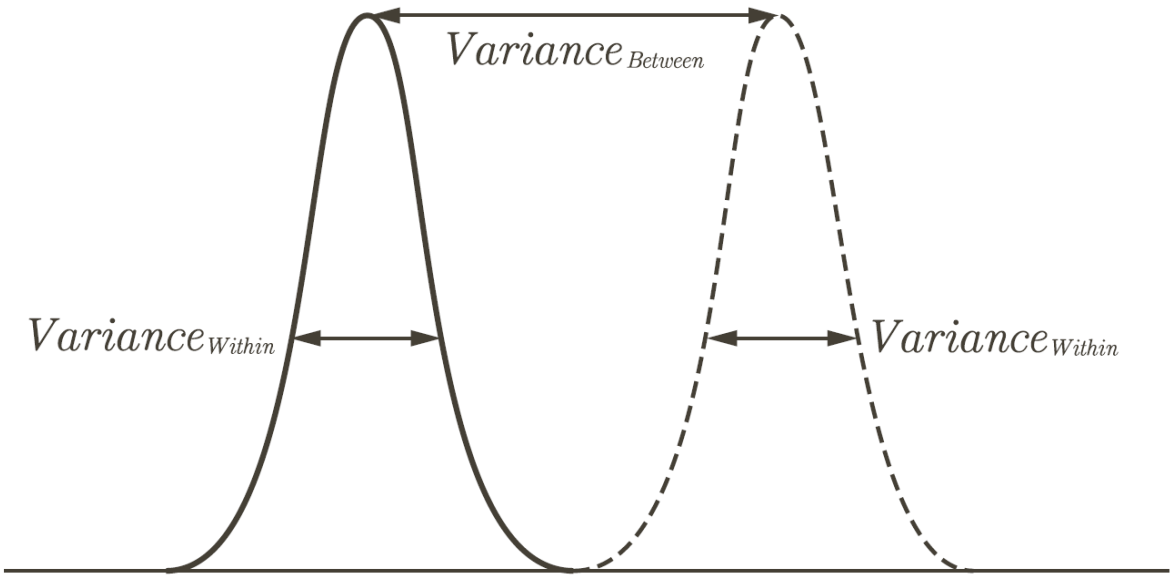
$Variance_{Between}$
$Variance_{Within}$
$Variance_{Within}$

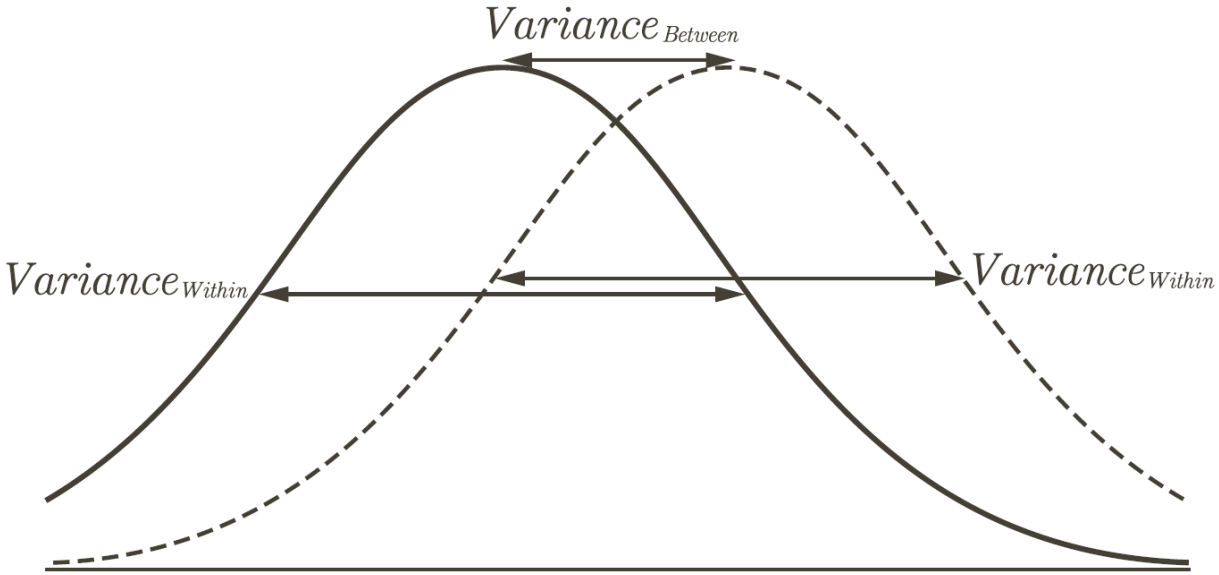
$Variance_{Between}$
$Variance_{Within}$
$Variance_{Within}$

일원분산분석의 논리

- 계산을 진행하면서 분산분석표(ANOVA table) 안에 각각의 숫자를 채워넣으면 된다. 아! 물론 계산은 컴퓨터가 한다.

Variance	SS	df	MS	F
Between groups	$SS_{between}$	$(k-1)$	$MS_{between}$	F
Within groups	SS_{within}	$(n-k)$	MS_{within}	
Total	SS_{total}	$(n-1)$	MS_{total}	

- 실제 표에서는 F 옆에 유의확률(p-value)이나 임계값(critical value) 등도 추가해서 써넣는 경우도 있다.

일원분산분석의 논리

일원분산분석의 가설 설정은 다소 주의를 요한다.

- 귀무가설은 모든 그룹에 걸쳐 평균이 같다는 내용이 된다. 예를 들면 다음과 같다: "출신지역 별로 정치적 보수주의 점수 평균에는 차이가 없다."

$$H_0 : \mu_1 = \mu_2 = \mu_3 = ... = \mu_j$$

- 그 대립가설은 "적어도 하나의 출신지역에서 정치적 보수주의 점수 평균이 다르다"가 된다.

$$H_a : (\mu_1 \neq \mu_2) \text{ or } (\mu_1 \neq \mu_3) \text{ or } ... \text{ or } (\mu_{j-1} \neq \mu_j)$$

- "모든 그룹에 있어 평균값이 다르다($H_a : \mu_1 \neq \mu_2 \neq \mu_3 = ... \neq \mu_j$)"가 아님에 주의할 것(Why?)!
- 일원분산분석은 실제 분석상 분산의 비율을 비교하고 있음에도 불구하고, 가설 설정은 평균에 대해 이루어진다는 점도 주의해야 한다.

일원분산분석의 논리

일원분산분석 절차는 굉장히 정형화되어 있다.

- 분석을 시작하기 전에 사용할 변수들이 무엇이고, 그들의 측도는 무엇인지 파악한다.
- 결측치와 극단치(outliers)의 존재를 파악하기 위해 먼저 기술통계 및 시각화를 수행하는 것이 좋다.
- SPSS에서 [분석]-[평균 비교]-[일원배치 분산분석]을 선택하여 일원분산분석을 수행한다. 이때 "기술통계"를 옵션에서 선택하는 쪽이 좋다.
- 분산분석표를 보고 해석할 수 있어야 한다. 제곱합, 자유도, 제곱 평균은 각각 어떻게 계산되었는지 이해한다.
- F 값과 유의 확률(p-value)은 어떻게 계산되었는지 이해한다.
- 분석의 결론은 무엇인지, 어떤 결론을 내려선 안되는지 판단한다.

일원분산분석의 논리

연습 1. citytemp.sav 자료를 SPSS에서 불러들여 1월 평균기온(tempjan)이 센서스 지역구획(region)에 따라 다른지 유의성 검정을 수행하시오.