사회통계연습
교차표 분석의 활용

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

October 20, 2023

진행 순서

1. 교차표에서 범주의 통폐합
2. 심슨의 역설
3. 다른 종류의 교차표
4. 교차표 및 χ^2 검정 연습

교차표에서 범주의 통폐합

교차표에서 범주의 통폐합

질적변수가 아니라 양적변수의 경우에도 교차표를 그릴 수 있을까?

- 물론이다. 정보의 손실(information loss)을 감수한다면 양적변수를 질적변수로 얼마든지 재부호화(recoding)할 수 있다. 그러나 그 역은 불가능하다.
- 엑셀에서는 "그룹" 기능으로 쉽게 범주화할 수 있다.
- 다만 범주화의 범위를 고려하여 많은 셀에서 0이 나오지 않도록 주의를 기울여야 한다!

교차표에서 범주의 통폐합

표본 크기가 작은데 셀에 아주 작은 숫자만 들어간다면 문제가 된다.

- 먼저 특정 셀에 아주 작은 숫자(특히 5보다 작은 수)가 들어간다는 것의 의미를 고민해야 한다.
- 이 문제는 아주 작은 표본($n < 40$)에 기반하여 2×2 교차표를 만들 때 제기되는 문제이다. 사실 오늘날 사회과학에서는 좀처럼 이런 상황이 없다.
- (2×2보다) 큰 교차표에서는 최소한 80% 이상의 셀이 5보다 큰 값을 가져야 한다.
- 이런 경우 다음의 세 가지 대응방법이 있다.

  (1) 범주를 다시 만든다. 2×2 교차표에서는 이 방법이 유효하지 않다.
  (2) (χ^2 독립성 검정에서) Yates의 연속성 보정(continuity correction)을 한다.
  (3) (χ^2 독립성 검정 대신) Fisher의 정확 검정(exact test)을 사용한다.

교차표에서 범주의 통폐합

연습 5. ASAN.SAV에서 향후 10년 내 한반도에서의 무력충돌 발생가능성과 주한미군의 한국주둔 필요성 인지 사이의 연관성에 대해 살펴보고 유의성 검정을 수행하시오. 그 다음, 무력충돌 발생가능성을 3개의 범주로 재부호화한 뒤 같은 방식으로 유의성 검정을 다시 수행하시오. 두 분석의 차이에 대해 논하시오.

교차표에서 범주의 통폐합

- 응답 범주를 통폐합하여 교차표의 행렬을 줄이거나 늘리면 χ^2 검정통계량과 유의도 검정 결과가 달라진다.
- 통계분석 자체는 거짓말을 한 것이 아니다(Why?).
- 다만 연구자가 자신에게 유리한 결과를 이끌어내기 위해 이런 재부호화를 시도할 수도 있다. 이것은 연구윤리 위반인가?
- 확실한 것은 연구자와 독자 사이에 분석과정의 정보비대칭(information asymmetry)이 제법 크다는 사실이다(Why?).

심슨의 역설

심슨의 역설

모든 통계분석에서 심슨의 역설을 기억해야 한다.

- x와 y의 관계를 살펴보고 양(+)의 상관관계를 발견했을 때, 그 상관관계는 집단 내부의 이질성(heterogeneity)은 고려하지 않은 결론으로만 받아들여야 한다 (Why?).
- 만약 집단 내부에 아주 주목할 만한 이질성이 존재한다면, 그 상관관계가 부분적으로 달라질 수 있다.
- 이것이 이른바 심슨의 역설(Simpson's Paradox)이다.
- 특히 집계자료(aggregate data)를 분석하여 내린 결론을 성급하게 그보다 작은 단위, 가령 개인자료(individual data)로도 확대적용하게 되면서 이런 문제가 발생한다.
- 이런 문제는 교차표 뿐 아니라 모든 통계분석에서 주의해야 하는 것이다!

심슨의 역설

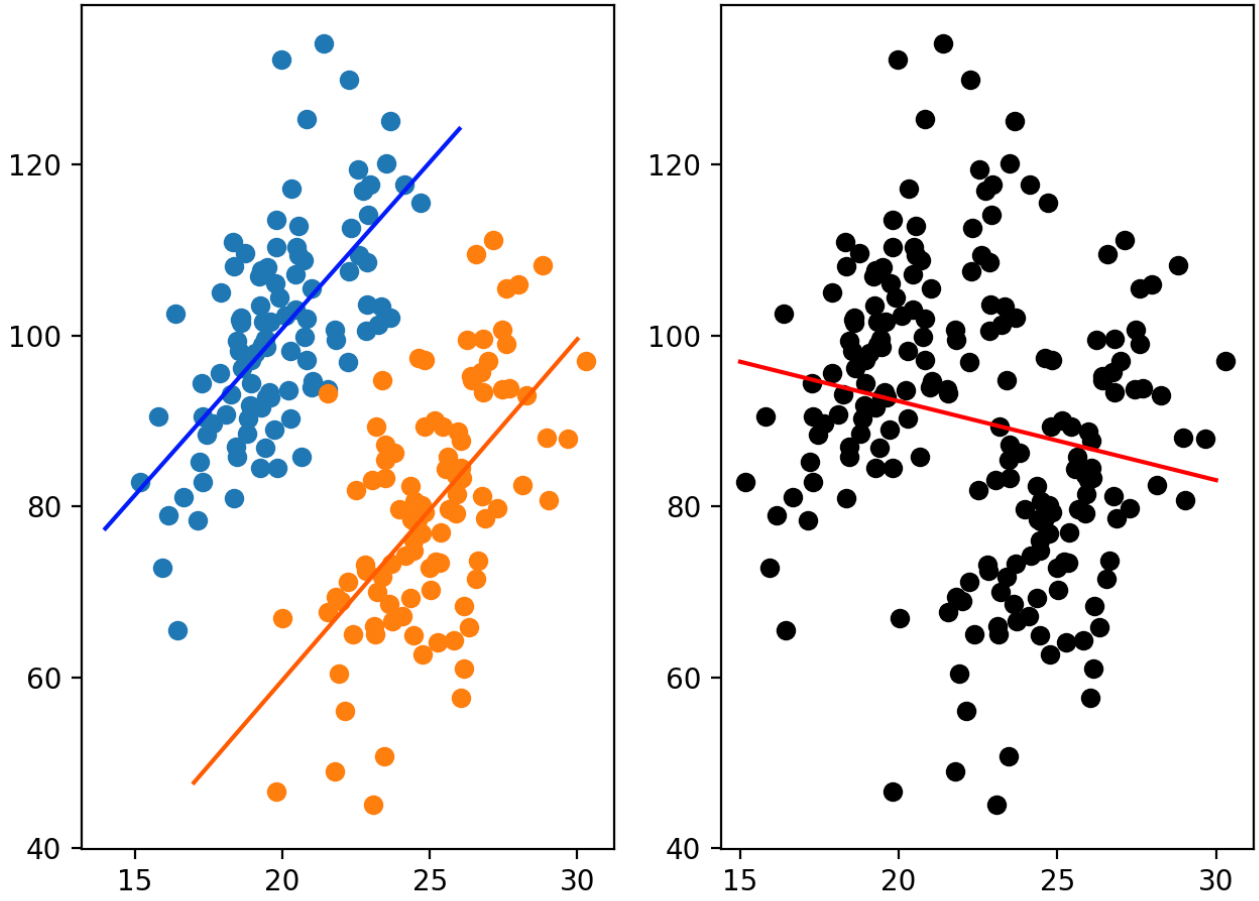

심슨의 역설

연습 6. EASTERLIN.SAV에서 소득수준 Q288R과 행복감 Q46 사이의 연관성을 살펴보기 위해 표를 작성하고 시각화하시오. 같은 표와 그래프를 국가 소득수준(incomeWB) 별로 각각 작성하고 발견점을 논의하시오.

심슨의 역설

- 전체 자료로 x와 y의 관계를 살펴보았을 때와 소득수준별로 쪼개어 그 연관성을 살펴보았을 때가 다르다.
- 소득수준이 높은 나라에서는 개인의 소득이 높아져도 행복감이 그만큼 증가하지 않는다. 이스털린의 역설(Easterlin's Paradox)이 이 패러독스를 지적한다.
- 그런데 자료를 얼마나 그리고 어떤 식으로 쪼갤 것인가는 상당히 애매한 문제이다 (Why?).
- 항상 그래프를 그리는 문제에 신경써야 한다. 종종 정답이 없으므로 다양한 방식으로 그려보고 어떤 방식이 가장 직관적인 해석을 제공하는지 고민해야 한다.

심슨의 역설

Low income
70
60
50
40
30
20
10
0
Low
Medium
High
Very happy
Quite happy
Not very happy
Not at all
Lower middle income
60
50
40
30
20
10
0
Low
Medium
High
Very happy
Quite happy
Not very happy
Not at all
Upper middle income
60
50
40
30
20
10
0
Low
Medium
High
Very happy
Quite happy
Not very happy
Not at all
High income
70
60
50
40
30
20
10
0
Low
Medium
High
Very happy
Quite happy
Not very happy
Not at all

다른 종류의 교차표

다른 종류의 교차표

Durhkeim의 〈자살론〉 교차표는 살짝 다른 종류의 것이다.

- Durkheim (1951[1897] 208)의 표를 잠깐 살펴보자.

	Suicides per million inhabitants	
	Urban population	*Rural population*
1866–69	202	104
1870–72	161	110

- SPSS에서는 [분석]-[표]-[사용자 정의 표]에서 만든다. 변수의 측도를 '척도(scale)'로 바꿔두어야만 평균을 보고할 수 있음에 주의해야 한다.
- 이런 종류의 교차표가 앞서 배운 교차표와 어떻게 다른지 꼼꼼하게 고민할 것! 문제가 주어졌을 때 어떤 교차표를 만들어야 하는지 먼저 파악해야 한다.
- 이러한 교차표에 대해서는 보통 χ^2 검정을 수행하지 않는다.

다른 종류의 교차표

사회동태의 구조를 교차표로 나타낼 수도 있다.

- 마코브체인(Markov Chain)은 상태변동 또는 이행(transition)의 확률을 교차표로 나타낸 것이다.
- 사회학에서는 세대간 직업이동(intergenerational occupational mobility)과 관련한 분석기법으로 잘 알려져 있다.
- 특히 직업이동 유출표(outflow table)에서 행(row)은 투입(input)이고 열(column)은 산출(output)로 생각할 수 있다.

다른 종류의 교차표

〈표 1〉 1, 2, 3차 불평등조사의 세대간 직업이동표의 유출률 비교: 1990-2000년

1. 1990년

	정신근로자	육체근로자	농민	계
정신근로자	66.1%	30.9%	3.0%	100.0%
육체근로자	39.2%	57.3%	3.5%	100.0%
농민	37.1%	36.0%	26.8%	100.0%

2. 1995년

	정신근로자	육체근로자	농민	계
정신근로자	61.5%	36.0%	2.5%	100.0%
육체근로자	37.5%	60.1%	2.4%	100.0%
농민	36.7%	43.8%	20.5%	100.0%

3. 2000년

	정신근로자	육체근로자	농민	계
정신근로자	68.4%	28.7%	3.0%	100.0%
육체근로자	43.2%	52.9%	3.9%	100.0%
농민	34.3%	48.3%	17.5%	100.0%

주: 행과 열은 각각 아버지와 아들의 직업을 가리킴.

차종천. 2002. "최근 한국사회의 사회이동 추세: 1990-2000." 『한국사회학』 36(2): 1-22.

다른 종류의 교차표

- 행렬의 곱셈을 알면 앞으로 직업이 어떻게 변화하게 될지 예상할 수 있다.

$$\begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix} \times \begin{bmatrix} 10 & 11 \\ 20 & 21 \\ 30 & 31 \end{bmatrix}$$

$$= \begin{bmatrix} 1\text{x}10 + 2\text{x}20 + 3\text{x}30 & 1\text{x}11 + 2\text{x}21 + 3\text{x}31 \\ 4\text{x}10 + 5\text{x}20 + 6\text{x}30 & 4\text{x}11 + 5\text{x}21 + 6\text{x}31 \end{bmatrix}$$

$$= \begin{bmatrix} 140 & 146 \\ 320 & 335 \end{bmatrix}$$

- 만약 2000년에 정신근로자가 100명, 육체근로자가 120명, 농민이 60명이였다면, 5년 뒤에는 각각 140.8명, 121명, 18명이 된다!

$$\begin{bmatrix} 100 & 120 & 60 \end{bmatrix} \times \begin{bmatrix} 0.684 & 0.287 & 0.03 \\ 0.432 & 0.529 & 0.039 \\ 0.343 & 0.483 & 0.175 \end{bmatrix} = \begin{bmatrix} 140.82 & 121.16 & 18.18 \end{bmatrix}$$

다른 종류의 교차표

연습 7. MCHAIN.SAV 자료를 SPSS에서 불러들여 직업이동의 유출표를 작성하시오.

다른 종류의 교차표

- 실제로는 큰 데이터로 만들지 않으면 각 셀 안의 사례수가 너무 적아 신뢰하기 어렵다 (Why?).
- 사회가 격변을 겪게 되면 직업이동 유출표의 안정성은 의심받을 수 밖에 없다(Why?).
- 직업이동 유출표 외에도 마코브체인과 관련하여 (1) 광역지자체간 인구이동이나 (2) 매년 조직내 인사이동 등 수많은 사회학적 예를 상상해 볼 수 있다.
- 각종 마케팅에서는 (1) 브랜드 이동(brand switching), (2) 지지후보의 변화 등을 측정하는데 마코브 체인이 활용되기도 한다.
- 어떤 식으로 표를 만들어야 할지 상상해보자.

교차표 및 χ^2 검정 연습

교차표 및 χ^2 검정 연습

연습 8. ECONEVAL.SAV에서 불러들여 연령대가 자기 가족의 현재 경제상황 Q4과 그리고 자기 가족의 몇 년 뒤 경제상황 Q6과 각각 어떻게 연관되어 있을지 표와 그림을 만들고 통계적 검정을 수행하시오.

교차표 및 χ^2 검정 연습

연습 9. ASAN.SAV에서 응답자의 성별, 연령대, 거주지역, 학력, 직업, 가구소득 별로 기술통계표를 만들고자 한다. 이때 각 인구학적 속성이 주한미군 신뢰도 및 주한미군의 한국주둔 필요성과 어떠한 연관성을 가지고 있는지 나타내는 표를 작성하고 적절한 유의성 검정을 수행하시오.