사회통계연습

모형의 적합도와 결과표 작성

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

November 8, 2024

진행 순서

1. 모형의 적합도
2. 결과표 작성

모형의 적합도

모형의 적합도

이제 자신의 회귀모형을 평가해보자.

- 우리가 모형(model)을 세워 그것을 현실 데이터에 맞추어(fit) 본 이상, 이것이 얼마나 잘 맞는가를 말할 수 있어야 한다. 이것이 모형의 자료 적합도(goodness-of-fit)이다.
- 크게 세 가지 적합도 지표(goodness-of-fit indices)를 공부한다:

  (1) 결정계수(R^2) 또는 조정된(adjusted) 결정계수(R^2)
  (2) 일원분산분석(one-way ANOVA)
  (3) 제곱근평균제곱오차(root mean square error; RMSE).
- 어느 한 가지 지표에만 맹목적으로 의존하지 않고 모든 지표들을 균형있게 살펴보면서 자신이 세운 모형이 얼마나 자료에 잘 맞는가를 확인해야 한다.
- 물론 적합도 지표에 근거해 여러 가지 모형들을 비교 평가할 수도 있다.

모형의 적합도

먼저 결정계수를 살펴보자.

- 주어진 자료에 전체 변량(total variation)이 있다면, 이것은 (모형에 의해) 설명된 변량(explained variation)과 (그렇지 못하고) 남은 변량(residual variation)의 합이라고 분해될 수 있다.

$$\sigma^2_{total} = \sigma^2_{explained} + \sigma^2_{residual}$$

- 그렇다면 설명된 변량 $\sigma^2_{explained}$와 전체 변량 σ^2_{total}의 비율은 모형의 높은 설명력을 의미한다고 볼 수 있다.

$$R^2 = \frac{\sigma^2_{explained}}{\sigma^2_{total}} = 1 - \frac{\sigma^2_{residual}}{\sigma^2_{total}}$$

- 이것이 바로 결정계수 R^2의 직관적 의미이다. 설명된 변량과 전체 변량의 비율이므로 0과 1사이에 놓인다. 1에 가까울수록 모형은 높은 적합도를 보인다고 할 수 있다.

모형의 적합도

독립변수 X가 없을 때 종속변수 Y를 가장 잘 예측하는 요소는 무엇일까?

- 이 질문은 생각보다 매우 중요하다! 그것은 바로 종속변수의 평균($\bar{Y}$)이다(Why?).
- 이 원리는 우리에게 중요한 원칙 하나를 제공한다: "어떤 모형을 세우던지 최소한 종속변수의 평균($\bar{Y}$)보다는 나은 설명력을 보여야 한다."
- 종속변수의 평균 $\bar{Y}$은 일종의 기준점이자 최소한의 바닥이다. 이것보다도 못한 모형은 아무런 가치도 없다.
- 한편 종속변수의 실제 값(Y_i)은 일종의 이상점이자 최고의 천장이다. 이것은 모형이 추구할 수 있는 최고의 이상이다.
- (직관적으로 설명한다면) 당연히 모형의 예측값 $\widehat{Y}_i$은 Y_i와 $\bar{Y}$ 사이 어딘가 놓이리라 생각할 수 있다(실제로는 꼭 그렇지 않을수도 있다).

모형의 적합도

- (아주 엄밀하지는 않지만) 그림을 통해서 우리는 총변량이 "설명된 변량"과 "잔여 변량"의 합임을 직관적으로 이해할 수 있다.

$$(Y_i - \bar{Y}) = (Y_i - \widehat{Y}_i) + (\widehat{Y}_i - \bar{Y})$$

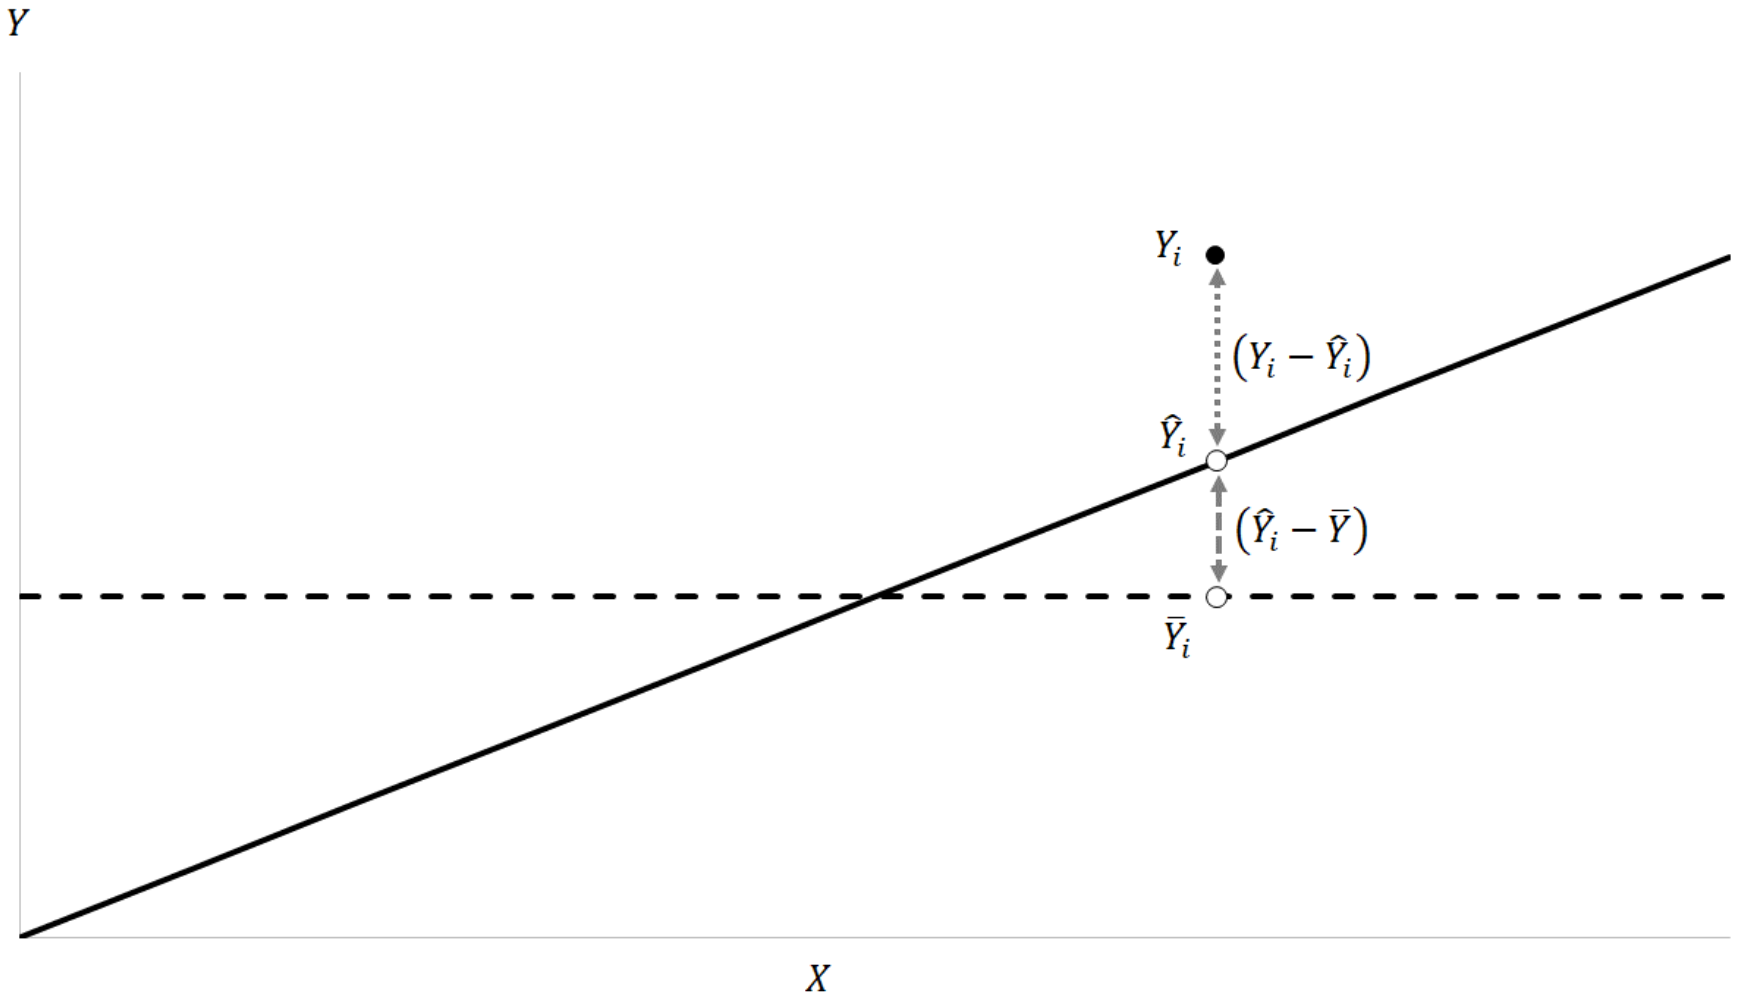

모형의 적합도

- 우리는 이제 제곱합(Sum of Squares; SS) 개념을 가지고 다음의 공식에 도달할 수 있다(증명 생략).

$$\sum(Y_i - \bar{Y})^2 = \sum(Y_i - \widehat{Y}_i)^2 + \sum(\widehat{Y}_i - \bar{Y})^2$$
$$SS_{total} = SS_{residual} \quad + SS_{explained}$$

- 이제 결정계수 R^2를 측정할 수 있다.

$$R^2 = \frac{SS_{explained}}{SS_{total}} = \frac{\sum(\widehat{Y}_i - \bar{Y})^2}{\sum(Y - \bar{Y})^2}$$
$$= 1 - \frac{SS_{residual}}{SS_{total}} = 1 - \frac{\sum(Y_i - \widehat{Y}_i)^2}{\sum(Y_i - \bar{Y})^2}$$

모형의 적합도

연습 5. CAR_PRICES.SAV에서 중고차 가격(Price)을 차량의 연식(Age)으로 설명하시오. 이후 추가적으로 주행거리(Miles)를 독립변수로 추가하였을 때 모형 적합도의 개선 여부를 판단하시오.

모형의 적합도

모형 적합도 판정은 상당히 정형화되어 있다.

- "차량의 연식만을 고려한 회귀모형으로도 중고차 가격 변량의 83%를 설명한다."
- "차량 연식과 주행거리를 추가하였을 때, 이 회귀모형은 중고차 가격 변량의 84.6%를 설명한다."
- 변수를 하나 추가하였지만 통계적으로 유의하지도 않고 R는 겨우 1.6% 증가했을 뿐이다.
- 바로 아래 조정된 결정계수(adjusted R^2)는 무엇인가? 기본적으로 결정계수는 보다 많은 독립변수를 집어넣을 때 무제한적으로 팽창하는 성향이 있다. 그런데 이것은 오캄의 면도날 원칙(Occam's Razor)에 반하는 것이므로, 독립변수를 추가적으로 집어넣을 때마다 적절한 패널티를 가할 필요가 있다.
- 조정된 결정계수는 바로 이렇게 패널티가 가해진 결정계수이다.

모형의 적합도

분산분석 결과표 역시 모형 전체의 적합도를 보여준다.

- 아래와 같이 선형모형을 설정하였을 때 최악의 추정 결과는 무엇일까?

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_2 + \beta_3 X_3 + \epsilon_i$$

- 그건 (상수 빼고) 모든 회귀계수가 0이 되는 상황이다. 보다 구체적으로 말해서 "모집단에서 (상수 빼고) 모든 β가 0인 상황"이다.
- 제대로 된 모형이라면 최소한 이런 경우는 부정할 수 있어야 한다. 만일 이런 상황을 부정할 수 없다면 "이 모형은 완전히 쓸모없다" 라는 말을 부정할 수 없는 것이나 마찬가지이기 때문이다.

모형의 적합도

- 그러므로 다음과 같은 가설구조를 검증해 볼 수 있다.

$$H_0 : \beta_1 = \beta_2 = \beta_3 = 0$$
$$H_a : (\beta_1 \neq 0) \text{ or } (\beta_2 \neq 0) \text{ or } (\beta_3 \neq 0)$$

- 이 가설구조를 테스트할 수 있는 방법은 일원분산분석(one-way ANOVA)이다.

모형의 적합도

- 제6주차 때 연습한 일원분산분석의 검정통계량 F 값은 다음과 같았다.

$$F_{(k-1,n-k)} = \frac{\sigma^2_{between}}{\sigma^2_{within}} = \frac{MS_{between}}{MS_{within}} = \frac{SS_{between}/(k-1)}{SS_{within}/(n-k)}$$

- 다중회귀분석의 맥락에서 검정통계량 F 값은 다음과 같다. 단 k는 독립변수의 수를 의미한다.

$$F_{(k,n-k-1)} = \frac{\sigma^2_{explained}}{\sigma^2_{residual}} = \frac{MS_{explained}}{MS_{residual}} = \frac{SS_{explained}/k}{SS_{residual}/(n-k-1)}$$

- F 값이 클수록 유의확률(p-value)이 작아지므로 위 귀무가설을 기각할 수 있다.

모형의 적합도

- 분산분석표 안에 채워진 숫자는 다음과 같은 의미이다(교재 309).

Variance	SS	df	MS	F
Explained	$SS_{explained} = \sum(\widehat{Y}_i - \bar{Y})^2$	k	$MS_{explained}$	F
Residual	$SS_{residual} = \sum(Y_i - \widehat{Y}_i)^2$	$n-k-1$	$MS_{residual}$	
Total	$SS_{total} = \sum(Y_i - \bar{Y})^2$	$n-1$	MS_{total}	

- SPSS에서는 Explained 대신에 Regression으로 표기하고 있다.

모형의 적합도

이제 회귀분석 결과에서 ANOVA표를 이해할 수 있다!

- CAR_PRICES.SAV에서 F 값은 46.835이고 유의확률(Sig.)은 0.000이므로 0.05보다 당연히 작다. 그러므로 99.9% 신뢰수준에서 다음의 귀무가설을 기각할 수 있다.

$$H_0 : \beta_{\text{Age}} = \beta_{\text{Miles}} = 0$$

- 우리는 "모든 회귀계수가 0이다"라는 귀무가설을 기각하고 "최소한 하나의 회귀계수는 0이 아니다"라는 대립가설을 채택할 수 있었다. 다행이다~

결과표 작성

결과표 작성

회귀분석을 수행하고나서 그 결과물을 표로 정리하여 보고해야 한다.

- 김성훈·우명숙(2020)을 참고로 어떤 표들이 필요한지 살펴보자!
- 최종적으로 사용한 변수의 목록을 잘 정리하여 표로 정리했음을 기억하자.
- 회귀분석의 결과표가 어떤 식으로 이루어졌는지 잘 흉내내어 만들어보아야 한다.

결과표 작성

〈표 4〉 고3 학업성취도에 대한 회귀분석의 결과 1

	모형 1		모형 2		모형 3	
	계수	표준오차	계수	표준오차	계수	표준오차
비일반고[1]	.062**	.179	.017	.155	.019	.154
중3 학업성취도			.509***	.008		
남성[2]					-.009	.107
자아존중감					.165***	.014
학습시간					.091***	.008
학습태도					.355***	.013
교사-학생 관계					.046*	.019
가구소득					.056**	.114
부모 관리/전문직[3]					.034	.116
부모 대졸 이상[4]					.055**	.123
부모 감독					-.005	.035
부모 애정					.009	.029
4년제 대학교 졸업 부모 기대[5]					.082**	.194
대학원 졸업 부모 기대[5]					.099***	.253
아직 정해지지 않은 부모 기대[5]					.028	.243
상수	8.952***	.065	6.498***	.126	-.819	.985
사례수	1,361		1,361		1,361	
결정계수	.004		.261		.285	

***$p<.01$, **$p<.05$, *$p<.1$.
계수는 표준화 회귀계수. 단, 상수의 계수는 비표준화 회귀계수.
기준집단: 1 = 일반고; 2 = 여성; 3 = 부모 비전문/관리직; 4 = 부모 고졸 이하; 5 = 2-3년제 전문대학 졸업 이하 부모 기대.

결과표 작성

연습 6. 2020년 Z세대 10대 청소년의 가치관 변화 연구 자료를 사용하여 다음에 답하시오.

(1) 종속변수로 다문화사회에 대한 지지(24번 문항)를, 우리 사회에 대한 공정성 변수들(16-2, 16-3, 16-4, 16-5)의 합성지수를 독립변수로 하는 단순회귀분석을 수행하시오.

(2) 공동체에 대한 기여 의식 변수들(16-7, 16-8, 16-9, 16-10, 16-13)의 합성지수를 추가적인 독립변수로 하는 다중회귀분석을 별도로 수행하시오.

(3) 이때 적절한 가설을 각각 제시하고, 유의성 검정 및 그 해석을 적절히 제시하시오. 모형의 적합도 개선 여부에 대해 논하시오.

(4) 김성훈·우명숙(2020)을 참고로 회귀분석의 결과표 및 시각화 또한 제시하시오.